

Detecção de Fake News com Redes Neurais de Grafos: Ablation Sistemática e Diagnóstico de Aplicabilidade Topológica

André Messina Livingston

César Augusto Sibila

Enzo Kikuji Takida

Brasil, 2026

André Messina Livingston

César Augusto Sibila

Enzo Kikuji Takida

**Detecção de Fake News com Redes Neurais de Grafos:
Ablation Sistemática e Diagnóstico de Aplicabilidade
Topológica**

Brasil

2026

Contents

Resumo	1
Abstract	3
1 Introdução	7
1.1 Contextualização	7
1.2 Motivação	7
1.3 Perguntas de pesquisa	7
1.4 Contribuições	7
1.5 Estrutura do trabalho	7
2 Fundamentação Teórica	8
2.1 Detecção de fake news: panorama	8
2.2 Grafos e redes sociais	8
2.3 Embeddings textuais	8
2.4 Redes Neurais de Grafos	8
2.4.1 Graph Convolutional Networks (GCN)	8
2.4.2 Graph Attention Networks (GAT)	8
2.4.3 GraphSAGE	8
2.5 Degeneração do GCN com features homogêneas	8
2.6 Encodings posicionais	9
2.7 Explicabilidade em GNNs: GNNExplainer	9
2.8 Validação estatística	9
2.9 Trabalhos relacionados	9
2.9.1 Surveys de GNNs em fake news	9
2.9.2 Métodos GNN canônicos	9
2.9.3 Detecção multilíngue	9
2.9.4 Trabalhos brasileiros relacionados	9
2.9.5 Homofilia e assortatividade em redes	9
2.9.6 Posicionamento deste trabalho	9

3	Metodologia	10
3.1	Visão geral do pipeline	10
3.2	Datasets	10
3.3	Construção de grafos: FakeNewsNet	10
3.4	Folds compartilhados	11
3.5	Arquiteturas GNN e hiperparâmetros	12
3.6	<i>Baselines</i> não-GNN	13
3.7	Protocolo de avaliação	13
3.8	Análise estratificada do erro	14
3.9	Análise de explicabilidade	15
3.10	Classificador dual: regra de combinação <i>post-hoc</i>	15
3.11	Reprodutibilidade	15
4	Resultados Experimentais	17
4.1	<i>Baselines</i> textuais sobre BERT da raiz	18
4.2	Diagnóstico de <i>confound</i> topológico	19
4.3	Cross-dataset UPFD: nossos resultados <i>versus</i> literatura	20
4.4	Topologia sem texto: o achado central (RQ3, parte a)	21
4.5	Consistência de <i>score</i> topológico entre idiomas (RQ3, parte b)	23
4.6	Por que GossipCop funciona e PolitiFact não? (RQ2)	25
4.7	Concordância textual $\times$ topológico (RQ1)	27
4.8	GNNExplainer: o que o SAGE aprendeu	30
4.9	Análise estratificada do erro	31
4.9.1	Distribuição estrutural: <i>heavy-tail</i> mais agressivo que lognormal	31
4.9.2	LOWESS: onde o modelo degrada	32
4.9.3	Outliers e a inversão distributiva	33
4.9.4	Cascatas profundas: o ganho cresce com a profundidade	36
4.10	Painel mestre dos achados	39
5	Discussão e Conclusão	40
5.1	Síntese dos achados por pergunta de pesquisa	40
5.2	Achado negativo é achado	41
5.3	Limitações	42
5.4	Trabalhos futuros	43
5.5	Considerações finais	44
A	Hiperparâmetros completos	47
B	Índice geral de figuras e tabelas	48
C	Estrutura do repositório de código	49

D	Aplicação demonstrativa: Bluesky e ferramenta web	50
D.1	O <i>dataset</i> Bluesky	50
D.2	Inferência <i>cross-domain</i> dos modelos persistidos	50
D.3	Concordância textual $\times$ topológico	52
D.4	Ferramenta web	52

Chapter 1

Introdução

1.1 Contextualização

1.2 Motivação

1.3 Perguntas de pesquisa

1.4 Contribuições

1.5 Estrutura do trabalho

Chapter 2

Fundamentação Teórica

2.1 Detecção de fake news: panorama

2.2 Grafos e redes sociais

2.3 Embeddings textuais

2.4 Redes Neurais de Grafos

2.4.1 Graph Convolutional Networks (GCN)

$$H^{(l+1)} = \sigma \left(\hat{D}^{-1/2} \hat{A} \hat{D}^{-1/2} H^{(l)} W^{(l)} \right) \quad (2.1)$$

2.4.2 Graph Attention Networks (GAT)

$$\alpha_{ij} = \frac{\exp \left(\text{LeakyReLU}(\mathbf{a}^T [W h_i \parallel W h_j]) \right)}{\sum_{k \in \mathcal{N}(i)} \exp \left(\text{LeakyReLU}(\mathbf{a}^T [W h_i \parallel W h_k]) \right)} \quad (2.2)$$

2.4.3 GraphSAGE

2.5 Degeneração do GCN com features homogêneas

$$\begin{aligned} H^{(1)} &= \sigma \left(\tilde{A} X W \right) \\ &= \sigma \left(\tilde{A} \mathbf{1}_N x^T W \right) \\ &= \sigma \left((\tilde{A} \mathbf{1}_N) (x W)^T \right) \end{aligned} \quad (2.3)$$

2.6 Encodings posicionais

2.7 Explicabilidade em GNNs: GNNExplainer

2.8 Validação estatística

Table 2.1: Interpretação de tamanho de efeito de Cohen (d).

$ d $	Interpretação
< 0.2	desprezível
$0.2 \leq d < 0.5$	pequeno
$0.5 \leq d < 0.8$	médio
≥ 0.8	grande

2.9 Trabalhos relacionados

2.9.1 Surveys de GNNs em fake news

2.9.2 Métodos GNN canônicos

2.9.3 Detecção multilíngue

2.9.4 Trabalhos brasileiros relacionados

2.9.5 Homofilia e assortatividade em redes

2.9.6 Posicionamento deste trabalho

Chapter 3

Metodologia

3.1 Visão geral do pipeline




Figure 3.1: Visão geral do *pipeline* de detecção. Dados brutos são transformados em grafos de propagação com *features* estruturais (e textuais via BERT, quando disponíveis), passados por modelos GNN, e avaliados com protocolo de k-fold pareado.

3.2 Datasets

Table 3.1: Datasets utilizados, com tamanho, fonte e papel no trabalho.

Dataset	N grafos	N classes	Fonte	Papel
FakeNewsNet PolitiFact	~754	2 (50/50)	[3]	Treino + validação
UPFD-PolitiFact	~314	2 (50/50)	[1]	Cross-dataset
UPFD-GossipCop	~5.464	2 (50/50)	[1]	Cross-dataset
Bluesky (acadêmico)	168.463	–	[2]	Aplicação (sem <i>labels</i>)

3.3 Construção de grafos: FakeNewsNet

A construção dos grafos do FakeNewsNet é realizada pelo *script* `00_construir_grafos_fakenewsnet`. O *script* efetua o *download* direto dos CSVs do repositório oficial do KaiDMML [3], gera o *embedding* textual do título de cada notícia via *Sentence-BERT* multilíngue (modelo `paraphrase-multilingual-mpnet-base-v2`, dimensão 768) e *cacheia* o resultado em disco para evitar recomputação. Cada notícia gera um grafo em estrela: o nó raiz é a

notícia em si, e seus filhos são os identificadores de *tweets* listados pelo CSV como tendo propagado a notícia.

A topologia em estrela (e não em árvore com profundidade) é imposta pelo formato do CSV bruto, que fornece apenas uma lista plana de `tweet_ids` por notícia, sem relação de parentesco entre *retweets* e sem *timestamps* (caveat já discutido em §3.2). Aplicam-se dois filtros: o mínimo de dois *tweets* de propagação por notícia (descarta cascatas degeneradas, sem o que o grafo de propagação seria reduzido a um único nó) e o máximo de 100 nós por grafo. A distribuição bruta de tamanhos de cascata é fortemente assimétrica: a mediana é de 30 *tweets*, mas a média chega a 552 e o máximo observado a 29.060. O limite de 100 nós trunca, portanto, 50% dos grafos do *dataset*; não se trata de remoção de *outliers* raros, mas de decisão de projeto com efeito substancial. A justificativa é estrutural: em um grafo-estrela, todos os nós-filho compartilham o mesmo *embedding* BERT (replicado a partir do título), e folhas adicionais além de uma centena acrescentam informação marginal desprezível; além disso, o *global mean pool* adotado pela camada final faria com que, em um grafo de dezenas de milhares de folhas quase idênticas, a contribuição do nó raiz, único portador das *features* `is_root` e `grau_norm`, fosse diluída a uma fração ínfima do vetor agregado. Como contrapartida, os grafos truncados tornam-se indistinguíveis quanto ao tamanho absoluto da cascata (limitação retomada em §5.3).

O *script* oferece três variantes de construção, controladas pela *flag* `-feature-variant`: `posfull` (todas as três codificações posicionais ativas, vetor nodal de 771 dimensões), `posmin` (apenas `is_root` e `pos`, com `grau_norm` zerado) e `posgrau` (apenas `is_root` e `grau_norm`, com `pos` zerado). As três variantes materializam-se em diretórios distintos em `data/fakenewsnet_<suffix>/` e são consumidas pela ablation intra-encoding (§4.4). Uma asserção de sanidade no construtor (`x.unique(dim=0).shape[0] >= min(num_nos, 3)`) garante que os vetores nodais de um mesmo grafo não sejam idênticos, prevenindo o cenário de degeneração do *message passing* descrito em §2.5.

3.4 Folds compartilhados

O *script* `gerar_folds.py` instancia `StratifiedKFold(n_splits=10, shuffle=True, random_state=42)` do *scikit-learn* sobre os 754 grafos do FakeNewsNet e persiste os índices em `data/folds_fnn.pt`. Esse arquivo é gerado *uma única vez* e consumido por todos os experimentos do trabalho que reportam comparações pareadas: o baseline textual (§4.1), o diagnóstico de *confound* (§4.2), o teste de significância entre arquiteturas GNN, entre outros.

A motivação é estatística. O teste *t* pareado (`scipy.stats.ttest_rel`) que usamos para comparar dois modelos exige que cada par de métricas comparado tenha sido obtido sobre os *mesmos exemplos*. Caso contrário, a variação entre folds se mistura à diferença entre modelos, reduzindo o poder do teste e tornando suas conclusões questionáveis. O

compartilhamento de *folds* elimina essa fonte de ruído e é pré-requisito do protocolo de avaliação formalizado em §3.7.

3.5 Arquiteturas GNN e hiperparâmetros

Três arquiteturas representativas das principais famílias de Redes Neurais de Grafos são avaliadas: a *Graph Convolutional Network* (GCN, [?]), com agregação espectral normalizada pelo grau; a *Graph Attention Network* (GAT, [?]), com pesos de aresta aprendidos via mecanismo de atenção; e o GraphSAGE ([?]), com agregação indutiva por média dos vizinhos. Todas as três são implementadas no *PyTorch Geometric* [?] e compartilham a mesma arquitetura agregada: três camadas convolucionais, com 64 canais ocultos por camada, seguidas de *global mean pool* sobre os nós, *dropout* de 0,5 e um classificador linear final. A Tabela 3.2 reúne os hiperparâmetros.

*Para o UPFD, o vetor de features de entrada de cada nó é o vetor pré-computado fornecido pelo dataset (variante **profile**, com 10 dimensões); para o FakeNewsNet, o vetor é o de 771 dimensões descrito em §3.3; para os experimentos de topologia pura da §4.4, ambos os datasets têm suas features substituídas por [is_root, grau_norm] (dimensão 2).*

Table 3.2: Hiperparâmetros usados nos modelos GNN. Defaults são iguais entre arquiteturas; diferenças anotadas na própria tabela.

Hiperparâmetro	GCN	GAT	SAGE
hidden_channels	64	64	64
num_layers	3	3	3
dropout	0.5	0.5	0.5
num_heads (atenção)	–	4	–
pooling	global_mean_pool	idem	idem
learning_rate	0.001	0.001	0.001
weight_decay	5×10^{-4}	5×10^{-4}	5×10^{-4}
batch_size	32	32	32
optimizer	Adam	Adam	Adam
scheduler	ReduceLROnPlateau (factor=0.5, patience=5)		
early_stopping	patience=7 sobre F1-macro de validação		
max_epochs	30	30	30
seed	42 (com varredura para 10 <i>seeds</i> em §4.4)		

A opção por hiperparâmetros idênticos entre as três arquiteturas não busca otimizar cada uma ao máximo (o que tornaria a comparação dependente de quanto cada modelo foi ajustado), mas sim *isolar o efeito arquitetural*: se uma família se destaca consistentemente

sob a mesma configuração básica, o sinal observado é atribuível à arquitetura, não ao *tuning*. Os defaults adotados são valores convencionais na literatura de GNNs e suficientes para conduzir o treinamento à convergência dentro do máximo de 30 épocas estabelecido.

3.6 *Baselines* não-GNN

Dois *baselines* deliberadamente simples acompanham as arquiteturas GNN ao longo do trabalho, cada um isolando uma direção do espaço de hipóteses.

O primeiro é um classificador puramente *textual*: a *Regressão Logística* aplicada sobre o *embedding* BERT da raiz da árvore de propagação (isto é, o vetor de 768 dimensões do título da notícia). Esse modelo não tem acesso a nenhuma informação estrutural: ignora o grafo inteiro e vê apenas o conteúdo textual. Estabelece, portanto, o *teto textual* do problema; qualquer GNN que não supere significativamente este *baseline* não está agregando valor sobre a informação do texto.

O segundo é um classificador puramente *estrutural tabular*: um *Random Forest* com 200 árvores, treinado sobre apenas duas *features* agregadas por grafo: o número total de nós (`num_nodes`) e o grau do nó raiz (`grau_root`). Esse modelo encarna o *confound trivial* da detecção de fake news em redes: a observação recorrente de que notícias falsas tendem a viralizar mais, gerando cascatas maiores. Se um *Random Forest* alimentado apenas com tamanho e grau atinge um F1 próximo do da GNN, o ganho aparente da GNN não vem de capturar estrutura sutil, mas apenas de reproduzir esse *confound*; se, por outro lado, o GNN supera significativamente o RF, há sinal estrutural genuíno sendo aprendido. Os dois *baselines* são confrontados, lado a lado, com as arquiteturas GNN em §4.1 e §4.2.

3.7 Protocolo de avaliação

A métrica primária adotada é o *F1-macro*, a média não ponderada dos F1 das duas classes (fake e real). Como os três *datasets* supervisionados utilizados são aproximadamente balanceados em torno de 50%/50% entre as classes (§3.2), o F1-macro é numericamente próximo da acurácia, mas com a vantagem de permanecer significativo caso futuros *datasets* apresentem desequilíbrio, situação comum em detecção de fake news em produção, onde a classe *fake* pode ser minoritária. A literatura UPFD [1] reporta acurácia; usamos F1-macro para alinhar com práticas mais recentes em classificação binária desbalanceada e marcamos expressamente a diferença quando confrontamos com valores publicados (Tabela 4.4).

Para comparar dois modelos sob o mesmo *dataset*, utilizamos o *teste t pareado* (`scipy.stats.ttest`) sobre os *folds* compartilhados de §3.4. O pareamento tem duas implicações práticas: a variação entre *folds* é cancelada (cada *fold* contribui com uma diferença entre modelos, não com uma métrica absoluta), e o teste recupera o sinal mesmo em diferenças pequenas

que o teste não-pareado não detectaria. No caso particular dos *subsets post-hoc* (como os recortes por profundidade da cascata em §4.9), nos quais o pareamento por fold é impossível por o *subset* ser definido sobre o conjunto de teste único, recorreremos ao *bootstrap* pareado descrito em §3.8.

Para a análise descritiva de separabilidade estrutural entre fake e real (§4.6), reportamos o *tamanho de efeito de Cohen* (d), conforme definição clássica de [?]. A escala interpretativa adotada é a usual: $|d| < 0,2$ desprezível, $0,2 \leq |d| < 0,5$ pequeno, $0,5 \leq |d| < 0,8$ médio, $|d| \geq 0,8$ grande. A tese central do trabalho está operacionalizada nesse limiar (ver §5.2).

Caveat de reprodutibilidade. Todos os experimentos foram executados em CPU (Intel Raptor Lake, 16 *cores* lógicos, 16 GB de RAM), sob Python 3.12.10 e PyTorch 2.10+cpu, com semente universal 42. Os resultados são reproduzíveis no mesmo ambiente, mas não bit-exato entre máquinas: operações `scatter` e `gather` do PyTorch Geometric não possuem *kernel* determinístico em GPU, e diferenças entre versões de CUDA/cuDNN ou entre CPUs distintas geram variação tipicamente na terceira casa decimal das métricas. Como contramedida, os achados centrais foram validados em 10 *seeds* independentes (§4.4) e em *bootstrap* pareado de 2.000 reamostragens (§4.9.4); as conclusões qualitativas se mantêm entre execuções.

3.8 Análise estratificada do erro

O F1-macro agregado mede *quanto* um modelo acerta, não *onde* ele acerta. Para responder a essa segunda questão, relevante para a caracterização de regimes em que cada modelo falha ou prospera, adotamos três técnicas complementares aplicadas sobre o *test set* do UPFD-GossipCop, em conjunto detalhadas em §4.9.

A primeira é uma *regressão localmente ponderada* (LOWESS) de $P(\text{acerto} \mid m)$ em função de cada métrica estrutural m . Implementamo-la via *rolling mean* de janela proporcional (10% da amostra ordenada, com mínimo absoluto de 30 observações), evitando a dependência de `statsmodels`. A vantagem sobre o *binning* discreto é dupla: visualiza-se continuamente a variação da acurácia ao longo de m , sem decidir arbitrariamente onde cortar os *bins*, o que evita o espaço para *cherry-picking*.

A segunda é a definição de *outliers* via *percentil empírico* (p5/p95) sobre o próprio *test set*, em vez de limiares baseados em *z-score*. A escolha é justificada pela forma das distribuições: métricas de cascata em redes sociais são *heavy-tail*: a média não é robusta, o desvio-padrão é inflado por poucos casos extremos, e critérios baseados em σ tornam-se mal-definidos. O percentil empírico é invariante à forma da distribuição e identifica reciprocamente o 5% inferior e o 5% superior independentemente da assimetria.

A terceira é o *bootstrap pareado* (com $n_{\text{boot}} = 2.000$) para intervalos de confiança sobre a diferença de F1 entre dois modelos avaliados no mesmo *subset*, técnica empregada em

§4.9.4 para confirmar a significancia do ganho do SAGE estrutural sobre o RF tabular em recortes de profundidade da cascata. O *bootstrap* é o substituto natural do `ttest_rel` pareado por *fold* quando o pareamento por *fold* não se aplica, como ocorre em *subsets* definidos *post-hoc* sobre o teste único do UPFD.

3.9 Análise de explicabilidade

Para inspecionar o que a arquitetura SAGE estrutural efetivamente aprende do grafo de propagação, recorreremos ao *GNNExplainer* [?], implementado em `torch_geometric.explain.Explainer` com algoritmo `GNNExplainer(epochs=200)` e `edge_mask_type="object"`, em modo de classificação multi-classe sobre o grafo inteiro. O *GNNExplainer* aprende uma máscara sobre as arestas do grafo que maximiza a informação mútua entre a sub-rede mascarada e a predição do modelo, identificando assim quais arestas são mais decisivas para a classificação de cada grafo.

A análise é aplicada sobre 20 amostras do *test set* do UPFD-GossipCop estratificadas em quatro grupos de cinco grafos cada (*fake-pequena*, *fake-grande*, *real-pequena*, *real-grande*), permitindo identificar padrões diferenciais por classe e por tamanho. Para cada amostra, calcula-se a fração de massa de importância concentrada em arestas a 1-hop (raiz $\rightarrow$ filhos diretos), 2-hops e ≥ 3 -hops da raiz. Os resultados, apresentados em §4.8, revelam uma assimetria sistemática entre *fake* e *real* no padrão espacial de importância, achado que sustenta interpretações sobre o mecanismo de classificação aprendido pelo modelo.

3.10 Classificador dual: regra de combinação *post-hoc*

Para a aplicação prática documentada no Apêndice D, combinamos o classificador textual (LogReg-BERT) e o classificador topológico (RF estrutural) por meio de uma regra de combinação heurística. É importante registrar, já aqui, que essa regra **não é uma decisão metodológica a priori**: trata-se de uma heurística derivada *post-hoc*, ou seja, após a observação empírica dos resultados de §4.7. Sua formulação exata, sua justificativa quantitativa e a discussão das alternativas descartadas são apresentadas naquela seção, sob a equação (4.1). A menção antecipada neste capítulo serve apenas para precedência expositiva, dado que a ferramenta web descrita no Apêndice D consome o classificador combinado.

3.11 Reprodutibilidade

A reprodutibilidade dos resultados é tratada em três níveis. Primeiro, o ambiente de execução é fixado: Python 3.12.10, PyTorch 2.10+cpu, PyTorch Geometric 2.7.0, *scikit-learn*

e demais dependências versionadas em `requirements.txt` (*pinned*). Os experimentos foram conduzidos em **ambiente CPU** (Intel *Raptor Lake*, 16 *cores* lógicos, 16 GB de RAM, Windows 11); não se utilizou GPU em nenhum momento do treinamento ou da avaliação.

Segundo, todas as fontes de aleatoriedade são semeadas com o valor 42: `torch.manual_seed`, `numpy.random.seed`, `random.seed`, `StratifiedKFold(random_state=42)` e os construtores dos classificadores do *scikit-learn* (`n_jobs=-1` é adotado para o RF, sem efeito sobre determinismo). Para os experimentos sensíveis à inicialização, conduzimos varredura explícita sobre 10 *seeds* independentes em §4.4 e reportamos média e desvio-padrão.

Terceiro, reconhecemos as limitações ao determinismo: operadores `scatter` e `gather` do PyTorch Geometric não possuem *kernel* determinístico em GPU [?]¹, e diferenças de arquitetura de CPU ou de versão de bibliotecas geram variação tipicamente na terceira casa decimal das métricas reportadas. As conclusões qualitativas do trabalho são robustas a essa variação. O repositório oficial do código, com o `README.md` como fonte autoritativa de instruções, está publicado junto aos pesos persistidos em [4].

¹Referência da nota: a documentação oficial do PyTorch sobre reprodutibilidade (<https://pytorch.org/docs/stable/notes/randomness.html>).

Chapter 4

Resultados Experimentais

Cada seção deste capítulo responde uma das perguntas de pesquisa formuladas em §1.3. Resultados negativos (em particular o desempenho dos modelos topológicos no UPFD-PolitiFact em §4.4) são reportados com a mesma extensão dos positivos: a refutação de uma hipótese tem peso evidencial equivalente à sua confirmação, e é justamente a sobreposição dos dois lados que permite caracterizar o regime de aplicabilidade do paradigma topológico. A Tabela 4.1 consolida em uma só vista as métricas-chave por (*dataset* $\times$ modelo), com código de cores que sinaliza desempenho forte, intermediário e colapso.

Table 4.1: Síntese de resultados: F1-macro por (*dataset* $\times$ modelo). Células verdes indicam desempenho forte ($\geq 0,80$); amarelas, médio (0,60–0,79); vermelhas, colapso ($< 0,60$). Negrito marca o melhor modelo de cada *dataset*. O contraste entre UPFD-GossipCop (todas as linhas verdes) e UPFD-PolitiFact com features estruturais puras (linha inteira em vermelho) e’ o achado central do trabalho.

Modelo / <i>features</i>	FNN	UPFD-Polit	UPFD-Goss	Fonte
<i>Baselines textuais</i>				
LogReg-BERT (título)	0,859	0,842	0,954	T1, T3
RandomForest-BERT	0,855	–	–	T1
<i>GNNs com texto (feature content/profile)</i>				
GCN	–	0,782	0,941	T3
GAT	–	0,694	0,939	T3
SAGE	–	0,817	0,945	T3
<i>Modelos topológicos puros (sem texto)</i>				
RF tabular [num_nodes, grau_root]	–	–	0,753	T6
GCN [is_root, grau_norm]	0,528	0,362	0,645	T4
GAT [is_root, grau_norm]	0,537	0,380	0,483	T4
SAGE [is_root, grau_norm]	0,536	0,331	0,810	T4
<i>Referência (Dou et al., SIGIR 2021)</i>				
GCN/GAT/SAGE publicado	–	0,846 [†]	0,971 [†]	T10

[†] Acurácia reportada por Dou et al. com *feature bert* (768d); nosso F1-macro com *content* (310d). Não bit-exact, indicativo apenas.

“Melhor da coluna” aplicado dentro de cada bloco; o negrito da linha SAGE em UPFD-PolitiFact destaca o caso de colapso (não um *me*).

4.1 *Baselines* textuais sobre BERT da raiz

Table 4.2: Baseline textual no FakeNewsNet (k-fold estratificado, k=10).

Modelo	Folds	F1-macro	Accuracy
LogReg	10	0.8593 $\pm$ 0.0431	0.8595 $\pm$ 0.0430
RandomForest	10	0.8549 $\pm$ 0.0372	0.8555 $\pm$ 0.0369

A Tabela 4.2 reporta o desempenho de dois classificadores clássicos (*Regressão Logística* e *Random Forest*) treinados *exclusivamente* sobre o vetor BERT do título de cada notícia

no FakeNewsNet, em validação cruzada estratificada de 10 *folds*. O LogReg-BERT atinge F1-macro de $0,859 \pm 0,043$; o Random Forest sobre o mesmo *embedding* atinge $0,855 \pm 0,037$, valor próximo. Em ambos os casos, a acurácia é essencialmente igual ao F1-macro (consistente com o balanço 50/50 do FNN, §3.2).

A leitura desse resultado define o *teto textual* do problema neste *dataset*: o texto da raiz da árvore de propagação, isoladamente, já carrega quase todo o sinal classificatório recuperável. Modelos baseados em grafos só se justificam, no FakeNewsNet, se o ganho que trazem sobre esse teto for estatisticamente distinguível, o que se mostrará, em §4.4, *não ocorrer*: as arquiteturas GNN com *features* estruturais puras sequer alcançam 0,55, e mesmo as variantes com texto têm ganho marginal sobre o LogReg-BERT. Em §4.6 discutiremos por que esse teto textual tão alto e a ausência de ganho topológico no FNN são coerentes com a tese central do trabalho.

4.2 Diagnóstico de *confound* topológico

Notícias falsas tendem, na literatura de detecção em redes sociais, a viralizar mais que notícias verdadeiras e gerar cascatas maiores. Essa correlação cria um *confound* trivial: o desempenho que se atribui a uma GNN pode, em última instância, não estar capturando estrutura sutil alguma — pode estar apenas reproduzindo o atalho “*fake* = grafo maior”. Para testá-lo diretamente, treinamos um *Random Forest* (§3.6) no FakeNewsNet alimentado *apenas* com a *feature* `num_nodes`. O F1-macro resultante é de $\approx 0,523$, valor próximo do nível de chance (0,50 em problema balanceado) e bem abaixo do limiar de 0,65 que adotariamos *a priori* como sinal de *confound* dominante. Sendo assim, o tamanho do grafo *contribui*, mas não *explica* o sinal capturado pelos modelos posteriores: há ruído demais na correlação entre tamanho e veracidade para que um classificador trivial dela extraia valor preditivo. O ganho que se observa nas GNNs vem, portanto, de outras fontes — textuais, no caso do FNN; estruturais multi-hop, no caso do UPFD-GossipCop (cuja decomposição por profundidade da cascata é quantificada em §4.9).

4.3 Cross-dataset UPFD: nossos resultados *versus* literatura

Table 4.3: Benchmark cross-dataset UPFD (PolitiFact + GossipCop) – GCN/GAT/SAGE vs baseline textual.

Dataset	Modelo	Seeds/Folds	F1-macro
gossipcop	GAT	3	0.9390 ± 0.0050
gossipcop	GCN	3	0.9411 ± 0.0059
gossipcop	LogReg_root	1	0.9540 ± 0.0000
gossipcop	SAGE	3	0.9448 ± 0.0041
politifact	GAT	5	0.6936 ± 0.1865
politifact	GCN	5	0.7816 ± 0.0548
politifact	LogReg_root	1	0.8415 ± 0.0000
politifact	SAGE	5	0.8166 ± 0.0095

Table 4.4: Comparacao com baselines do UPFD original (Dou et al., SIGIR 2021, Tabela 4). Nota: nossos resultados sao F1-macro sobre k-fold com feature 'content' (310d); valores publicados sao accuracy com feature 'bert' (768d). Comparacao indicativa, nao bit-exact.

Dataset	Modelo	F1-macro (nosso)	Acc (Dou et al.)
politifact	GCN	0.782 ± 0.055	0.846
politifact	GAT	0.694 ± 0.186	0.846
politifact	SAGE	0.817 ± 0.010	0.846
gossipcop	GCN	0.941 ± 0.006	0.972
gossipcop	GAT	0.939 ± 0.005	0.971
gossipcop	SAGE	0.945 ± 0.004	0.971

A Tabela 4.3 reporta os resultados de GCN, GAT e SAGE nas duas variantes do UPFD: PolitiFact (314 grafos) e GossipCop (5.464 grafos), com média sobre 3 a 5 *seeds* independentes. O contraste entre os dois domínios já está presente aqui: no UPFD-GossipCop as três arquiteturas convergem para F1-macro em torno de 0,94, próximas do *baseline* textual (0,954); no UPFD-PolitiFact, os modelos espalham-se entre 0,69 (GAT) e 0,82 (SAGE), com o próprio LogReg-BERT atingindo 0,84 — isto é, no PolitiFact a variação entre arquiteturas é muito maior, e nenhuma supera o *baseline* textual em margem significativa. A Tabela 4.4 confronta estes mesmos valores com os de Dou et al. [1]: PolitiFact em torno de 0,78–0,82 no nosso (vs. 0,846 publicado), GossipCop em torno de 0,94–0,95 (vs. 0,971 publicado).

Esta comparação é *aproximada, não replicação exata*: as razões precisam ser declaradas explicitamente. Três diferenças deliberadas afastam nossa configuração da deles: (i) utilizamos a *feature content* (310 dimensões, combinação de *spaCy* e *profile*) ao invés da *feature bert* (768 dimensões), por restrição de memória RAM na densificação da matriz esparsa do GossipCop em ambiente Windows/CPU; (ii) adotamos hiperparâmetros próprios ($lr = 0,001$, $hidden = 64$, três camadas), uma vez que a configuração exata de [1] não é totalmente especificada no artigo; (iii) reportamos F1-macro enquanto Dou et al. reportam acurácia. O propósito da comparação não é *ranking* competitivo com a literatura, mas *calibração*: verificar que nosso *pipeline*, com diferenças conhecidas e declaradas, está *no envelope* dos valores publicados — condição necessária para que os achados subsequentes deste capítulo sejam tomados como informativos sobre o problema, e não como artefatos de implementação defeituosa.

4.4 Topologia sem texto: o achado central (RQ3, parte a)

Table 4.5: Topologia SEM texto: features [is_root, grau_norm] – sinal estrutural puro por dataset/arch.

Dataset	Modelo	Seeds/Folds	F1-macro
fnn	GAT	10	0.5372 ± 0.0709
fnn	GCN	10	0.5275 ± 0.0678
fnn	SAGE	10	0.5362 ± 0.0747
upfd_gossipcop	GAT	10	0.4834 ± 0.1075
upfd_gossipcop	GCN	10	0.6445 ± 0.0190
upfd_gossipcop	SAGE	10	0.8097 ± 0.0023
upfd_politifact	GAT	10	0.3800 ± 0.0802
upfd_politifact	GCN	10	0.3621 ± 0.0554
upfd_politifact	SAGE	10	0.3314 ± 0.0093




Figure 4.1: F1-macro por (arquitetura $\times$ *feature variant* $\times$ *dataset*). Verde = modelo aprende; vermelho = colapsa. SAGE em UPFD-GossipCop com apenas duas *features* estruturais atinge $F1 \approx 0.81$.

A Tabela 4.5 e a Figura 4.1 resumem o *achado central* do trabalho. A combinação **SAGE** + **UPFD-GossipCop** + *features* estruturais puras [is_root, grau_norm] (vetor nodal de apenas duas dimensões, nenhuma das quais contém texto) atinge F1-macro de $0,810 \pm 0,002$, média sobre dez *seeds* independentes. O mesmo modelo, treinado nos outros dois *datasets*, colapsa: $F1 \approx 0,33$ em UPFD-PolitiFact (abaixo do nível de chance) e $F1 \approx 0,54$ em FakeNewsNet. As outras duas arquiteturas testadas no UPFD-GossipCop ficam atrás do SAGE (GCN 0,64, GAT 0,48), reforçando que a agregação indutiva por média do GraphSAGE é particularmente adequada à estrutura em estrela do dataset. *Sem nenhum acesso ao texto da notícia, apenas com duas dimensões estruturais por nó, o SAGE no UPFD-GossipCop alcança 81% de F1-macro, a 13 pontos percentuais do baseline textual (0,954) e a 14 pontos do SAGE com texto (0,945)*. Este é o resultado central que responde afirmativamente à parte (a) da RQ3: é viável detectar fake news apenas pela topologia da propagação, *desde que* o domínio ofereça sinal estrutural mensurável (condição examinada em §4.6).

A baixa variância em torno desse F1 de 0,81 ($\sigma = 0,002$ sobre dez *seeds*) merece justificativa, pois é atipicamente pequena para um experimento de aprendizado profundo. Auditoria do *script* de execução confirma que (i) `torch.manual_seed` e `np.random.seed` são chamados antes de cada execução independente; (ii) o `DataLoader` com `shuffle=True` consome do gerador semeado; (iii) o construtor da `SAGEClassifier` recebe `seed=seed` explicitamente. A baixa variância é, portanto, comportamento genuíno do experimento, e é consequência da combinação de três fatores: (a) o vetor de entrada tem apenas duas dimensões, oferecendo pouco espaço para que diferenças de inicialização se tornem diferenças de convergência; (b) o sinal estrutural no UPFD-GossipCop é muito forte (Cohen’s $d = +1,53$ no *branching factor*, §4.6), conduzindo o otimizador ao mesmo óptimo independentemente da semente; (c) o *split* treino/validação/teste do UPFD é fixo, isolando

completamente a fonte de variação do *dataset*. Como controle negativo, a mesma arquitetura SAGE aplicada ao UPFD-PolitiFact (onde Cohen’s d é desprezível em todas as métricas) produz $\sigma \approx 0,05$, ordem de grandeza maior; isto é, o σ baixo é função do *dataset*, não de *bug* de semente.

4.5 Consistência de *score* topológico entre idiomas (RQ3, parte b)

É necessário delimitar com precisão o que este experimento mede *antes* de discutir seus resultados. O *snapshot* acadêmico do Bluesky utilizado aqui *não possui rótulos fake/real*, e portanto este experimento **não mede detecção** em português, alemão ou qualquer outro idioma. Mede, em vez disso, a *consistência da distribuição do score* que o classificador estrutural, treinado em UPFD-GossipCop e arquiteturalmente cego ao texto, produz quando aplicado a posts em diferentes idiomas. Essa consistência é condição *necessária mas não suficiente* para detecção multilíngue: distribuições discrepantes indicariam que o mecanismo estrutural responde sistematicamente ao idioma do post (por confounders de comunidade, volume ou regime de engajamento), refutando a independência linguística do mecanismo; distribuições equivalentes *não garantem* acurácia preditiva em produção, apenas que o classificador não introduz viés sistemático por idioma.

Table 4.6: Comparacao da distribuicao de score topologico no Bluesky entre idiomas (RQ3 parte b). PT vs EN: efeito desprezivel ($|d| < 0.2$); DE vs EN: efeito medio ($|d| = 0.47$). Interpretacao com 3 hipoteses alternativas em §4.4-bis (shift dominio, vies amostral, desbalanco).

Par	n_a	n_b	$\bar{s}_a$	$\bar{s}_b$	Cohen’s d	KS p
por vs eng	2661	132312	0.381	0.398	-0.057	2.69e-42
deu vs eng	9686	132312	0.259	0.398	-0.468	0.00e+00
por vs deu	2661	9686	0.381	0.259	+0.739	5.48e-321




Figure 4.2: Distribuição do *score* topológico do RF-estrutural (treinado em UPFD-GossipCop) aplicado a posts do Bluesky por idioma. EN ($n=132.312$), DE ($n=9.686$) e PT ($n=2.661$) médias indicadas na legenda. PT e EN são praticamente indistinguíveis ($d=-0.057$); DE difere por efeito médio ($d=-0.468$).

A Tabela 4.6 e a Figura 4.2 resumem o experimento. Quanto ao par português *versus* inglês, Cohen’s $d = -0,057$ é *desprezível* pela escala de [?]. Os testes de Kolmogorov-Smirnov e Mann-Whitney rejeitam a hipótese nula de mesma distribuição com $p < 10^{-5}$, mas é preciso enfatizar que isso ocorre porque $n_{EN} = 132.312$ torna estatisticamente detectável praticamente qualquer diferença real, por menor que seja sua importância prática. O tamanho de efeito, métrica que não se infla com n , é o critério adequado neste regime; e o efeito está bem abaixo do limiar de efeito *pequeno* ($|d| < 0,2$ pela escala de Cohen). Concluimos, portanto, que a diferença entre PT e EN é *estatisticamente detectável mas praticamente irrelevante*. O par alemão *versus* inglês, em contraste, exibe $d = -0,468$ (efeito médio): posts em alemão apresentam *score* topológico sistematicamente mais baixo (média 0,26, contra 0,40 do inglês). O par PT *versus* DE apresenta $d = +0,739$ (mediano-grande), consistente com os pares anteriores: PT está mais próximo de EN do que de DE.

A interpretação da divergência DE *versus* EN exige cautela. É plausível atribuí-la a padrões de engajamento da comunidade germânica no Bluesky (adoção tardia, uso mais discreto da plataforma, comunidade autoselecionada). Mas *hipóteses alternativas são igualmente válidas e não podem ser descartadas sem experimentos adicionais*: (1) *shift* de domínio: o classificador foi treinado em notícias de celebridade/entretenimento (UPFD-GossipCop), enquanto posts DE no Bluesky podem ter perfil temático mais político ou

profissional; (2) viés amostral: os usuários alemães no Bluesky podem constituir subgrupo demográfico específico (*early adopters*, comunidade tech) e não a comunidade germânica como um todo; (3) desbalanço de cobertura: $n_{PT} = 2.661$, $n_{DE} = 9.686$, $n_{EN} = 132.312$ são suficientes para a estimativa pontual do Cohen’s d , mas a cobertura de regimes raros de engajamento é necessariamente desigual.

A resposta refinada à parte (b) da RQ3 é portanto a seguinte: o classificador estrutural *não processa texto algum*, e portanto seu mecanismo é *arquiteturalmente independente do idioma do post*. A consistência empírica dessa independência foi confirmada para o par PT *versus* EN; foi parcialmente refutada para DE *versus* EN, com a causa exata não isolada entre fatores de idioma, de comunidade, de *shift* de domínio e de amostragem.

4.6 Por que GossipCop funciona e PolitiFact não? (RQ2)

Table 4.7: Análise estrutural fake vs real – separabilidade por métrica topológica. Cohen’s d : $|d| \geq 0.5$ médio, ≥ 0.8 grande.

Dataset	Métrica	media _{fake}	media _{real}	Cohen’s d	p -valor
fnn	num_nodes	69.67	60.91	+0.223	0.002331
fnn	branching_avg	68.67	59.91	+0.223	0.002331
upfd_politifact	num_nodes	114.92	146.57	-0.245	0.03147
upfd_politifact	branching_avg	7.33	7.01	+0.059	0.6057
upfd_gossipcop	num_nodes	76.16	38.87	+0.905	0
upfd_gossipcop	branching_avg	23.61	7.50	+1.534	0




Figure 4.3: *Forest plot* de Cohen's d entre fake e real para cada métrica estrutural, em cada *dataset*. Linhas pontilhadas indicam limiares de Cohen (0.2 / 0.5 / 0.8). UPFD-GossipCop apresenta efeito *grande* ($d=+1.53$) em *branching factor*; UPFD-PolitiFact e FakeNewsNet ficam abaixo do limiar de efeito *pequeno* ($|d| < 0.2$).

A Tabela 4.7 e a Figura 4.3 reportam o tamanho de efeito de Cohen entre as classes *fake* e *real*, calculado sobre cinco métricas estruturais por grafo (`num_nodes`, `num_edges`, `depth_max`, `width_max`, `branching_avg`), nos três *datasets*. A diferença entre domínios é drástica: o UPFD-GossipCop apresenta $d = +1,53$ em *branching factor* (efeito *grande* pela escala de Cohen) e $d = +0,91$ em `num_nodes`; ambas as métricas mostram cascatas sistematicamente maiores e mais ramificadas nas notícias falsas. O UPFD-PolitiFact, em contraste, não alcança nem mesmo um efeito médio em nenhuma das métricas avaliadas: o máximo é $|d| = 0,25$ em `num_nodes`, abaixo do limiar de 0,5. O FakeNewsNet apresenta $|d| \approx 0,22$ em `num_nodes` e `branching_avg`, valores matematicamente idênticos porque, em grafo-estrela, o *branching* médio coincide com `num_nodes`–1, dado que apenas o nó raiz é não-folha.

Este resultado tem fundamentação teórica na literatura de *homofilia* e *assortatividade* em redes. Newman [?] estabelece que redes nas quais nós da mesma classe se conectam preferencialmente exibem assortatividade alta; Pei et al. [?] demonstram que GNNs convolucionais dependem justamente de assortatividade por classe para serem efetivas. Em UPFD-GossipCop, *fake* e *real* são *estruturalmente assortativos* no sentido de Pei: cada classe forma cascatas com perfis de *branching* distintos e o operador de agregação do GNN tira proveito dessa separação. Em UPFD-PolitiFact, a ausência de assortatividade impede o operador de construir representações nodais que distingam as classes; qualquer arquitetura, não apenas SAGE, colapsa sob essa condição.

A tese central deste trabalho está operacionalizada nesse fenômeno: *modelos topológicos exigem diferença estrutural entre classes da ordem de magnitude de um efeito médio de Cohen ($|d| \geq 0,5$) em pelo menos uma métrica de cascata para serem efetivos*. A tese é deliberadamente **falsificável**: a apresentação de um *dataset* com $0,2 < |d| < 0,5$ no qual uma arquitetura GNN atinja desempenho significativamente acima do baseline textual e do RF tabular constituiria contra-evidência direta.

4.7 Concordância textual $\times$ topológico (RQ1)

Table 4.8: Comparacao TEXTUAL vs TOPOLOGICO no UPFD-GossipCop – concordancia, kappa, e desempenho condicional.

Metрика	Valor
F1-macro textual (LogReg-content)	0.9540
F1-macro topologico (RF estrutural)	0.7534
Agreement rate	0.7588
Cohen’s kappa	0.5179
F1 quando AMBOS concordam	0.9662
F1 textual quando DISCORDAM	0.9139
F1 topologico quando DISCORDAM	0.0845




Figure 4.4: *Scatter score* textual (LogReg-BERT) $\times$ topológico (SAGE estrutural) no UPFD-GossipCop *test*. Quadrantes indicam concordância em FAKE (canto inferior-esquerdo) e em REAL (canto superior-direito); discordância ocupa os outros dois quadrantes.

A Tabela 4.8 e a Figura 4.4 reportam o experimento de concordância entre o classificador textual (LogReg-BERT-*content*) e o classificador topológico (RF estrutural sobre `[num_nodes, grau_root]`) aplicados sobre os 3.826 grafos do *test set* do UPFD-GossipCop. Tomados isoladamente, o textual atinge F1-macro de 0,954 e o topológico, 0,753, conforme reportado na Tabela 4.3. A pergunta interessante aqui não é qual dos dois é melhor, mas *onde os dois discordam e quem acerta nas discordâncias*. A taxa de concordância agregada é de 75,9% (Cohen’s $\kappa = 0,518$, concordância moderada). Quando ambos concordam, o F1 conjunto é de 0,966, próximo do máximo teórico. Quando discordam, o textual mantém F1 de 0,914, mas o topológico cai a **0,085**.

Esse valor de 0,085 merece interpretação cuidadosa. Ele está *substancialmente abaixo* de duas referências: do nível de chance ($\approx 0,50$ em problema balanceado) e da predição puramente majoritária ($\approx 0,33$). No subconjunto de discordância, portanto, o classi-

ficador topológico não apenas *erra*: ele está *sistematicamente invertido*. A explicação desse fenômeno é uma *inversão distributiva*: a relação entre estrutura e classe está aproximadamente espelhada nesse subconjunto, em relação ao que prevalece no treinamento. O RF aprendeu a regra geral “*fake* = grau de raiz alto” no UPFD-GossipCop (Cohen’s $d = +1,53$ em *branching*, §4.6, confirma essa regra no agregado), mas as previsões em que discorda do textual são justamente: (i) notícias *reais* que viralizaram fortemente, com grau de raiz alto, levando o RF a prever *fake* e errar; e (ii) notícias *fake* de propagação contida, com grau de raiz baixo, levando o RF a prever *real* e errar. A §4.9.3 caracteriza esses dois subgrupos numericamente, confirmando que o SAGE acerta zero de 31 *fakes* contidos e apenas 43% dos 60 *reais* virais.

Esse comportamento de inversão *justifica* a regra dual apresentada a seguir, não a contradiz: o topológico só é confiável quando concorda com o textual; quando discorda, está sinalizando precisamente o subconjunto em que sua regra estrutural falha por construção. A regra adotada na ferramenta web — Equação (4.1) e Figura 4.5 — encarna essa lógica: pesos iguais quando os dois concordam, peso 4 vezes maior para o textual quando discordam.

$$\text{score}_{\text{final}} = \begin{cases} 0.5 \cdot s_T + 0.5 \cdot s_K & \text{se } \text{pred}_T = \text{pred}_K \\ 0.8 \cdot s_T + 0.2 \cdot s_K & \text{se } \text{pred}_T \neq \text{pred}_K \end{cases} \quad (4.1)$$




Figure 4.5: Fluxograma da regra dual de combinação textual × topológico, derivada *post-hoc* dos resultados de §4.7.

4.8 GNNExplainer: o que o SAGE aprendeu




Figure 4.6: Fração de massa de importância em arestas a 1-hop, 2-hop e 3+ hops da raiz, agregado por estrato (classe $\times$ tamanho). Assimetria FAKE *vs* REAL: para FAKE, o SAGE concentra quase toda a decisão em arestas 1-hop (raiz $\rightarrow$ filhos diretos); para REAL-grande, distribui entre *hops* mais distantes.

A Figura 4.6 agrega a fração de massa de importância atribuída pelo GNNExplainer às arestas, segmentada por *hop distance* desde a raiz, para 20 amostras estratificadas do *test set* do UPFD-GossipCop (cinco por estrato: *fake-pequena*, *fake-grande*, *real-pequena*, *real-grande*). O achado central é uma *assimetria sistemática por classe* no padrão de importância espacial. Para os grafos da classe *fake* (pequenos e grandes, $N = 10$), a fração de massa em arestas a 1-hop, da raiz a seus filhos diretos, está praticamente saturada, entre 0,97 e 1,00. Para a classe *real-grande* ($N = 5$), a fração a 1-hop cai para 0,50 a 0,62, com massa significativa redistribuída para arestas mais distantes da raiz. Os cinco grafos *real-pequena* não exibem padrão consistente e são reportados aqui como observação preliminar, dado o N insuficiente para conclusão firme.

A interpretação desta assimetria é que o SAGE estrutural aprendeu uma heurística diferenciada para cada classe: para *detectar fake*, ele se convém em olhar quase exclusivamente o entorno imediato da raiz (consistente com o sinal de *branching factor* alto que caracteriza fake news na agregação da §4.6); para *confirmar real*, sobretudo em cascatas grandes, ele precisa *buscar* informação mais profundamente na árvore. Quantitativamente, esse esforço adicional rende ganho: o RF tabular alimentado apenas com `[num_nodes, grau_root]` atinge F1-macro de 0,753 no mesmo *test set*, ao passo que o SAGE atinge 0,814, diferença de +6,1 pontos percentuais absolutos atribuível ao acesso à topologia multi-hop. A §4.9.4 estratifica esse ganho por profundidade de cascata e mostra que ele se concentra fortemente nos grafos mais profundos, consistente com a leitura dada aqui pelo *GNNExplainer*.

Esta assimetria tem implicação prática para a ferramenta web documentada no Apêndice D:

a concentração de massa em *1-hop* pode ser exposta na interface como *proxy de confiança* do modelo: predições *fake* com $h_1 \approx 1$ correspondem a casos em que o modelo decidiu sob sinal forte; predições *real* com $h_1 < 0,7$ correspondem a casos em que o modelo precisou de mais informação para concluir, sinalizando incerteza relativa.

4.9 Análise estratificada do erro

As seções anteriores reportam o F1 *agregado* do SAGE estrutural em UPFD-GossipCop ($F1 = 0,810$). Este número único esconde três comportamentos distintos do modelo, que a presente seção isola com três lentes complementares aplicadas sobre os 3.826 grafos do *test* sem nenhum re-treino do classificador (*leakage* controlado por construção): uma lente *contínua* (regressão local LOWESS da probabilidade de acerto em função das métricas estruturais), uma lente *categórica* (seis subgrupos extremos definidos *post-hoc* via percentil empírico) e uma lente *ordinal* (estratificação por profundidade da cascata, com intervalos de confiança *bootstrap*). Os achados desta seção transformam o resultado agregado em diagnóstico operacional sobre *onde* cada modelo funciona e *onde* colapsa: distribuição mais pesada que lognormal, inversão distributiva confirmada em subgrupos nomeados, e *gap* SAGE–RF crescendo monotonicamente com a profundidade da cascata.

4.9.1 Distribuição estrutural: *heavy-tail* mais agressivo que log-normal




Figure 4.7: Histograma das três métricas estruturais (eixo x em escala logarítmica para `num_nodes`) com ajuste de distribuição lognormal sobreposto. Teste KS rejeita o *fit* em todas ($p < 10^{-11}$), indicando cauda mais pesada que lognormal.

A Figura 4.7 ajusta uma distribuição lognormal a cada uma das três métricas estruturais sobre o *test* de UPFD-GossipCop e submete o ajuste a teste de Kolmogorov-Smirnov. O *fit* é rejeitado nas três métricas ($p < 10^{-11}$ em todas), o que indica que a cauda das distribuições estruturais é *mais agressiva* do que aquilo que uma lognormal descreve, regime consistente com a literatura clássica de redes sociais, em que distribuições de

grau e de cascata seguem tipicamente leis de potência ou variantes *power-law-like* [?]. A consequência metodológica é direta: *z-score* como critério de outlier seria mal-definido neste regime, porque a média e o desvio-padrão amostrais são dominados por poucos pontos da cauda e não caracterizam o “centro” da distribuição. Adotamos, portanto, **percentil empírico** (p5/p95 sobre o próprio *test*) como definição de extremo em todas as análises desta seção, e *plots* envolvendo `num_nodes` usam eixo logarítmico em x por consistência com a forma da distribuição subjacente.

4.9.2 LOWESS: onde o modelo degrada




Figure 4.8: Probabilidade de acerto suavizada (*rolling-mean* de janela proporcional, 10% da amostra) do RF tabular e do SAGE estrutural em função de cada métrica estrutural no UPFD-GossipCop *test*. Linha pontilhada cinza marca o *chance level*. SAGE supera RF de forma crescente em `num_nodes` e `depth_max`; o gap em `branching_avg` é maior na região mediana.




Figure 4.9: F1-macro de RF e SAGE por tercil estrutural – versão discreta da Figura 4.8. Em `num_nodes`, SAGE cresce monotonicamente (T1 $\rightarrow$ T3); RF decresce. Em `depth_max`, distribuição discreta colapsa o tercil intermédio.

As Figuras 4.8 e 4.9 reportam, respectivamente, a probabilidade de acerto suavizada (*rolling-mean* de janela proporcional a 10% da amostra, mínimo de 30 observações por janela [?]) e a versão discreta por tercil estrutural, ambas em função de cada uma das

três métricas. A leitura combinada das duas representações é que *não existe um modelo globalmente superior*: o RF tabular e o SAGE estrutural atravessam suas curvas em pontos distintos do espaço de métricas. Em `num_nodes`, o SAGE *sobe* ao longo dos tercís enquanto o RF *desce*, cruzamento que indica que a vantagem da rede neural concentra-se em grafos suficientemente grandes para que haja estrutura de propagação a ser explorada por agregação *multi-hop*; em grafos pequenos, a topologia degenera para padrão próximo da estrela rasa e o operador de agregação perde poder discriminativo (compatível com a interpretação mecanicista da §4.6, em que o sinal estrutural de UPFD-GossipCop está no *branching factor*). Em `branching_avg`, o padrão é em U: ambos os modelos erram mais nos extremos. A curva por `depth_max` antecipa o achado mais quantificado da §4.9.4: o *gap* SAGE–RF cresce com a profundidade. Esta subseção prepara, portanto, a leitura das duas subseções seguintes, que isolam numericamente os dois fenômenos: a inversão do modelo em subgrupos extremos (§4.9.3) e o crescimento do *gap* com a profundidade (§4.9.4).

4.9.3 Outliers e a inversão distributiva

Table 4.9: Acuracia do RF estrutural e do SAGE em seis subgrupos extremos do UPFD-GossipCop *test*. Subgrupos derivados *post-hoc* via percentil empírico (não *z*-score, justificado pela rejeição do *fit* lognormal em §4.9.1). Δ = diferença vs. acurácia agregada (RF=0.754, SAGE=0.814). *Subgrupos com classe única não admitem F1-macro.

Subgrupo	N	acc RF (Δ)	acc SAGE (Δ)	F1m RF	F1m SAGE
real_viral	60	0.233 (−0.520)	0.433 (−0.381)	—*	—*
fake_contido	31	0.000 (−0.754)	0.000 (−0.814)	—*	—*
cauda_alta_n	192	0.547 (−0.207)	0.823 (+0.009)	0.506	0.816
cauda_baixa_n	265	0.913 (+0.160)	0.913 (+0.099)	0.477	0.477
deep_extreme	256	0.531 (−0.222)	0.762 (−0.052)	0.528	0.741
wide_extreme	192	0.932 (+0.179)	0.974 (+0.160)	0.600	0.493




Figure 4.10: Acurácia do RF e do SAGE em seis subgrupos extremos definidos *post-hoc* via percentil empírico (p5/p95 sobre o *test*). Linhas pontilhadas indicam baselines agregados. O subgrupo `fake_contido` (notas falsas com baixo engajamento) e o `real_viral` (notícias verdadeiras que viralizaram) caem abaixo da chance – confirmam a inversão distributiva descrita em §4.7.




Figure 4.11: Composição real (% *fake* verdadeira) *vs.* proporção predita pelo modelo, por subgrupo. Linhas com cor diferente em uma mesma coluna indicam que o modelo não reproduz a distribuição de classes do subgrupo – característico de `real_viral` (linha “% predito fake” alta enquanto “% fake verdadeira” = 0).

A §4.7 descreveu narrativamente a inversão distributiva do classificador estrutural: no subconjunto de discordância com o textual, o SAGE atingia $F1 = 0,085$ — *abaixo* do nível da chance. A presente subseção confirma esse fenômeno com números nominais sobre subgrupos extremos definidos *post-hoc*. A Tabela 4.9 e as Figuras 4.10–4.11 re-

portam seis subgrupos, todos derivados de cortes em percentis empíricos do próprio *test*: **fake_contido** (*fakes* com grau de raiz $\leq p5$), **real_viral** (*reais* com grau de raiz $\geq p95$), **cauda_alta_n** e **cauda_baixa_n** (extremos de tamanho da cascata), **deep_extreme** (profundidade ≥ 5) e **wide_extreme** (*branching factor* acima do *p95*).

Três achados se destacam. O primeiro: dos 31 grafos de **fake_contido**, o SAGE acerta **zero** (acurácia 0,000, inversão total da regra aprendida). O segundo: dos 60 grafos de **real_viral**, o SAGE acerta apenas 26 (acurácia 0,433), *abaixo da chance* de 0,50 em problema balanceado. Esses dois subgrupos são os contra-exemplos exatos da regra implicitamente aprendida pelo classificador estrutural (“*fake* = cascata grande, *real* = cascata pequena”): *fakes* contidas violam o primeiro laço da regra, *reais* virais violam o segundo, e o modelo erra precisamente nesses violadores. Não se trata de degradação gradual; trata-se de *inversão distributiva*: a relação entre estrutura e classe está aproximadamente espelhada no subconjunto extremo em relação ao que prevalece no treinamento. O terceiro achado oferece o contraponto positivo: em **cauda_alta_n** ($N = 192$ grafos com **num_nodes** acima do *p95*), o SAGE atinge 0,823 contra 0,547 do RF, *gap* de aproximadamente 28 pontos percentuais absolutos. Quando a topologia oferece estrutura suficiente, a arquitetura neural extrai sinal que o tabular não alcança.

Esta subseção fornece a justificativa empírica mais forte para a assimetria 0,8/0,2 da regra dual (§4.7): quando o classificador estrutural discorda do textual, está sinalizando que possivelmente caiu em um dos subgrupos onde sua regra falha; pesar quatro vezes mais o textual nesse regime é instânciação direta do diagnóstico aqui construído. A caracterização explícita dos subgrupos onde o modelo erra sistematicamente também é insômo direto para a discussão de limitações (Capítulo 5, §5.3) e para o desenho da interface da ferramenta web descrita no Apêndice D, em que predições nesses subgrupos podem ser sinalizadas como “requer revisão humana”.

4.9.4 Cascatas profundas: o ganho cresce com a profundidade




Figure 4.12: Distribuição de profundidade máxima da cascata (`depth_max`) no UPFD-GossipCop *test*. 70% dos grafos tem profundidade 2 (estrela rasa); 30% tem profundidade ≥ 3 , com cauda estendendo-se até 9 *hops*. Contraria a premissa comum de que UPFD é “somente estrela plana”.

Table 4.10: Ganho do SAGE estrutural sobre o RF tabular em subsets de profundidade da cascata no UPFD-GossipCop *test*. Intervalo de confiança 95% via *bootstrap* pareado ($n_{boot} = 2000$). Todos os *subsets* apresentam ganho do SAGE significativo (IC não cruza zero). A magnitude do ganho cresce com a profundidade – consistente com a tese de que o SAGE explora propagação multi-hop, não apenas tamanho.

Subset	N	F1m RF	F1m SAGE	Diff	IC 95%
$\text{depth} \geq 1$ (todos)	3826	0.753	0.814	+0.060	[+0.047, +0.074]
$\text{depth} \geq 3$	1143	0.657	0.791	+0.134	[+0.103, +0.165]
$\text{depth} \geq 5$	256	0.528	0.741	+0.213	[+0.139, +0.287]




Figure 4.13: F1-macro do RF tabular e do SAGE estrutural por valor exato de `depth_max`. O *gap* cresce monotonicamente: +0.029 em `depth=2`, +0.130 em `depth=3`, +0.230 em `depth=5`, +0.383 em `depth=7`.




Figure 4.14: Diferença $F1(SAGE) - F1(RF)$ em *subsets* de profundidade crescente, com IC 95% *bootstrap* ($n_{boot} = 2000$). Barras verdes indicam *subsets* onde o IC inferior é estritamente positivo (SAGE significativamente melhor). O *gap* em $depth \geq 5$ é 3,5× o agregado – evidência direta de que o SAGE explora propagação *multi-hop*, não só tamanho.

A Figura 4.12 desfaz uma premissa comum sobre o *dataset*: o UPFD-GossipCop oficial *não é* composto apenas por estrelas rasas. Dos 3.826 grafos do *test*, 2.683 (70,1%) têm profundidade máxima 2 (de fato estrelas), mas os 1.143 restantes (29,9%) têm profundi-

dade ≥ 3 , com cauda estendendo-se até 9 *hops*. Esta heterogeneidade estrutural é o que permite a estratificação seguinte.

A Tabela 4.10 e a Figura 4.13 reportam o $F1$ -macro do RF tabular e do SAGE estrutural estratificado por valor de `depth_max`, e o *gap* entre ambos cresce monotonicamente: +0,029 em `depth`= 2, +0,130 em `depth`= 3, +0,230 em `depth`= 5 e +0,383 em `depth`= 7. Em valores acumulados, o *gap* é de +0,060 no agregado (todos os 3.826 grafos, $IC_{95\%}$ [+0,047, +0,074]), sobe para +0,134 em `depth` ≥ 3 ($N = 1.143$, $IC_{95\%}$ [+0,103, +0,165]) e atinge +0,213 em `depth` ≥ 5 ($N = 256$, $IC_{95\%}$ [+0,139, +0,287]). Os intervalos de confiança foram obtidos por *bootstrap* pareado de 2.000 reamostragens [?] e **não cruzam zero em nenhum dos recortes**; o SAGE é significativamente melhor que RF em todos os três. A Figura 4.14 sintetiza visualmente: a razão entre o *gap* em `depth` ≥ 5 e o agregado é de aproximadamente $3,5\times$, evidência direta de que o ganho da arquitetura neural sobre o tabular *não é uniforme*: concentra-se justamente onde existe estrutura multi-hop a ser explorada.

A leitura mecanicista coerente com este achado encontra-se na §4.8: o GNNExplainer mostrou que o SAGE, em grafos *fake* (tipicamente de *branching* alto), concentra quase toda a massa de importância em arestas a 1-*hop* da raiz, portanto exatamente o sinal que o RF tabular acessa via [`num_nodes`, `grau_root`]; em grafos *real* de cascata grande, o SAGE redistribui importância para *hops* mais distantes, acessando informação que o tabular não consegue representar. É essa segunda capacidade, a propagação multi-hop, que se materializa numericamente no *gap* crescente da Figura 4.13.

Registramos, por fim, uma precisão terminológica: a observação de que “UPFD-GossipCop oficial possui 30% de grafos com `depth` ≥ 3 ” contradiz a leitura simplificada de que “UPFD é tudo estrela”. Esta segunda formulação, que encontramos em discussões preliminares deste trabalho, *não se aplica* ao *dataset* oficial de Dou et al. [1]; aplica-se apenas ao FakeNewsNet que construímos a partir do repositório CSV (limitação (a) da §5.3), em que a ausência de parentesco entre *retweets* força o grafo a degenerar em estrela rasa.

Síntese da §4.9

A estratificação agregou três contribuições ao trabalho. Primeira: confirmou numericamente, com N s explícitos e acurácias nominais, a inversão distributiva que a §4.7 havia descrito apenas em forma narrativa: o SAGE não apenas erra em `fake_contido` e `real_viral`: erra de modo sistematicamente *invertido*. Segunda: demonstrou que o $F1 = 0,810$ agregado do SAGE em UPFD-GossipCop não se distribui uniformemente: o *gap* sobre o RF tabular cresce de +0,060 no agregado para +0,213 em cascatas com `depth` ≥ 5 , com IC *bootstrap* que não cruza zero. Terceira: caracterizou explicitamente os subgrupos em que o modelo falha, fornecendo material direto para a discussão de

limitações (§5.3) e para o desenho da interface da aplicação demonstrativa (Apêndice D).

4.10 Painel mestre dos achados




Figure 4.15: Painel mestre: F1-macro por *dataset* $\times$ tipo de modelo. Azul = textual (LogReg-BERT-raiz); verde = topológico puro (GNN sem texto); vermelho = completo (GNN com *feature* textual). O contraste entre GossipCop e PolitiFact é manifesto: topologia pura aproxima-se da textual no primeiro; despenca para próximo de *chance* no segundo.

A Figura 4.15 consolida visualmente o argumento que percorre todo este capítulo. Cada *dataset* é representado por um trio de barras coloridas: **azul** para o modelo textual (LogReg-BERT-raiz), **verde** para o modelo topológico puro (GNN treinada sem texto algum) e **vermelho** para o modelo completo (GNN com *feature* textual). A leitura horizontal, entre *datasets* dentro de uma mesma cor, expõe a desigualdade que fundamenta a tese central: em UPFD-GossipCop, o modelo topológico puro aproxima-se do textual e se reconcilia com ele no modelo completo; em UPFD-PolitiFact, o topológico puro despenca para nível próximo da chance enquanto o textual mantém desempenho elevado, e o modelo completo não recupera nada além do que o texto já oferecia. A leitura vertical, entre cores dentro de um mesmo *dataset*, expõe o achado complementar: a *magnitude do ganho* aportado pela topologia ao texto depende criticamente do domínio, e essa dependência está operacionalizada pelo Cohen's *d* entre as classes (§4.6). É a esses dois eixos (horizontal e vertical) que os Capítulos seguintes voltarão para discutir limitações e direções futuras.

Chapter 5

Discussão e Conclusão

Este capítulo é o lugar onde se assume responsabilidade pelo que os experimentos efetivamente mostraram. Cada afirmação quantitativa aqui apresentada é ancorada na tabela, figura ou seção que a sustenta; afirmações sem essa âncora foram deliberadamente excluídas.

5.1 Síntese dos achados por pergunta de pesquisa

RQ1 — a topologia carrega sinal acima do que o texto da raiz já fornece? A resposta depende do *dataset* e do regime de *features*. No FakeNewsNet, o texto da raiz isoladamente já satura o sinal: o *baseline* LogReg-BERT atinge $F1\text{-macro} = \mathbf{0,859 \pm 0,043}$ sobre 10 *folds* (Tabela 4.2), e nenhuma das três arquiteturas GNN adicionada ao mesmo protocolo (GCN, GAT e SAGE com *features* estruturais sobre o FNN *posfull*) difere significativamente desse valor pelo *ttest_rel* pareado (todos ranqueados como não-significantes em §3.7). No UPFD-GossipCop, ao contrário, a topologia agrega ganho mensurável: o SAGE com *features* estruturais puras atinge $\mathbf{F1} = \mathbf{0,810 \pm 0,002}$ (Tabela 4.5), e a análise estratificada da §4.9 mostrou que esse ganho *cresce monôtonicamente com a profundidade da cascata*: de $+0,060$ no agregado para $+0,213$ em $\text{depth} \geq 5$, com intervalo de confiança *bootstrap* de 2.000 reamostragens que não cruza zero em nenhum dos recortes (Tabela 4.10). Em UPFD-PolitiFact, finalmente, não se detecta ganho topológico significativo: a mesma arquitetura SAGE sem texto colapsa para $\mathbf{F1} = \mathbf{0,331 \pm 0,009}$ (Tabela 4.5), valor abaixo do nível de chance (0,50 em problema balanceado), e as outras duas arquiteturas testadas no mesmo regime ficam pouco acima (0,362 para GCN; 0,380 para GAT), todas em colapso equivalente.

RQ2 — sob quais condições estruturais? A resposta foi operacionalizada via tamanho de efeito de Cohen (d) entre as classes em métricas de cascata (§4.6 e Tabela 4.7). O UPFD-GossipCop apresenta $\mathbf{d} = +1,53$ no *branching factor* (efeito *grande* pela escala de Cohen) e $d = +0,91$ em *num_nodes* (também grande); o UPFD-PolitiFact não al-

cança sequer um efeito médio em nenhuma métrica avaliada, com $|d|$ máximo de **0,25** em `num_nodes`; e o FakeNewsNet apresenta $|d| \approx 0,22$ em `num_nodes` e `branching_avg`, valores matematicamente idênticos por consequência direta da topologia em estrela (em estrela, $\text{branching avg} = \text{num_nodes} - 1$). Este contraste sustenta a **tese central**, que formulamos de modo deliberadamente falsificável:

Modelos topológicos exigem diferença estrutural entre classes da ordem de magnitude de um efeito médio de Cohen ($|d| \geq 0,5$) em pelo menos uma métrica de cascata para serem efetivos; abaixo desse limiar, colapsam, independentemente da arquitetura GNN escolhida.

A tese é refutável: a apresentação de um *dataset* com $0,2 < |d| < 0,5$ no qual uma arquitetura GNN atinja desempenho significativamente acima do *baseline* textual e do RF tabular constituiria contra-evidência direta.

RQ3 — é viável detectar fake news apenas pela topologia, em cenários sem texto explorável? A resposta também é bilateral e composta de duas partes. Quanto à parte (a), viável sem texto algum?, a Tabela 4.5 mostra que sim, mas *condicional* à condição da RQ2: SAGE com duas dimensões estruturais por nó (`is_root`, `grau_norm`) atinge $F1 = 0,810$ em GossipCop, sem nenhum acesso ao conteúdo textual da notícia. Quanto à parte (b), indiferente ao idioma do post?, a §4.5 aplicou o RF estrutural sobre subconjuntos monolíngues do Bluesky e encontrou $d = -0,057$ entre português e inglês (efeito desprezível) e $d = -0,468$ entre alemão e inglês (efeito médio) (Tabela 4.6). Como o classificador estrutural *não processa texto*, seu mecanismo é arquiteturalmente independente do idioma; a divergência DE *vs.* EN não pôde ser isolada entre fator linguístico, fator de comunidade, *shift* de domínio e desbalanço amostral.

5.2 Achado negativo é achado

O resultado de UPFD-PolitiFact merece tratamento explícito porque é metodologicamente tão importante quanto o resultado positivo de UPFD-GossipCop. Não se trata de falha de implementação: a mesma arquitetura, com o mesmo *pipeline*, atinge $F1 = 0,810$ quando treinada em um *dataset* estruturalmente assortativo (Tabela 4.5). Tampouco se trata de inadequação da família GNN em geral: as três arquiteturas testadas (GCN, GAT, SAGE) colapsam de forma equivalente em PolitiFact, respectivamente para 0,362, 0,380 e 0,331. O Cohen’s d desprezível naquele domínio (Tabela 4.7) mostra, no plano descritivo, que *fake* e *real* são *estruturalmente indistinguíveis* nas métricas de cascata avaliadas, e é justamente isso que a tese da §4.6 prevê: causa estrutural identificada, não falha de modelo.

Reportar este achado com a mesma extensão dos achados positivos não é formalismo: é exigência da tese central. Uma teoria que afirma “topologia funciona sob a condição X ” é fortalecida, não enfraquecida, pela demonstração de que ela *não funciona* quando X falha. A literatura de detecção de fake news com GNNs tende a reportar predominantemente resultados positivos; ao trazer explicitamente o caso negativo, este trabalho oferece o diagnóstico de aplicabilidade, e não apenas mais uma demonstração, que propõe como contribuição primária.

Uma evidência complementar reforça a leitura. A §4.9.3 mostrou que, mesmo no UPFD-GossipCop (onde o modelo *funciona*), há subgrupos extremos em que a regra estrutural aprendida pelo SAGE se inverte sistematicamente: dos 31 grafos do subgrupo **fake_contido** (*fakes* com grau de raiz no percentil 5 inferior), o SAGE acerta **zero**; dos 60 grafos do subgrupo **real_viral** (*reais* com grau de raiz no percentil 95 superior), acerta apenas 43%, desempenho abaixo da chance (Tabela 4.9). Esses subgrupos demarcam o *limite operacional* do mecanismo topológico: ele funciona quando a regra “*fake* = cascata maior” vale, e inverte exatamente onde essa regra falha.

5.3 Limitações

Reconhecemos sete limitações do trabalho, listadas em ordem de importância decrescente.

- (a) **Topologia em estrela no FakeNewsNet construído por nós.** O grafo gerado por `00_construir_grafos_fakenewsnet.py` (§3.3) é sempre uma estrela rasa, pois o CSV bruto do repositório KaiDMML não fornece parentesco entre *retweets* nem *timestamps*. Adicionalmente, o filtro de `MAX_NOS=100` adotado trunca metade dos grafos do *dataset* (verificação matemática em §3.3 mostrou que a distribuição bruta tem média 552 e máximo 29.060 *tweets* por notícia), tornando os 377 grafos truncados indistinguíveis quanto ao tamanho absoluto da cascata. Esta limitação vale exclusivamente para o FakeNewsNet que construímos: no UPFD-GossipCop oficial, 30% dos grafos possuem profundidade ≥ 3 , com cauda até profundidade 9 (§4.9.4).
- (b) **Regra dual derivada *post-hoc* de um único experimento.** A combinação textual + topológico exposta na §4.7 usa pesos 0,8/0,2 derivados após a observação da inversão distributiva no UPFD-GossipCop. Sua generalização a outros domínios é uma conjectura a ser testada, não um resultado validado.
- (c) **Bluesky sem rótulos de veracidade.** O *dataset* de Failla e Rossetti [2] não traça rótulos *fake/real*, o que restringe seu uso à parte (b) da RQ3 (§4.5) e à aplicação demonstrativa documentada no Apêndice D, impedindo validação supervisionada nesta fonte. Os rótulos heurísticos por palavras-chave que acompanham nossa publicação do *dataset* processado não foram empregados como supervisão.

- (d) **Reprodutibilidade não *bit-exact*.** Embora todos os *seeds* sejam fixados (42 como semente universal), o não-determinismo de operadores `scatter/gather` do PyTorch Geometric e a sensibilidade aritmética entre versões de biblioteca podem produzir variações na terceira casa decimal das métricas reportadas. As conclusões qualitativas são robustas a essa variação: os achados centrais foram validados em 10 *seeds* independentes (§4.4) e em *bootstrap* pareado de 2.000 reamostragens (§4.9.4).
- (e) **Ausência de comparativo numérico direto com BiGCN e GCNFN.** Não foi viável re-implementar essas arquiteturas dentro do escopo do trabalho; a comparação com Dou et al. [1] é indicativa (Tabela 4.4) por três diferenças declaradas: *feature content* (310d) em vez de *bert* (768d), hiperparâmetros próprios, e métrica F1-macro em vez de acurácia.
- (f) **Bluesky é *snapshot* temporal.** O dado coletado por [2] cobre 11 *feeds* temáticos da plataforma em janela de aproximadamente um ano; generalização para janelas temporais futuras não é garantida.
- (g) **Ambiente exclusivamente CPU.** Todos os experimentos foram executados em CPU (Intel *Raptor Lake*, 16 *cores* lógicos, 16 GB de RAM, PyTorch 2.10+cpu). Hiperparâmetros adotados podem ser subótimos em ambientes com GPU; o *pipeline*, no entanto, é portátil.

5.4 Trabalhos futuros

Quatro direções naturais se desdobram dos achados deste trabalho.

- (1) **Pseudo-rótulos no Bluesky para retreino especializado.** A inferência *cross-domain* demonstrada no Apêndice D poderia ser convertida em ciclo de auto-treinamento: usar o LogReg-BERT treinado em FakeNewsNet como oráculo para gerar pseudo-rótulos em um subconjunto de alta confiança do Bluesky, e então retreinar classificadores estruturais especializados para a plataforma. Os 168.463 posts disponíveis (§D.1) tornariam o experimento tratável.
- (2) **Calibração de probabilidades.** O *score* produzido pelo RF estrutural sobre o Bluesky é empregado como *proxy* ordinal (§D.2); transformá-lo em probabilidade calibrada exigiria técnicas como *Platt scaling* ou regressão isotônica, o que demanda subconjunto rotulado no domínio-alvo.
- (3) **Expansão para *datasets* de noticiário contemporâneo.** A existência de pelo menos um domínio com $|d| < 0,5$ (UPFD-PolitiFact) sugere que a tese central possa ser

refinada com mais *datasets* de diferentes plataformas (Mastodon, Threads, X pós-2023) e diferentes janelas temporais, testando se o limiar de 0,5 é exato ou apenas ordem de magnitude.

(4) Replicação direta de BiGCN e GCNFN. Para preencher a limitação (e) acima, vale re-implementar essas arquiteturas e submetê-las ao mesmo protocolo de avaliação adotado aqui (mesmo k -fold, mesmo $ttest_rel$ pareado), permitindo confronto *bit-exact* com a literatura.

5.5 Considerações finais

Este trabalho não propôs uma nova arquitetura de Rede Neural de Grafos. Propôs, em seu lugar, um *diagnóstico*: sob quais condições a topologia da propagação detecta fake news, e quando não detecta. Três *datasets*, três arquiteturas e mais de uma dezena de métricas (Tabela 4.1) convergem para uma tese única e refutável: a aplicabilidade depende de assortatividade estrutural mensurável ($|d| \geq 0,5$). A defesa de um resultado negativo (UPFD-PolitiFact) lado a lado de um resultado positivo (UPFD-GossipCop), ancorada em estatística de tamanho de efeito e validada por análise estratificada do erro com *bootstrap* pareado, é a contribuição metodológica que esperamos transcender o escopo do *dataset* específico. O código, os pesos persistidos no Hugging Face Hub e a ferramenta web (Apêndice D) permitem que esta posição seja contestada empiricamente em outros domínios, exatamente como a tese, por ser falsificável, exige.

Bibliography

- [1] Yingtong Dou, Kai Shu, Congying Xia, Philip S. Yu, and Lichao Sun. User preference-aware fake news detection. In *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*, pages 2051–2055, 2021.
- [2] Andrea Failla and Giulio Rossetti. “I’m in the Bluesky Tonight”: Insights from a Year’s Worth of Social Data. *PLOS ONE*, 19(11):e0310330, 2024. Dataset utilizado no Cap 5; disponível no Zenodo, DOI 10.5281/zenodo.14258401.
- [3] Kai Shu, Deepak Mahudeswaran, Suhang Wang, Dongwon Lee, and Huan Liu. FakeNewsNet: A data repository with news content, social context, and spatiotemporal information for studying fake news on social media. *Big Data*, 8(3):171–188, 2020.
- [4] César Augusto Sibila, André Messina Livingston, and Enzo Kikuji Takida. Bluesky Fake News Dataset: A curated snapshot of bluesky posts and repost cascades (2024–2025). Hugging Face Datasets, 2026. Curado pelos autores a partir de um dump público da firehose do Bluesky; rótulos heurísticos derivados de etiquetas de moderação da API e léxico ad-hoc de termos de desinformação.

Apêndices

Appendix A

Hiperparâmetros completos

Appendix B

Índice geral de figuras e tabelas

Appendix C

Estrutura do repositório de código

Appendix D

Aplicação demonstrativa: Bluesky e ferramenta web

Este apêndice documenta a aplicação dos modelos persistidos sobre o *dataset* acadêmico do Bluesky e a ferramenta web que integra os classificadores textual e topológico. É matéria *demonstrativa*, não validatória: o Bluesky não possui rótulos *fake/real*, e portanto nenhum *claim* supervisionado é feito a partir deste material. A validação quantitativa do trabalho está inteiramente no Capítulo 4; a parte referente à independência linguística (RQ3-b) está na §4.5.

D.1 O *dataset* Bluesky

Utilizamos o *snapshot* acadêmico publicado por Failla e Rossetti [2], que cobre 168.463 posts distribuídos em 11 *feeds* temáticos (*Blacksky*, *News*, *Science*, *Political Science*, entre outros), coletados via AT Protocol [?]. O dado é *snapshot* e não amostra probabilística — a limitação temporal está registrada como item (f) da §5.3. O empacotamento publicado pelos autores deste trabalho no Hugging Face Hub [4] preserva a estrutura original dos *feeds* e adiciona rótulos heurísticos por palavra-chave que *não foram empregados* como supervisão em momento algum do *pipeline*.

D.2 Inferência *cross-domain* dos modelos persistidos

Aplicamos o classificador textual (LogReg-BERT-*content* treinado em FakeNewsNet Poli-tiFact) e o classificador topológico (RF estrutural treinado em UPFD-GossipCop) sobre os 168.463 posts. A Tabela ?? reporta a média do *score* “*fake-like*” do RF estrutural por *feed*, permitindo *ranking* relativo entre comunidades.

Table D.1: Aplicacao do RF estrutural (treinado em GossipCop) sobre 168k posts do Bluesky – ranking de feeds por score ‘fake-like’.

Feed Bluesky	N	Score medio	% pred=fake
Political Science	357	0.6663	69.2%
Blacksky	86490	0.4391	32.0%
What’s History	161	0.3665	28.0%
#Disability	566	0.3475	17.1%
#UkrainianView	2098	0.3377	26.1%
Science	33831	0.3374	23.0%
BookSky	638	0.3210	12.5%
GreenSky	662	0.3120	14.2%
AcademicSky	913	0.3095	10.0%
Game Dev	635	0.2809	4.4%
News	42112	0.2704	6.7%




Figure D.1: Distribuição do *score* “fake-like” produzido pelo RF estrutural sobre os 168.463 posts do Bluesky, estratificada por *feed*.

Limitação explícita de interpretação. O *score* reportado *não é probabilidade calibrada*. É a saída `predict_proba` do RF treinado em UPFD-GossipCop, aplicada a um domínio diferente (Bluesky), sem *ground-truth* que permita calibração por *Platt scaling* ou regressão isotônica. A interpretação correta é como *proxy ordinal* — útil para o *ranking* relativo entre *feeds* reportado na Tabela ??, não para decisão absoluta. Trabalho futuro (§5.4, item 2) discute essa calibração.

D.3 Concordância textual $\times$ topológico

Sobre uma amostra estratificada de 3.728 posts com cascata mínima para visualização da árvore de propagação, comparamos as predições do classificador textual com as do topológico (novamente: sem *ground-truth*, apenas concordância entre classificadores). A taxa de concordância agregada é moderada, seguindo o mesmo padrão observado em UPFD-GossipCop (§4.7): *posts* com cascata grande tendem à concordância ($\geq 74\%$ para $n_{\text{nodes}} \geq 20$), *posts* de tamanho médio caem na zona cinzenta (42% a 44% para $2 \leq n_{\text{nodes}} \leq 20$). O *feed Political Science* atinge 88,7% de concordância agregada — o mais alto da amostra — o que sugere que comunidades politicamente engajadas geram sinais textuais e estruturais mais alinhados.

D.4 Ferramenta web

A aplicação web (FastAPI *backend* + Next.js *frontend*) integra os três modelos persistidos — LogReg-BERT-*content*, RF estrutural e SAGE estrutural — expostos através do *endpoint* `/api/result`. A combinação das predições textual e topológica segue a regra dual derivada *post-hoc* dos resultados do Capítulo 4 (Equação 4.1 e Figura 4.5):

Listing D.1: Trecho da regra dual no *backend* FastAPI.

```
def _combinar_scores(score_textual, score_topo):
    pred_t = score_textual >= 0.5
    pred_k = score_topo >= 0.5
    if pred_t == pred_k:
        return 0.5 * score_textual + 0.5 * score_topo, True
    return 0.8 * score_textual + 0.2 * score_topo, False
```

Os pesos do modelo são carregados a partir do repositório publicado no Hugging Face Hub [4] sob licença CC-BY-4.0; o código da *API*, os *scripts* de inferência e o *frontend* estão no repositório Git do trabalho (Apêndice C). A ferramenta foi construída como prova de conceito de *deploy*, não como produto auditado para uso em moderação real — decisões sobre conteúdo a partir desses *scores* devem respeitar as limitações documentadas no Capítulo 5, em especial a ausência de calibração de probabilidades e a dependência de assortatividade estrutural do domínio-alvo.