

Detecção de Fake News com Redes Neurais de Grafos: Ablation Sistemática e Diagnóstico de Aplicabilidade Topológica

André Messina Livingston

César Augusto Sibila

Enzo Kikuji Takida

São Paulo, 2026

André Messina Livingston
César Augusto Sibila
Enzo Kikuji Takida

**Detecção de Fake News com Redes Neurais de Grafos:
Ablation Sistemática e Diagnóstico de Aplicabilidade
Topológica**

São Paulo
2026

André Messina Livingston
César Augusto Sibila
Enzo Kikuji Takida

Detecção de Fake News com Redes Neurais de Grafos: Ablation Sistemática e Diagnóstico de Aplicabilidade Topológica

Trabalho de Conclusão de Curso apresentado ao curso de Ciência de Dados da Pontifícia Universidade Católica de São Paulo como requisito parcial para obtenção do título de Bacharel em Ciência de Dados. Aprovado em:

BANCA EXAMINADORA

Prof. Orientador(a) – PUC-SP

Prof. Examinador(a) – PUC-SP

Prof. Examinador(a) – PUC-SP

São Paulo, 2026

Resumo

A detecção de fake news em redes sociais é tradicionalmente abordada por processamento de linguagem natural (PLN), mas essa estratégia perde robustez frente a modelos generativos capazes de produzir texto gramaticalmente impecável e a postagens em idiomas não cobertos por modelos pré-treinados. Este trabalho investiga em que condições a **topologia da propagação**, o padrão com que uma notícia se espalha pela rede, pode complementar ou substituir a análise textual. Três perguntas de pesquisa orientam o trabalho: (RQ1) topologia carrega sinal discriminante acima do texto da raiz da árvore de propagação? (RQ2) sob quais condições estruturais? (RQ3) é viável detectar fake news *apenas* pela topologia?

Realizamos ablation sistemática em três *datasets* (FakeNewsNet PolitiFact, UPFD-PolitiFact, UPFD-GossipCop), comparando GCN, GAT e GraphSAGE com três variantes de *features* estruturais. Os experimentos são validados com k-fold pareado, teste *t* pareado (`ttest_rel`) e tamanho de efeito de Cohen (*d*).

Os achados centrais são bilaterais. **Positivo:** GraphSAGE com apenas duas *features* estruturais por nó atinge F1-macro = 0,810 em UPFD-GossipCop *sem usar texto algum* (10 *seeds*, $\sigma = 0,002$). **Negativo:** a mesma arquitetura colapsa em UPFD-PolitiFact (F1 $\approx 0,33$, abaixo da chance). A causa estrutural é identificada via Cohen's *d*: GossipCop apresenta $d = +1,53$ no *branching factor* das cascatas; PolitiFact não alcança efeito médio em nenhuma métrica avaliada ($|d| < 0,5$). A tese central, deliberadamente falsificável, é que modelos topológicos requerem $|d| \geq 0,5$ em pelo menos uma métrica de cascata para serem efetivos. Como evidência complementar para a parte (b) da RQ3, o classificador estrutural produz, sobre subconjuntos monolíngues de um *snapshot* acadêmico do Bluesky, distribuições de *score* estatisticamente equivalentes entre português e inglês ($d = -0,057$). Os pesos persistidos no Hugging Face Hub e a ferramenta web que integra os classificadores estão documentados no Apêndice D.

Palavras-chave: Fake news. Graph Neural Networks. UPFD. FakeNewsNet. Bluesky. Cohen's *d*. Encodings posicionais.

Abstract

Fake-news detection in social media is traditionally tackled by Natural Language Processing (NLP), but this strategy loses robustness against generative models capable of producing grammatically impeccable text and against posts in languages not covered by pre-trained models. This work investigates under which conditions **propagation topology**, the pattern by which news spreads through the network, can complement or replace textual analysis. Three research questions guide the work: (RQ1) does topology carry discriminative signal beyond the root-text of the propagation tree? (RQ2) under which structural conditions? (RQ3) is it feasible to detect fake news *using topology only*?

We perform a systematic ablation on three datasets (FakeNewsNet PolitiFact, UPFD-PolitiFact, UPFD-GossipCop), comparing GCN, GAT and GraphSAGE under three structural feature variants. Experiments are validated with paired k-fold, paired `ttest_rel`, and Cohen’s d effect size.

Findings are bilateral. **Positive:** GraphSAGE with only two per-node structural features achieves $F1\text{-macro} = 0.810$ on UPFD-GossipCop *without using text at all* (10 seeds, $\sigma = 0.002$). **Negative:** the same architecture collapses on UPFD-PolitiFact ($F1 \approx 0.33$, below chance). The structural cause is identified via Cohen’s d : GossipCop shows a fake-vs-real difference of $d = +1.53$ on cascade branching factor; PolitiFact does not reach a medium-effect size on any evaluated metric ($|d| < 0.5$). Our central and deliberately falsifiable thesis is that topological models require $|d| \geq 0.5$ on at least one cascade metric to be effective. As complementary evidence for RQ3 part (b), the structural classifier produces, over monolingual subsets of an academic Bluesky snapshot, statistically equivalent score distributions between Portuguese and English ($d = -0.057$). Persisted weights on the Hugging Face Hub and the web application integrating the classifiers are documented in Appendix D.

Keywords: Fake news. Graph Neural Networks. UPFD. FakeNewsNet. Bluesky. Cohen’s d . Positional encodings.

Lista de Figuras

- 1.1 Caminho percorrido por uma notícia candidata pelos modelos persistidos do trabalho. Em azul, a entrada bruta (título e árvore de propagação); em laranja e verde, os dois encoders independentes (*embedding* textual e *features* estruturais); em violeta, os classificadores treinados que produzem dois *scores* (s_T , s_K); a regra dual (em amarelo) decide se os dois concordam e atribui pesos 0,5/0,5 ou 0,8/0,2 ao combinar (§4.7); o *score* final é acompanhado de uma *flag* de concordância que sinaliza confiança do par. 15
- 2.1 Exemplos reais de árvores de propagação extraídos dos conjuntos UPFD PolitiFact (linha superior) e GossipCop (linha inferior). O nó raiz (mais escuro) representa a publicação original; os demais nós representam interações subsequentes (reposts, respostas). Em ambos os datasets, exemplos falsos (vermelho) e verdadeiros (azul) apresentam estruturas superficialmente similares em tamanho — evidenciando que o número de nós isolado não é discriminante, motivação central para o uso de GNNs neste trabalho. 20
- 2.2 Arquitetura da GCN utilizada neste trabalho: três camadas GCNConv (768→64, 64→64, 64→64) com ativação ReLU, seguidas de Global Mean Pool, Dropout (0,5) e classificador linear (64→2). 23
- 2.3 Arquitetura da GAT utilizada neste trabalho: três camadas GATConv com atenção *softmax* multi-cabeça (camadas 1 e 2: 4 cabeças, concat=False; camada 3: 1 cabeça), seguidas de Global Mean Pool, Dropout (0,5) e classificador linear (64→2). 24
- 2.4 Arquitetura da GraphSAGE utilizada neste trabalho: três camadas SAGEConv com agregação por média ($W_l \cdot h + W_r \cdot h_{\mathcal{N}}$, indutivo), seguidas de Global Mean Pool, Dropout (0,5) e classificador linear (64→2). 25
- 3.1 Visão geral do *pipeline* de detecção. Dados brutos são transformados em grafos de propagação com *features* estruturais (e textuais via BERT, quando disponíveis), passados por modelos GNN, e avaliados com protocolo de k-fold pareado. 33

4.1	F1-macro por (arquitetura $\times$ <i>feature variant</i> $\times$ <i>dataset</i>). Verde = modelo aprende; vermelho = colapsa. SAGE em UPFD-GossipCop com apenas duas <i>features</i> estruturais atinge $F1 \approx 0.81$	46
4.2	Distribuição do <i>score</i> topológico do RF-estrutural (treinado em UPFD-GossipCop) aplicado a posts do Bluesky por idioma. EN ($n=132.312$), DE ($n=9.686$) e PT ($n=2.661$) médias indicadas na legenda. PT e EN são praticamente indistinguíveis ($d=-0.057$); DE difere por efeito médio ($d=-0.468$).	48
4.3	<i>Forest plot</i> de Cohen's d entre fake e real para cada métrica estrutural, em cada <i>dataset</i> . Linhas pontilhadas indicam limiares de Cohen (0.2 / 0.5 / 0.8). UPFD-GossipCop apresenta efeito <i>grande</i> ($d=+1.53$) em <i>branching factor</i> ; UPFD-PolitiFact e FakeNewsNet ficam abaixo do limiar de efeito <i>médio</i> ($ d < 0,5$); o máximo é $ d \approx 0,25$	50
4.4	<i>Scatter score</i> textual (LogReg-BERT) $\times$ topológico (SAGE estrutural) no UPFD-GossipCop <i>test</i> . Quadrantes indicam concordância em FAKE (canto inferior-esquerdo) e em REAL (canto superior-direito); discordância ocupa os outros dois quadrantes.	52
4.5	Fluxograma da regra dual de combinação textual $\times$ topológico, derivada <i>post-hoc</i> dos resultados de §4.7.	53
4.6	Fração de massa de importância em arestas a 1-hop, 2-hop e 3+ hops da raiz, agregado por estrato (classe $\times$ tamanho). Assimetria FAKE <i>vs</i> REAL: para FAKE, o SAGE concentra quase toda a decisão em arestas 1-hop (raiz $\rightarrow$ filhos diretos); para REAL-grande, distribui entre <i>hops</i> mais distantes.	54
4.7	Histograma das três métricas estruturais (eixo x em escala logarítmica para num_nodes) com ajuste de distribuição lognormal sobreposto. Teste KS rejeita o <i>fit</i> em todas ($p < 10^{-11}$), indicando cauda mais pesada que lognormal.	56
4.8	Probabilidade de acerto suavizada (<i>rolling-mean</i> de janela proporcional, 10% da amostra) do RF tabular e do SAGE estrutural em função de cada métrica estrutural no UPFD-GossipCop <i>test</i> . Linha pontilhada cinza marca o <i>chance level</i> . SAGE supera RF de forma crescente em num_nodes e depth_max ; o gap em branching_avg é maior na região mediana.	57
4.9	F1-macro de RF e SAGE por tercil estrutural – versão discreta da Figura 4.8. Em num_nodes , SAGE cresce monotonicamente (T1 $\rightarrow$ T3); RF decresce. Em depth_max , distribuição discreta colapsa o tercil intermédio.	57
4.10	Acurácia do RF e do SAGE em seis subgrupos extremos definidos <i>post-hoc</i> via percentil empírico (p5/p95 sobre o <i>test</i>). Linhas pontilhadas indicam baselines agregados. O subgrupo fake_contido (notas falsas com baixo engajamento) e o real_viral (notícias verdadeiras que viralizaram) caem abaixo da chance – confirmam a inversão distributiva descrita em §4.7.	58

4.11	Composição real (% <i>fake</i> verdadeira) <i>vs.</i> proporção predita pelo modelo, por subgrupo. Linhas com cor diferente em uma mesma coluna indicam que o modelo não reproduz a distribuição de classes do subgrupo – característico de <code>real_viral</code> (linha “% predito fake” alta enquanto “% fake verdadeira” = 0).	59
4.12	Distribuição de profundidade máxima da cascata (<code>depth_max</code>) no UPFD-GossipCop <i>test</i> . 70% dos grafos tem profundidade 2 (estrela rasa); 30% tem profundidade ≥ 3 , com cauda estendendo-se até 9 <i>hops</i> . Contraria a premissa comum de que UPFD é “somente estrela plana”.	60
4.13	F1-macro do RF tabular e do SAGE estrutural por valor exato de <code>depth_max</code> . O <i>gap</i> cresce monotonicamente: +0.029 em <code>depth</code> =2, +0.130 em <code>depth</code> =3, +0.230 em <code>depth</code> =5, +0.383 em <code>depth</code> =7.	61
4.14	Diferença F1(SAGE) – F1(RF) em <i>subsets</i> de profundidade crescente, com IC 95% <i>bootstrap</i> ($n_{boot} = 2000$). Barras verdes indicam <i>subsets</i> onde o IC inferior é estritamente positivo (SAGE significativamente melhor). O <i>gap</i> em <code>depth</code> ≥ 5 é $3,5\times$ o agregado – evidência direta de que o SAGE explora propagação <i>multi-hop</i> , não só tamanho.	62
4.15	Painel mestre: F1-macro por <i>dataset</i> $\times$ tipo de modelo. Azul = textual (LogReg-BERT-raiz); verde = topológico puro (GNN sem texto); vermelho = completo (GNN com <i>feature</i> textual). O contraste entre GossipCop e PolitiFact e manifesto: topologia pura aproxima-se da textual no primeiro; despenca para próximo de <i>chance</i> no segundo.	64
D.1	Distribuição do <i>score</i> “ <i>fake-like</i> ” produzido pelo RF estrutural sobre os 168.463 posts do Bluesky, estratificada por <i>feed</i>	92

Lista de Tabelas

2.1	Interpretação de tamanho de efeito de Cohen (d).	29
3.1	Datasets utilizados, com tamanho, fonte e papel no trabalho.	34
3.2	Hiperparâmetros usados nos modelos GNN. Defaults são iguais entre arquiteturas; diferenças anotadas na própria tabela.	36
4.1	Síntese de resultados: F1-macro por ($dataset \times$ modelo). Células verdes indicam desempenho forte ($\geq 0,80$); amarelas, médio ($0,60-0,79$); vermelhas, colapso ($< 0,60$). Negrito marca o melhor modelo de cada <i>dataset</i> . O contraste entre UPFD-GossipCop (todas as linhas verdes) e UPFD-PolitiFact com features estruturais puras (linha inteira em vermelho) e' o achado central do trabalho.	42
4.2	Baseline textual no FakeNewsNet (k-fold estratificado, $k=10$).	43
4.3	Benchmark cross-dataset UPFD (PolitiFact + GossipCop) – GCN/GAT/SAGE vs baseline textual.	44
4.4	Comparacao com baselines do UPFD original (Dou et al., SIGIR 2021, Tabela 4). Nota: nossos resultados sao F1-macro sobre k-fold com feature 'content' (310d); valores publicados sao accuracy com feature 'bert' (768d). Comparacao indicativa, nao bit-exact.	44
4.5	Topologia SEM texto: features [is_root, grau_norm] – sinal estrutural puro por dataset/arch.	45
4.6	Comparacao da distribuicao de score topologico no Bluesky entre idiomas (RQ3 parte b). PT vs EN: efeito desprezivel ($ d < 0.2$); DE vs EN: efeito medio ($ d = 0.47$). Interpretacao com 3 hipoteses alternativas em §4.4-bis (shift dominio, vies amostral, desbalanco).	47
4.7	Analise estrutural fake vs real – separabilidade por metrica topologica. Cohen's d : $ d \geq 0.5$ medio, ≥ 0.8 grande.	49
4.8	Comparacao TEXTUAL vs TOPOLOGICO no UPFD-GossipCop – concordancia, kappa, e desempenho condicional.	51

4.9	Acuracia do RF estrutural e do SAGE em seis subgrupos extremos do UPFD-GossipCop <i>test</i> . Subgrupos derivados <i>post-hoc</i> via percentil empírico (não <i>z</i> -score, justificado pela rejeição do <i>fit</i> lognormal em §4.9.1). Δ = diferença vs. acurácia agregada (RF=0.754, SAGE=0.814). *Subgrupos com classe única não admitem F1-macro.	58
4.10	Ganho do SAGE estrutural sobre o RF tabular em subsets de profundidade da cascata no UPFD-GossipCop <i>test</i> . Intervalo de confiança 95% via <i>bootstrap</i> pareado ($n_{boot} = 2000$). Todos os <i>subsets</i> apresentam ganho do SAGE significativo (IC não cruza zero). A magnitude do ganho cresce com a profundidade – consistente com a tese de que o SAGE explora propagação multi-hop, não apenas tamanho.	61
A.1	Hiperparâmetros das arquiteturas GNN avaliadas em GCN, GAT e SAGE. Defaults idênticos onde não indicado; diferenças anotadas na coluna respectiva.	78
A.2	Hiperparâmetros dos classificadores <i>baseline</i> textuais e tabulares utilizados nos experimentos.	79
A.3	Parâmetros do protocolo estatístico adotado.	80
A.4	Parâmetros adotados na construção dos grafos do FakeNewsNet (script <code>00_construir_grafos_fakenewsnet.py</code>).	80
A.5	Configuração do ambiente computacional adotado em todos os experimentos.	81
B.1	Tabelas geradas pelo trabalho, seus papéis no texto e <i>scripts</i> geradores. . .	83
B.2	Figuras geradas pelo trabalho. Identificadores F1–F35 correspondem aos arquivos persistidos em <i>Imagens/</i> do repositório.	85
D.1	Aplicacao do RF estrutural (treinado em GossipCop) sobre 168k posts do Bluesky – ranking de feeds por score 'fake-like'.	92

Lista de abreviaturas e siglas

BERT Bidirectional Encoder Representations from Transformers

BFS Breadth-First Search (busca em largura)

CC-BY-4.0 *Creative Commons Attribution 4.0 International*

CPU Central Processing Unit

CSV Comma-Separated Values

DOI Digital Object Identifier

FNN FakeNewsNet

GAT Graph Attention Network

GCN Graph Convolutional Network

GNN Graph Neural Network (Rede Neural de Grafos)

GNNs Graph Neural Networks

GPU Graphics Processing Unit

HF Hugging Face

IC Intervalo de confiança

KS Kolmogorov-Smirnov (teste de)

LLM *Large Language Model*

LOWESS *Locally Weighted Scatterplot Smoothing*

ML *Machine Learning* (Aprendizado de Máquina)

MPNet *Masked and Permuted Pre-training for Language Understanding*

NLP *Natural Language Processing*

PLN Processamento de Linguagem Natural

RAM *Random Access Memory*

ReLU *Rectified Linear Unit*

RF *Random Forest*

RQ *Research Question* (Pergunta de pesquisa)

SAGE GraphSAGE (*Sample and Aggregate* para grafos)

SBERT Sentence-BERT

TCC Trabalho de Conclusão de Curso

UPFD *User Preference-aware Fake News Detection* (Dou et al., 2021)

XAI *Explainable Artificial Intelligence*

Sumário

Resumo	1
Abstract	2
Lista de figuras	5
Lista de tabelas	7
Lista de abreviaturas e siglas	8
1 Introdução	13
1.1 Contextualização	13
1.2 Motivação	14
1.3 Perguntas de pesquisa	15
1.4 Contribuições	15
1.5 Estrutura do trabalho	16
2 Fundamentação Teórica	18
2.1 Detecção de fake news: panorama	18
2.2 Grafos e redes sociais	19
2.3 Embeddings textuais	21
2.4 Redes Neurais de Grafos	22
2.4.1 Graph Convolutional Networks (GCN)	22
2.4.2 Graph Attention Networks (GAT)	23
2.4.3 GraphSAGE	24
2.5 Degeneração do GCN com <i>features</i> homogêneas	25
2.6 Codificações posicionais	26
2.7 Explicabilidade em GNNs: GNNExplainer	27
2.8 Validação estatística	28
2.9 Trabalhos relacionados	29
2.9.1 Surveys de GNNs em detecção de fake news	29
2.9.2 Métodos GNN canônicos para detecção	30

2.9.3	Detecção multilíngue	30
2.9.4	Trabalhos brasileiros relacionados	31
2.9.5	Homofilia e assortatividade em redes	31
2.9.6	Posicionamento deste trabalho	32
3	Metodologia	33
3.1	Visão geral do pipeline	33
3.2	Datasets	33
3.3	Construção de grafos: FakeNewsNet	34
3.4	Folds compartilhados	35
3.5	Arquiteturas GNN e hiperparâmetros	35
3.6	<i>Baselines</i> não-GNN	37
3.7	Protocolo de avaliação	37
3.8	Análise estratificada do erro	38
3.9	Análise de explicabilidade	39
3.10	Classificador dual: regra de combinação <i>post-hoc</i>	39
3.11	Reprodutibilidade	39
4	Resultados Experimentais	41
4.1	<i>Baselines</i> textuais sobre BERT da raiz	42
4.2	Diagnóstico de <i>confound</i> topológico	43
4.3	Cross-dataset UPFD: nossos resultados <i>versus</i> literatura	44
4.4	Topologia sem texto: o achado central (RQ3, parte a)	45
4.5	Consistência de <i>score</i> topológico entre idiomas (RQ3, parte b)	47
4.6	Por que GossipCop funciona e PolitiFact não? (RQ2)	49
4.7	Concordância textual $\times$ topológico (RQ1)	51
4.8	GNNEExplainer: o que o SAGE aprendeu	53
4.9	Análise estratificada do erro	55
4.9.1	Distribuição estrutural: <i>heavy-tail</i> mais agressivo que lognormal	55
4.9.2	LOWESS: onde o modelo degrada	56
4.9.3	Outliers e a inversão distributiva	58
4.9.4	Cascatas profundas: o ganho cresce com a profundidade	60
4.10	Painel mestre dos achados	63
5	Discussão e Conclusão	65
5.1	Síntese dos achados por pergunta de pesquisa	65
5.2	Achado negativo é achado	66
5.3	Limitações	67
5.4	Trabalhos futuros	68
5.5	Considerações finais	69

A	Hiperparâmetros completos	77
A.1	Arquiteturas GNN	78
A.2	Classificadores <i>baseline</i>	79
A.3	Protocolo de avaliação estatística	80
A.4	Construção do FakeNewsNet	80
A.5	Ambiente de execução	81
B	Índice geral de figuras e tabelas	82
B.1	Tabelas	83
B.2	Figuras	85
B.3	<i>Scripts</i> de geração	86
C	Estrutura do repositório de código	87
C.1	Training/ — <i>scripts</i> experimentais	87
C.2	Execution/ — artefatos persistidos	88
C.3	Material/ — <i>datasets</i> e o TCC	88
C.4	Interface/ — aplicação web demonstrativa	89
C.5	Documentos de controle (raiz do repositório)	89
C.6	Reprodução integral do <i>pipeline</i>	90
D	Aplicação demonstrativa: Bluesky e ferramenta web	91
D.1	O <i>dataset</i> Bluesky	91
D.2	Inferência <i>cross-domain</i> dos modelos persistidos	91
D.3	Concordância textual $\times$ topológico	93
D.4	Ferramenta web	93

Capítulo 1

Introdução

1.1 Contextualização

A circulação de desinformação em redes sociais constitui um problema epistêmico real, com consequências documentadas que vão da erosão de confiança em instituições públicas [Hussain et al. 2025, Arias-Mendoza, González-Pardo e Cortés-Peña 2023] a danos físicos diretos. A pandemia de COVID-19 ofereceu casos paradigmáticos do fenômeno: no Brasil, “remédios milagrosos” sem respaldo científico foram promovidos em larga escala; nos Estados Unidos, relatório dos *Centers for Disease Control and Prevention* documentou que parcela substancial de adultos entrevistados aderiu a práticas de risco (uso inadequado de desinfetantes e alvejantes como proteção contra o vírus) motivada por narrativas falsas [Gharpure et al. 2020]. O padrão subjacente a esses episódios não é fortuito: estudos quantitativos sobre redes sociais reportam diferenças sistemáticas na dinâmica de difusão entre conteúdo falso e verdadeiro (desde o alcance bruto até a velocidade média de propagação [Vosoughi, Roy e Aral 2018]), diferenças que se explicam, em parte, pelos algoritmos das plataformas, que amplificam conteúdo de alta interação independentemente de sua veracidade [Bakshy, Messing e Adamic 2015], e em parte pelo viés de confirmação do leitor, reforçado por *echo chambers*, que torna o compartilhamento mais rápido que a verificação [Vicario et al. 2016].

A escala em que esses fenômenos ocorrem inviabiliza a verificação manual. O volume de postagens em redes sociais opera em regime de *Big Data*, com fluxos massivos em tempo real; produzir uma mentira é instantâneo, desmenti-la é lento e custoso. Modelos computacionais de detecção tornam-se, portanto, não um acessório, mas uma necessidade. A abordagem tradicional, baseada em Processamento de Linguagem Natural (PLN), tem limites bem estabelecidos: depende da qualidade textual dos exemplos rotulados, falha diante de textos com alta sofisticação linguística [Hu, Mao e Zhang 2025, Roumeliotis, Tselikas e Nasiopoulos 2025], e (a limitação estruturalmente mais importante) é atravessada pela ascensão recente de modelos generativos

de língua natural que apagam, no plano linguístico de superfície, a fronteira entre texto humano e texto sintetizado [Yi et al. 2025]. É plausível, embora ainda não demonstrado em larga escala, que a detecção baseada *exclusivamente* no texto perca robustez à medida que essa fronteira se desfaz.

1.2 Motivação

Uma linha alternativa de pesquisa observa que a desinformação não se distingue apenas pelo conteúdo, mas também pelo *padrão com que se espalha pela rede*: quem compartilha o quê, para quem, e em qual ordem temporal. Essa observação deu origem à aplicação de Redes Neurais de Grafos (*Graph Neural Networks*, GNNs) ao problema, partindo de Monti et al. [Monti et al. 2019] e consolidando-se em uma família de trabalhos que tratam a árvore de propagação como objeto classificável [Dou et al. 2021, Bian et al. 2020, Hu et al. 2025, Phan, Nguyen e Hwang 2023]. O ganho conceitual é claro: o sinal estrutural não depende do idioma do texto, não é degradado por paráfrase ou sinônimo, e em princípio resiste a textos gerados por LLM, desde que a topologia da propagação, ela mesma, preserve diferenças discrimináveis entre conteúdo falso e verdadeiro.

Sob quais condições essa premissa se sustenta é uma pergunta menos respondida do que parece. A literatura tende a reportar resultados positivos em *datasets* específicos; reporta parcialmente os casos em que o paradigma *não* funciona; e oferece poucos critérios mensuráveis, a priori, sobre quando empregar arquiteturas topológicas e quando recorrer ao texto. É nesse vazio que o presente trabalho se posiciona: **caracterizar as condições estruturais sob as quais o paradigma topológico é aplicável**, com igual peso evidencial para os resultados positivos e negativos observados.

A Figura 1.1 ilustra, em alto nível, o caminho percorrido por uma notícia candidata desde a sua entrada até o *score* final produzido pelos modelos persistidos pelo trabalho: o texto é codificado por Sentence-BERT, a árvore de propagação fornece *features* estruturais, e os dois caminhos convergem na regra dual derivada *post-hoc* dos experimentos (formalizada em §4.7).




Figura 1.1: Caminho percorrido por uma notícia candidata pelos modelos persistidos do trabalho. Em azul, a entrada bruta (título e árvore de propagação); em laranja e verde, os dois encoders independentes (*embedding* textual e *features* estruturais); em violeta, os classificadores treinados que produzem dois *scores* (s_T , s_K); a regra dual (em amarelo) decide se os dois concordam e atribui pesos 0,5/0,5 ou 0,8/0,2 ao combinar (§4.7); o *score* final é acompanhado de uma *flag* de concordância que sinaliza confiança do par.

1.3 Perguntas de pesquisa

O trabalho organiza-se em torno de três perguntas de pesquisa, respondidas no Capítulo 4:

- RQ1.** A topologia da propagação carrega sinal discriminante para detecção de fake news *acima* do que a *feature* textual da raiz da árvore de propagação (*embedding* BERT) já fornece?
- RQ2.** Caso a resposta a RQ1 dependa do domínio, *sob quais condições estruturais* o paradigma topológico é efetivo? Operacionalizamos essa pergunta através do tamanho de efeito de Cohen [Cohen 1988] entre as classes *fake* e *real* em métricas de cascata.
- RQ3.** É viável detectar fake news *apenas* pela topologia, em cenários onde o texto não é explorável? A pergunta é composta de duas partes: (a) experimento sem acesso algum a texto em UPFD-GossipCop; (b) experimento de consistência da distribuição do *score* estrutural entre idiomas no *snapshot* acadêmico do Bluesky [Failla e Rossetti 2024, Kleppmann et al. 2024].

1.4 Contribuições

Apresentamos quatro contribuições, em ordem decrescente de importância:

- (a) **Ablation sistemática de codificações posicionais contra a degeneração do GCN.** Demonstramos, com prova matemática em §2.5 e ablation em §4.4, que a GCN clássica [Kipf e Welling 2017] degenera quando alimentada com *features* nodais homogêneas, e caracterizamos quais combinações de codificações posicionais nodais (*is_root*, *grau_norm*, *pos*) recuperam capacidade discriminativa em cada *dataset*.

- (b) **Diagnóstico bilateral da aplicabilidade topológica.** Mostramos, em protocolo de *k-fold* pareado validado por teste *t* pareado e tamanho de efeito de Cohen, que o paradigma topológico *funciona* em UPFD-GossipCop (GraphSAGE estrutural atinge $F1 = 0,810 \pm 0,002$ *sem usar texto algum*) e *colapsa* em UPFD-PolitiFact (a mesma arquitetura alcança $F1 \approx 0,33$, abaixo da chance). A explicação estrutural do contraste, derivada *a priori* a partir do Cohen’s *d* entre as classes (§4.6), sustenta a tese central do trabalho — *modelos topológicos exigem diferença estrutural entre classes da ordem de $|d| \geq 0,5$ em pelo menos uma métrica de cascata para serem efetivos* — formulada de maneira deliberadamente *falsificável*.
- (c) **Análise de concordância textual-topológico e regra dual derivada *post-hoc*.** Caracterizamos numericamente os subgrupos em que o classificador estrutural *inverte* sistematicamente sua predição em relação ao textual (subgrupos `real_viral` e `fake_contido` da §4.9.3) e derivamos, a partir dessa caracterização, uma regra de combinação com pesos assimétricos — registrada explicitamente como heurística *post-hoc*, não como decisão metodológica *a priori* (§4.7).
- (d) **Pesos persistidos no Hugging Face Hub e aplicação demonstrativa.** Os três classificadores (LogReg-BERT, RF estrutural, SAGE estrutural) estão publicados sob licença CC-BY-4.0 no Hugging Face Hub, junto com uma aplicação web (FastAPI + Next.js) que integra texto e topologia através da regra dual da contribuição (c). A aplicação foi exercitada em *snapshot* acadêmico do Bluesky em modo demonstrativo (sem rótulos) e está documentada no Apêndice D.

É pertinente registrar o que este trabalho *não* propõe. Não há aqui uma nova arquitetura de Rede Neural de Grafos, nem proposta de *benchmark* novo. A contribuição primária é diagnóstica: um critério mensurável para decidir, *antes de treinar*, se topologia tem chance de funcionar em um domínio dado.

1.5 Estrutura do trabalho

O Capítulo 2 apresenta a fundamentação teórica: arquiteturas GNN avaliadas (GCN, GAT, GraphSAGE), *embeddings* textuais via Sentence-BERT, prova da degeneração do GCN com *features* homogêneas, e revisão de trabalhos relacionados em detecção multilíngue e em GNNs para fake news. O Capítulo 3 descreve o *pipeline* experimental: construção dos grafos a partir dos três *datasets* rotulados (FakeNewsNet, UPFD-PolitiFact, UPFD-GossipCop), hiperparâmetros das arquiteturas e protocolo de validação com *k-fold* pareado, *ttest_rel* e Cohen’s *d*.

O Capítulo 4 apresenta os resultados em ordem narrativa: *baselines* textuais, diagnóstico de *confound*, calibração com a literatura, achado central (topologia sem texto),

explicação estrutural via Cohen's d , análise de concordância, GNNExplainer, e análise estratificada do erro (distribuição *heavy-tail*, LOWESS, *outliers* e cascatas profundas). O Capítulo 5 sintetiza os achados, discute o resultado negativo de UPFD-PolitiFact com a mesma extensão do positivo, enumera limitações do trabalho e aponta quatro direções de continuidade. O Apêndice D documenta a aplicação demonstrativa sobre o Bluesky e a ferramenta web.

Capítulo 2

Fundamentação Teórica

2.1 Detecção de fake news: panorama

Fake news é termo de uso amplo cuja definição acadêmica está longe de ser consensual. A revisão sistemática de Tandoc et al. [Jr., Lim e Ling 2018] catalogou seis acepções distintas em uso na literatura (sátira, paródia, fabricação, manipulação, propaganda e publicidade disfarçada de notícia) organizadas em duas dimensões: *facticidade* (quão verificável é o conteúdo) e *intenção de enganar* (quão deliberada é a falsidade). Para fins deste trabalho, adotamos como foco a categoria de *fabricação* (conteúdo apresentado sob forma jornalística que é factualmente falso e cuja intenção é enganar), modalidade que também concentra a atenção da literatura computacional de detecção [Hu, Mao e Zhang 2025, Hussain et al. 2025]. A delimitação importa porque exclui do escopo sátira e paródia, cuja detecção envolve modelagem de intenção pragmática para além do conteúdo proposicional.

A relevância social do problema é bem documentada empiricamente. Allcott e Gentzkow [Allcott e Gentzkow 2017] estimaram que, nos três meses anteriores à eleição presidencial estadunidense de 2016, histórias falsas pró-Trump foram compartilhadas 30 milhões de vezes no Facebook contra 8 milhões das pró-Clinton, e Vosoughi, Roy e Aral [Vosoughi, Roy e Aral 2018] demonstraram, em amostra de ~ 126 mil histórias do Twitter, que notícias falsas se propagam de forma estatisticamente mais ampla, mais rápida e mais profunda do que verdadeiras, com efeito mais pronunciado em notícias políticas. Essa assimetria observável *na propagação* é o que sustenta, ao final, o uso de modelos estruturais para detecção.

A literatura computacional de detecção subdivide-se em três abordagens. A primeira, *baseada em conteúdo*, recupera *features* textuais (lexêmicas, sintáticas, semânticas) e treina classificadores supervisionados sobre elas [Hu, Mao e Zhang 2025, Roumeliotis, Tselikas e Nasiopoulos]. É a abordagem dominante na prática, mas perde robustez frente a textos sofisticados, em particular agora que modelos generativos são capazes de produzir prosa gramaticalmente impecável em escala industrial [Yi et al. 2025]. A segunda, *baseada em contexto*

social (perfil do publicador, histórico de credibilidade, rede de seguidores), opera sobre metadados e em muitos cenários não está disponível ou é legalmente restrito. A terceira, *baseada em propagação*, modela diretamente a topologia com que a notícia se espalha pela rede: é essa terceira linha que motiva o uso de Redes Neurais de Grafos (GNNs) [Monti et al. 2019, Dou et al. 2021, Phan, Nguyen e Hwang 2023].

Trabalhos recentes convergem para a hipótese de que *nenhuma das três abordagens isoladas é robusta*, e que estratégias *híbridas* (combinando texto e topologia, ou texto e contexto social) tendem a superar variantes puras [Hu et al. 2025, Jadhav et al. 2025]. O diagnóstico de complementaridade abre uma questão operacional — *quando* cada componente do híbrido carrega sinal informativo? — que formalizamos por meio do critério mensurável apresentado no Capítulo 4, §4.6.

2.2 Grafos e redes sociais

Um *grafo* é um par ordenado $G = (V, E)$ em que V é um conjunto de *vértices* (ou *nós*) e $E \subseteq V \times V$ é um conjunto de *arestas*. Quando as arestas são orientadas, isto é, quando o par $(u, v) \in E$ é distinto do par (v, u) , o grafo é dito *dirigido*. O *grau* de um vértice v , denotado $\deg(v)$, é o número de arestas incidentes a ele; em grafos dirigidos, distinguem-se *grau de entrada* e *grau de saída*. Esses conceitos básicos são formalizados, com a generalidade requerida pela aplicação a redes complexas, em [Newman 2003].

Uma *cascata de propagação* em rede social é uma classe particular de grafo dirigido, em geral com forma de árvore enraizada: o nó raiz representa a publicação original (*post*, *tweet*); cada nó-filho representa uma interação subsequente (*repost*, *retweet*, *reply*); cada aresta representa a relação de filiação causal entre uma interação e a publicação que a originou. As métricas estruturais que descrevem essa árvore, e que servem de *features* estruturais ao classificador topológico discutido em capítulos posteriores, são:

- **num_nodes** (número total de vértices, incluindo a raiz): proxy do alcance bruto da publicação;
- **depth_max** (profundidade máxima da árvore): número máximo de arestas em qualquer caminho da raiz a uma folha; mede o quão longe a propagação se estendeu por cadeias sucessivas de recompartilhamentos;
- **width_max** (largura máxima): número máximo de vértices em qualquer nível da árvore;
- **branching_avg** (ramificação média): número médio de filhos por nó não-folha, fornecendo um índice da *viralidade lateral* típica em cada nível.




Figura 2.1: Exemplos reais de árvores de propagação extraídos dos conjuntos UPFD PolitiFact (linha superior) e GossipCop (linha inferior). O nó raiz (mais escuro) representa a publicação original; os demais nós representam interações subsequentes (reposts, respostas). Em ambos os datasets, exemplos falsos (vermelho) e verdadeiros (azul) apresentam estruturas superficialmente similares em tamanho — evidenciando que o número de nós isolado não é discriminante, motivação central para o uso de GNNs neste trabalho.

Redes sociais reais apresentam padrões estruturais que as distinguem de grafos aleatórios clássicos. Watts e Strogatz [Watts e Strogatz 1998] demonstraram empiricamente o fenômeno *small-world* (coexistência de alto agrupamento local com curtos caminhos médios entre vértices arbitrários), e Barabási e Albert [Barabási e Albert 1999] introduziram o modelo de *anexação preferencial* (*preferential attachment*) que reproduz distribuições de grau seguindo lei de potência, típicas de redes sociais. A consequência prática para este

trabalho é que as distribuições de `num_nodes`, `depth_max` e `branching_avg` medidas sobre cascatas reais serão *heavy-tail* (cauda pesada), o que justificará o uso de percentis empíricos em vez de *z-scores* na definição de subgrupos de análise [Clauset, Shalizi e Newman 2009] (§3.8).

2.3 Embeddings textuais

Word embeddings são representações vetoriais densas de unidades linguísticas que codificam, em uma dimensão moderada, relações semânticas e sintáticas aprendidas a partir de grandes corpora. O paradigma foi popularizado por Mikolov et al. [Mikolov et al. 2013] com o modelo *word2vec*: treinado para prever palavras a partir de contextos vizinhos (ou vice-versa), o modelo aprende vetores em que pares de palavras semanticamente próximas ocupam regiões próximas do espaço latente. A limitação do paradigma *word2vec* é a representação *estática*: cada palavra recebe um único vetor independentemente do contexto em que aparece, o que apaga a distinção entre *sentidos* múltiplos de uma mesma forma de superfície.

Essa limitação foi superada pela arquitetura *Transformer* de Vaswani et al. [Vaswani et al. 2017] e por seu sucessor mais amplamente adotado em PLN, o *BERT* (*Bidirectional Encoder Representations from Transformers*) de Devlin et al. [Devlin et al. 2019]. O BERT produz representações vetoriais *contextuais*: o mesmo *token* recebe vetores distintos em contextos distintos, o que captura desambiguação lexical e estrutura sintática. O treinamento usa objetivos de *masked language modeling* e *next sentence prediction* sobre corpora massivos, e o resultado é um codificador de propósito geral que pode ser *fine-tuned* para tarefas específicas.

Para o problema de classificação de *sentenças inteiras*, contudo, o BERT padrão é ineficiente: produz um vetor por *token*, e a tradição de derivar um vetor de sentença via média dos *tokens* ou via vetor do *token* de *classification head* produz representações de qualidade inferior às do estado da arte para tarefas de similaridade semântica [Reimers e Gurevych 2019]. Reimers e Gurevych propuseram, então, o *Sentence-BERT* (SBERT) [Reimers e Gurevych 2019], que adapta o BERT via *fine-tuning* em arquitetura *siamesa* com objetivo contrastivo sobre pares de sentenças: o vetor de sentença resultante codifica similaridade semântica diretamente em distância no espaço vetorial.

Para detecção multilíngue, a questão adicional é como obter representações consistentes em idiomas distintos sem treinar um modelo por idioma. A solução adotada neste trabalho é o modelo `paraphrase-multilingual-mpnet-base-v2`, que estende o SBERT a 50+ idiomas via destilação de conhecimento entre línguas [Reimers e Gurevych 2020]: o modelo *aluno* multilíngue é treinado para reproduzir, em qualquer idioma, os vetores que o *professor* monolíngue produziria a partir das traduções correspondentes. O resultado é um espaço vetorial em que paráfrases de uma mesma sentença em português, inglês e

alemão ocupam pontos próximos, propriedade que sustenta o experimento de RQ3, parte (b) (§4.5). O vetor de saída é de 768 dimensões; sua adaptação ao *pipeline* de construção de grafos é descrita em §3.3.

2.4 Redes Neurais de Grafos

Redes Neurais Convolucionais e Redes Neurais Recorrentes operam, respectivamente, sobre domínios euclidianos com grade regular (imagens) e sequências ordenadas (texto). A maioria dos dados estruturados que importam para problemas práticos (redes sociais, moléculas, redes de citação, malhas de superfície) vive em domínios não-euclidianos onde *não* há ordenação canônica entre vizinhos nem grade regular. *Geometric Deep Learning* [Bronstein et al. 2017] é o termo abrangente que designa a família de técnicas projetadas para esses domínios; as *Graph Neural Networks* (GNNs) constituem a sub-família particular para grafos.

Toda GNN pode ser descrita através do paradigma *message passing*: a cada camada, cada nó recebe “mensagens” computadas a partir de seus vizinhos, agrega essas mensagens em um único vetor e atualiza sua própria representação com base nessa agregação. Formalmente, denotando por $h_v^{(l)}$ a representação do nó v na camada l e por $\mathcal{N}(v)$ sua vizinhança, a operação é

$$h_v^{(l+1)} = \text{UPDATE}\left(h_v^{(l)}, \text{AGGREGATE}\left(\{h_u^{(l)} : u \in \mathcal{N}(v)\}\right)\right), \quad (2.1)$$

onde AGGREGATE deve ser *permutação-invariante* (soma, média, máximo) para que a saída não dependa da ordem arbitrária de enumeração dos vizinhos. As arquiteturas avaliadas neste trabalho (GCN, GAT e GraphSAGE) diferem precisamente na escolha das funções AGGREGATE e UPDATE. A expressividade comparada da família foi formalmente caracterizada por Xu et al. [Xu et al. 2019], que mostraram que GNNs com agregação injetiva (soma em vez de média) atingem o limite teórico equivalente ao teste de isomorfismo de Weisfeiler-Lehman, e que agregações por média ou máximo são estritamente menos expressivas. Como discutiremos em §4.6, essa diferença teórica não se converte em vantagem prática neste trabalho: o sinal que distingue *fake* de *real* no nosso domínio está em estatísticas globais da cascata (`num_nodes`, *branching factor*), às quais a média tem acesso suficiente. Todas as três arquiteturas são implementadas via *PyTorch Geometric* [Fey e Lenssen 2019], biblioteca de referência para GNNs no ecossistema PyTorch.

2.4.1 Graph Convolutional Networks (GCN)

A GCN de Kipf e Welling [Kipf e Welling 2017] aproxima a convolução espectral em grafos por uma expansão de primeira ordem, e é a arquitetura que popularizou o paradigma

message passing sob a sua forma matricial. Sua regra de propagação por camada é

$$H^{(l+1)} = \sigma\left(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} H^{(l)} W^{(l)}\right), \quad (2.2)$$

onde $\hat{A} = A + I$ é a matriz de adjacência com auto-loops adicionados, $\hat{D}$ é sua matriz diagonal de graus ($\hat{D}_{ii} = \sum_j \hat{A}_{ij}$), $H^{(l)} \in \mathbb{R}^{N \times d_l}$ é a matriz de representações dos N nós na camada l , $W^{(l)} \in \mathbb{R}^{d_l \times d_{l+1}}$ é a matriz de pesos treinados, e σ é uma não-linearidade (ReLU neste trabalho). A normalização simétrica $\hat{D}^{-1/2} \hat{A} \hat{D}^{-1/2}$ controla o crescimento das normas das ativações ao longo das camadas, evitando explosão numérica, e o AGGREGATE resultante é uma média ponderada pelos graus dos vizinhos.

Custo computacional: o produto $\hat{A}H^{(l)}$ é linear em $|E|$ (número de arestas), uma vez que a matriz $\hat{A}$ é esparsa. Para as árvores de propagação deste trabalho, com $|V| \leq 100$ nós no FakeNewsNet (cap explicitado em §3.3) e ordens de algumas dezenas em UPFD em geral, o *forward* de uma camada é dominado pela multiplicação densa $H^{(l)}W^{(l)}$ e roda em milissegundos em CPU. A arquitetura tem, contudo, uma limitação estrutural que será explorada em §2.5: quando todos os nós de um grafo recebem o mesmo vetor de *features* de entrada, a GCN colapsa para uma função apenas do grau.




Figura 2.2: Arquitetura da GCN utilizada neste trabalho: três camadas GCNConv ($768 \rightarrow 64$, $64 \rightarrow 64$, $64 \rightarrow 64$) com ativação ReLU, seguidas de Global Mean Pool, Dropout (0,5) e classificador linear ($64 \rightarrow 2$).

2.4.2 Graph Attention Networks (GAT)

A GAT de Veličković et al. [Veličković et al. 2018] substitui o peso fixo $1/\sqrt{\hat{D}_{ii}\hat{D}_{jj}}$ da GCN por um peso *aprendido* entre cada par de nós vizinhos. O coeficiente de atenção α_{ij}

entre o nó i e um vizinho $j \in \mathcal{N}(i)$ é dado por

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(\mathbf{a}^T [Wh_i \parallel Wh_j]))}{\sum_{k \in \mathcal{N}(i)} \exp(\text{LeakyReLU}(\mathbf{a}^T [Wh_i \parallel Wh_k]))}, \quad (2.3)$$

onde $\parallel$ denota concatenação e $\mathbf{a}$ é um vetor de parâmetros treinados. A representação atualizada é então $h_i^{(l+1)} = \sigma(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} Wh_j)$. Em prática, o mecanismo de atenção é replicado em K cabeças independentes (*multi-head attention*, análoga ao Transformer [Vaswani et al. 2017]), e os resultados são concatenados ou médiados. Neste trabalho utilizamos $K = 4$ cabeças e a concatenação nas camadas intermediárias.

Conceitualmente, a atenção permite à GAT atribuir pesos distintos a vizinhos distintos *em função do conteúdo deles*, não apenas em função do seu grau no grafo. Para o problema deste trabalho, essa flexibilidade adicional não se traduz em ganho consistente sobre a GCN (§4.3): em árvores rasas e estreitas, a maior parte da informação encontra-se no grau do nó raiz, número que a GCN extrai tão bem quanto a GAT.




Figura 2.3: Arquitetura da GAT utilizada neste trabalho: três camadas GATConv com atenção *softmax* multi-cabeça (camadas 1 e 2: 4 cabeças, concat=False; camada 3: 1 cabeça), seguidas de Global Mean Pool, Dropout (0,5) e classificador linear (64→2).

2.4.3 GraphSAGE

A GraphSAGE de Hamilton, Ying e Leskovec [Hamilton, Ying e Leskovec 2017] foi originalmente proposta para o regime *indutivo*, em que o modelo treinado em um grafo deve generalizar a vértices ou grafos nunca vistos. A intuição chave é que o AGGREGATE deve operar sobre uma *amostra* fixa dos vizinhos, não sobre a vizinhança inteira, o que torna o custo por camada constante em relação ao grau do nó. A regra de propagação na

variante *mean* (a usada neste trabalho) é

$$h_v^{(l+1)} = \sigma\left(W^{(l)} \cdot \text{CONCAT}\left(h_v^{(l)}, \text{MEAN}\left(\{h_u^{(l)} : u \in \mathcal{S}(v)\}\right)\right)\right), \quad (2.4)$$

onde $\mathcal{S}(v) \subseteq \mathcal{N}(v)$ é um conjunto amostrado da vizinhança. Diferentemente da GCN, que mistura indissociavelmente a representação do próprio nó com a média das dos vizinhos, a GraphSAGE *concatena* as duas antes de aplicar a transformação linear $W^{(l)}$, o que preserva separadamente o sinal nodal e o sinal de vizinhança.

Em redes pequenas como as árvores de propagação deste trabalho, a vantagem indutiva original não se manifesta (todos os grafos cabem em memória e não há custo de amostragem a economizar), mas a distinção arquitetural, a concatenação em vez de mistura, é o que torna a GraphSAGE particularmente apta a explorar sinal estrutural quando esse sinal está concentrado em um único nó (a raiz da árvore). É essa propriedade que explica seu desempenho superior em UPFD-GossipCop sem texto (§4.4).




Figura 2.4: Arquitetura da GraphSAGE utilizada neste trabalho: três camadas SAGEConv com agregação por média ($W_l \cdot h + W_r \cdot h_N$, indutivo), seguidas de Global Mean Pool, Dropout (0,5) e classificador linear (64→2).

2.5 Degeneração do GCN com *features* homogêneas

A regra de propagação da GCN (Equação 2.2) é um operador linear sobre $H^{(l)}$ seguido por uma não-linearidade. Quando *todos* os nós do grafo recebem o mesmo vetor de *features* de entrada (caso degenerado mas não patológico em aplicações práticas, em particular naquelas em que o vetor nodal é replicado a partir de um único atributo global da instância), a primeira camada da GCN se reduz a uma função apenas do grau de cada nó. A demonstração é simples e o resultado tem implicação direta sobre o desenho de

features para cascatas de propagação.

Seja $X \in \mathbb{R}^{N \times d}$ a matriz de *features* de entrada, e suponha que todas as linhas são idênticas: $X_i = x^T \in \mathbb{R}^d$ para todo $i = 1, \dots, N$. Então X pode ser escrita como $X = \mathbf{1}_N x^T$, onde $\mathbf{1}_N \in \mathbb{R}^N$ é o vetor coluna de *uns*. Substituindo na regra de propagação (definindo $\tilde{A} \equiv \hat{D}^{-1/2} \hat{A} \hat{D}^{-1/2}$ por brevidade):

$$\begin{aligned} H^{(1)} &= \sigma(\tilde{A} X W) \\ &= \sigma(\tilde{A} \mathbf{1}_N x^T W) \\ &= \sigma((\tilde{A} \mathbf{1}_N)(x^T W)). \end{aligned} \tag{2.5}$$

O termo $\tilde{A} \mathbf{1}_N$ é um vetor coluna em $\mathbb{R}^N$ cujo i -ésimo componente é $\sum_j \tilde{A}_{ij} = \sum_j \hat{A}_{ij} / \sqrt{\hat{D}_{ii} \hat{D}_{jj}}$, isto é, uma função apenas dos graus de i e de seus vizinhos. O termo $x^T W \in \mathbb{R}^{d_{l+1}}$ é um vetor *fixo*, idêntico para todos os nós. A linha i de $H^{(1)}$, portanto, é um *múltiplo escalar* do mesmo vetor $x^T W$, com o escalar sendo função apenas do grau do nó.

Em palavras: a primeira camada da GCN reduz-se a uma função do grau no $\mathbb{R}^{d_{l+1}}$ que mapeia cada *valor de grau* a um *único* vetor de saída. *Nós distintos com o mesmo grau ficam indistinguíveis pela GCN*, e o classificador final não tem informação sobre qual nó discrimina como qual classe. Em seguida, ao agregar os vetores nodais via *global mean pool*, o classificador de grafo recebe uma média dos múltiplos escalares $\tilde{A} \mathbf{1}_N$ vezes o mesmo $x^T W$: grafos cuja *distribuição de grau* é similar produzem representações muito próximas, e a discriminação entre eles resta condicionada a essas estatísticas de grau, informação muito empobrecida em relação à estrutura completa da árvore. O fenômeno é parente do *oversmoothing* caracterizado por Li, Han e Wu [Li, Han e Wu 2018] para GCNs profundas, mas ocorre desde a *primeira* camada e é estrutural, não consequência da profundidade.

A implicação metodológica é direta: para que a GCN seja funcional sobre cascatas de propagação em que a *feature* nodal natural é o *embedding* BERT do título da notícia (idêntico para todos os nós de um mesmo grafo, por construção), é necessário *adicionar features* posicionais que tornem os nós distinguíveis, *features* detalhadas a seguir, em §2.6, e cuja necessidade empiricamente confirmada é o objeto de §4.4.

2.6 Codificações posicionais

Para quebrar a degeneração da §2.5, basta distinguir os nós entre si em alguma dimensão adicional ao *embedding* BERT comum. Adotamos três codificações posicionais nodais, todas calculadas determinísticamente a partir da estrutura do grafo, em linha com a estratégia de *topological features* reportada na literatura [Xu 2025]:

is_root $\in \{0, 1\}$. Vale 1 se o nó é a raiz da árvore de propagação, 0 caso contrário. É a codificação mínima que quebra a degeneração da GCN: basta um único nó ter

feature distinta para que a primeira camada da Equação 2.5 produza ao menos dois vetores nodais distintos.

grau_norm $\in [0, 1]$. Codifica a magnitude do entorno do nó em uma faixa fixa, evitando que cascatas de tamanhos muito diferentes contaminem a generalização. A definição adotada varia conforme a construção do grafo no *pipeline*: para *features* topológicas puras em UPFD (§4.4), usa-se $\deg(v)/\deg_{\max}^{(G)}$, onde $\deg_{\max}^{(G)}$ é o grau máximo *daquela* grafo, de modo que a magnitude resultante seja invariante à escala absoluta da cascata; para grafos do FakeNewsNet, que são em estrela rasa por construção (§3.3), o valor codificado é $N/N_{\max}^{\text{global}}$ na raiz (com 0 nos filhos), onde N é o número de nós do grafo e $N_{\max}^{\text{global}} = 100$ é o cap aplicado. Em ambos os casos, a *feature* captura a magnitude relativa da cascata que virá a ser explorada pelas camadas seguintes da GNN.

pos $\in [0, 1]$. Definido pela ordem de visitação em *busca em largura* (*breadth-first search*, BFS) a partir da raiz, normalizada pelo número total de nós do grafo. Codifica a posição *temporal* aproximada do nó na cascata, sob o pressuposto de que *reposts* próximos da raiz na BFS são tipicamente mais antigos do que folhas distantes. Quando combinada com **is_root**, distingue nós que estão na mesma profundidade mas em ramos distintos da árvore.

As três codificações são ortogonais em sentido informativo: **is_root** captura *onde é a raiz*, **grau_norm** captura *quão ramificado é o entorno do nó*, e **pos** captura *quão perto da raiz o nó foi adicionado*. A combinação das três produz o vetor de 771 dimensões (*embedding* BERT de 768 + 3 codificações posicionais) descrito no Capítulo 3.

A *ablation* sistemática de quais subconjuntos dessas codificações são necessários para recuperar performance após a degeneração é o objeto experimental de §4.4, e responde formalmente à parte (a) da RQ3: em UPFD-GossipCop, basta [**is_root**, **grau_norm**] (apenas *duas* dimensões estruturais por nó, sem nenhum texto) para que o GraphSAGE atinja $F1 = 0,810$. A codificação **pos** é necessária apenas para a GCN, que sem ela permanece sujeita à degeneração em grafos com múltiplos nós de mesmo grau na mesma profundidade.

2.7 Explicabilidade em GNNs: GNNExplainer

A explicabilidade em redes neurais profundas é uma questão de pesquisa ativa, e em GNNs adquire particularidade adicional: o objeto sobre o qual o modelo opera, o grafo, tem dimensionalidade variável entre instâncias, e as técnicas clássicas desenvolvidas para imagens (*saliency maps*) ou texto (*attention rollout*) não se transferem diretamente. A literatura tem produzido uma família crescente de métodos específicos para GNNs, sintetizados na revisão taxonômica de Yuan et al. [Yuan et al. 2023].

Adotamos neste trabalho o *GNNE explainer* de Ying et al. [Ying et al. 2019], o método de referência da família *baseada em máscaras*. Dada uma predição específica do modelo sobre uma instância (no nosso caso, sobre um grafo de propagação), o objetivo é identificar o *subconjunto mínimo* de arestas e de *features* nodais que, isoladamente, preservaria essa predição. O método aprende duas máscaras contínuas, $M_E \in [0, 1]^{|E|}$ sobre as arestas e $M_F \in [0, 1]^d$ sobre as dimensões das *features* nodais, otimizando o objetivo

$$\max_{M_E, M_F} \text{MI}(Y, \text{GNN}(G \odot M_E, X \odot M_F)) - \lambda(\|M_E\|_1 + \|M_F\|_1), \quad (2.6)$$

onde Y é a predição original, $G \odot M_E$ denota o grafo ponderado pelas máscaras, MI é a informação mútua, e λ controla a esparsidade. A primeira parcela incentiva a máscara a preservar a predição; a segunda penaliza inclusões desnecessárias. Em prática, o problema é resolvido por *gradient descent* sobre os logits das máscaras parametrizadas via sigmoide.

A implementação adotada usa o módulo `torch_geometric.explain.Explainer` com algoritmo `GNNEExplainer(epochs=200)` e `edge_mask_type="object"`, com a tarefa configurada como classificação de grafo multiclasse. Aplicado sobre o classificador SAGE estrutural treinado em UPFD-GossipCop (§4.8), o método revela uma assimetria de importância espacial entre *fake* e *real* que constitui interpretação mecanicista do achado central.

2.8 Validação estatística

A comparação rigorosa entre métodos de classificação exige um protocolo estatístico explícito que considere variação entre execuções (entre *folds* de validação, entre *seeds* de inicialização) e magnitude prática das diferenças observadas (não apenas a sua significância formal). Adotamos quatro instrumentos complementares, cujas convenções seguem recomendações consolidadas na literatura de *benchmarking* em aprendizado de máquina [Demšar 2006].

Validação cruzada estratificada de k folds. O *dataset* é particionado em k subconjuntos disjuntos, preservando em cada um a proporção das classes; cada *fold* é então utilizado como conjunto de teste para um modelo treinado nos $k - 1$ restantes. A estimativa final da métrica é a média sobre os k *folds*. Kohavi [Kohavi 1995] recomenda $k = 10$ como compromisso entre viés e variância da estimativa em *datasets* de tamanho moderado, e essa é a escolha adotada em §3.4.

Teste t pareado (ttest_rel). Para comparar duas arquiteturas sobre o mesmo *dataset*, o teste t pareado recebe as k diferenças fold-a-fold ($\Delta_i = m_i^{(A)} - m_i^{(B)}$, onde $m^{(A)}$ é a métrica do modelo A) e testa a hipótese nula $H_0 : \mathbb{E}[\Delta] = 0$. O pareamento (isto é, exigir que ambos os modelos sejam avaliados sobre exatamente os mesmos *folds*) elimina a variação entre *folds* da estimação, recuperando poder estatístico em relação ao teste t

independente. É o instrumento principal adotado no protocolo da §3.7.

Tamanho de efeito de Cohen (d). Significância estatística não implica magnitude prática: com k ou n suficientemente grande, diferenças muito pequenas tornam-se “significantes”. Cohen [Cohen 1988] propôs, para complementar testes de hipótese, o tamanho de efeito padronizado $d = (\mu_A - \mu_B)/\sigma_p$, onde σ_p é o desvio-padrão combinado das duas amostras. A interpretação da Tabela 2.1 é a usual; Sawilowsky [Sawilowsky 2009] propôs refinamentos adicionais (efeito *muito grande* para $|d| \geq 1,2$, efeito *enorme* para $|d| \geq 2,0$) que não são utilizados neste trabalho.

Tabela 2.1: Interpretação de tamanho de efeito de Cohen (d).

$ d $	Interpretação
$< 0,2$	desprezível
$0,2 \leq d < 0,5$	pequeno
$0,5 \leq d < 0,8$	médio
$\geq 0,8$	grande

Bootstrap pareado. Quando o pareamento por *fold* não é possível (caso de *subsets* definidos *post-hoc* sobre um único conjunto de teste, como os recortes por profundidade da cascata em §4.9.4), o intervalo de confiança sobre a diferença Δ é estimado por *bootstrap pareado* [Efron e Tibshirani 1993]: a cada uma de n_{boot} reamostragens com reposição do *subset*, recalcula-se a diferença entre as métricas dos dois modelos sobre a amostra reamostrada, e o intervalo de confiança 95% é o intervalo entre o percentil 2,5 e o percentil 97,5 da distribuição resultante. Adotamos $n_{\text{boot}} = 2.000$ em todos os experimentos. Intervalos cujo limite inferior é estritamente positivo são interpretados como evidência de diferença real, com a magnitude lida da estimativa pontual.

2.9 Trabalhos relacionados

2.9.1 Surveys de GNNs em detecção de fake news

A aplicação de Redes Neurais de Grafos ao problema de detecção de fake news é suficientemente madura para que tenham surgido *surveys* dedicados. Phan, Nguyen e Hwang [Phan, Nguyen e Hwang 2023] revisam sistematicamente métodos baseados em GNN publicados na literatura entre 2018 e 2023, organizando-os em quatro famílias (baseados em postagem, em contexto social, em propagação e híbridos) e identificando como tendência consolidada a convergência para métodos híbridos que combinam texto e topologia. Uma revisão mais ampla, não restrita a GNNs, foi conduzida pelos autores de [Hu, Mao e Zhang 2025], que organiza o problema sob a perspectiva das três dimensões (conteúdo, contexto, propagação) já discutidas na §2.1. Ambos os *surveys* identificam, como lacuna recorrente, a ausência de *benchmarks* de aplicabilidade que indiquem *quando*

cada família funciona e quando colapsa, lacuna que motiva o diagnóstico proposto neste trabalho.

2.9.2 Métodos GNN canônicos para detecção

A peça inaugural da linha é o trabalho de Monti et al. [Monti et al. 2019], que tratou a detecção como classificação de grafo sobre cascatas de *retweet* no Twitter, usando uma combinação de convolução em grafo e *features* de usuário, e reportou desempenho competitivo com *baselines* textuais. A linha continuou com o BiGCN de Bian et al. [Bian et al. 2020], que opera bidirecionalmente sobre a árvore de propagação (*top-down* e *bottom-up*) e adiciona *features* de conteúdo de cada nó. Variantes posteriores, sintetizadas em [Hu et al. 2025], exploraram atenção, agregação temporal e codificações adicionais.

O *benchmark* de referência para a linha é o UPFD de Dou et al. [Dou et al. 2021], que organiza dois *datasets* originalmente publicados em formato CSV (FakeNewsNet-PolitiFact e FakeNewsNet-GossipCop, com curadoria de Shu et al. [Shu et al. 2020]) em formato de grafo padronizado, com quatro variantes de *features* nodais (**profile**, **spacy**, **content**, **bert**) e *splits* train/val/test fixos. Os três *datasets* sobre os quais este trabalho opera (nosso FakeNewsNet construído independentemente, e o UPFD nas duas variantes oficiais) são precisamente os que esses trabalhos consagram.

A nossa configuração foge da literatura em três pontos declarados, retomados em §4.3: utilizamos a *feature* **content** (310 dimensões) em vez de **bert** (768 dimensões) por restrição de memória CPU, adotamos hiperparâmetros próprios em vez dos reportados em [Dou et al. 2021], e reportamos F1-macro em vez de acurácia. A comparação numérica com os valores publicados é, por essas diferenças, indicativa e não replicação *bit-exact*.

2.9.3 Detecção multilíngue

A detecção multilíngue de fake news enfrenta dificuldades adicionais ao caso monolíngue: disponibilidade desigual de dados rotulados entre idiomas, qualidade variável de *embeddings* pré-treinados, e diferenças estilísticas sistemáticas entre notícias produzidas em diferentes contextos linguísticos. Trabalhos recentes propõem duas estratégias dominantes. A primeira, *cross-lingual transfer*, treina o classificador em um idioma com abundância de dados (tipicamente o inglês) e o transfere por meio de embeddings multilíngues para idiomas de menor disponibilidade [Chu, Xie e Wang 2020]. A segunda explora a arquitetura *Transformer multilíngue* para encoder com representações alinhadas, como em [Fan, Hu e Zhao 2025] para o problema de detecção de *hate speech* translíngüística e em [Zhou, Tao e Zhang 2023] para fake news sobre COVID-19.

O presente trabalho se insere *tangencialmente* nessa linha. A contribuição específica é mostrar, empiricamente, que o classificador *topológico* (que não processa texto) produz distribuições de *score* estatisticamente equivalentes entre português e inglês sobre um

snapshot multilíngue do Bluesky (§4.5). Isso não constitui uma proposta de método multilíngue: a precisão classificatória em português não foi medida, dado que o Bluesky não possui *ground truth*. É, antes, evidência de que o sinal estrutural *transcende* o idioma, propriedade desejável para métodos híbridos futuros.

2.9.4 Trabalhos brasileiros relacionados

A pesquisa brasileira sobre detecção de desinformação em redes sociais é ainda incipiente em comparação com a literatura internacional, mas inclui exemplos relevantes. Cunha [Cunha 2021] (UFC) investigou cadeias de propagação no WhatsApp, plataforma de importância particular no contexto brasileiro pela criptografia ponta-a-ponta que limita o acesso a conteúdo de grupos. A dissertação de mestrado em [Souza 2023] (PUC-SP) aplica GNNs a um corpus de notícias em português, em contexto eleitoral, e [Souza 2023] (USP) revisa a literatura computacional disponível em português. Nenhum desses trabalhos propõe, contudo, o diagnóstico de aplicabilidade ancorado em *Cohen’s d* que constitui a contribuição central do presente trabalho.

2.9.5 Homofilia e assortatividade em redes

A pergunta de pesquisa central deste trabalho — *sob quais condições a topologia da propagação detecta fake news?* — remete a uma questão clássica em teoria de redes: quando é que classes de vértices em um grafo se diferenciam por estrutura?

McPherson, Smith-Lovin e Cook [McPherson, Smith-Lovin e Cook 2001] estabeleceram o conceito de *homofilia* (*birds of a feather flock together*) como princípio organizador de redes sociais: indivíduos similares formam laços preferencialmente, e essa preferência se manifesta em segregação mensurável da rede em comunidades por atributo. Newman [Newman 2003] formalizou *assortatividade por atributo* como o coeficiente de correlação entre atributos de vértices ligados por arestas: redes em que nós da mesma classe se conectam preferencialmente exibem assortatividade alta; redes em que classes se misturam exibem assortatividade próxima de zero.

Pei et al. [Pei et al. 2020] demonstraram que GNNs convolucionais dependem precisamente de assortatividade por classe para serem efetivas em classificação nodal: em redes pouco assortativas (*heterophilous*), os operadores de agregação misturam representações de classes diferentes em cada camada, degradando a discriminação final. Embora o trabalho de Pei trate classificação nodal em redes de citação, o mecanismo básico se transfere ao nosso problema de classificação de grafo: em UPFD-GossipCop, as cascatas das duas classes apresentam perfis estruturais distintos (*branching factor* alto em *fake*, baixo em *real*); em UPFD-PolitiFact, não há diferença estrutural correspondente. O *Cohen’s d* entre classes em métricas de cascata, que adotamos como operacionalização da tese central (§4.6), é a versão concreta dessa noção de assortatividade adaptada ao nível de grafo.

2.9.6 Posicionamento deste trabalho

O presente trabalho não propõe uma nova arquitetura de Rede Neural de Grafos. Avalia três arquiteturas canônicas (GCN, GAT, GraphSAGE) sob *ablation* sistemática das *features* nodais e dos *datasets* disponíveis, e propõe como contribuição primária um *diagnóstico de aplicabilidade*: um critério mensurável, diferença estrutural entre classes da ordem de $|d| \geq 0,5$ em pelo menos uma métrica de cascata, que decide, *antes do treinamento*, se há chance de o paradigma topológico funcionar em um domínio dado. O critério é deliberadamente *falsificável*: a apresentação de um *dataset* com $0,2 < |d| < 0,5$ em que uma arquitetura GNN atinja desempenho significativamente acima do *baseline* textual constituiria contra-evidência direta.

A limitação mais relevante assumida é que não reimplementamos o BiGCN [Bian et al. 2020] nem o GCNFN sob nosso protocolo de avaliação; a comparação com esses métodos é feita por meio dos valores reportados em [Dou et al. 2021], com as diferenças de configuração declaradas em §4.3. Essa e outras limitações do trabalho são retomadas em §5.3.

Capítulo 3

Metodologia

3.1 Visão geral do pipeline

O *pipeline* experimental deste trabalho transforma dados brutos de propagação em rede social em métricas de classificação auditadas estatisticamente, passando por cinco blocos sequenciais (construção de grafos, computação de *features*, treinamento GNN, avaliação com *k-fold* pareado e produção de métricas). A Figura 3.1 representa esses blocos e o fluxo entre eles; as seções seguintes deste capítulo detalham cada um.




Figura 3.1: Visão geral do *pipeline* de detecção. Dados brutos são transformados em grafos de propagação com *features* estruturais (e textuais via BERT, quando disponíveis), passados por modelos GNN, e avaliados com protocolo de k-fold pareado.

3.2 Datasets

Quatro *datasets* sustentam os experimentos deste trabalho, com papéis distintos. Três deles oferecem rótulos *fake/real* e portanto são usados para treino e validação quantitativa (FakeNewsNet PolitiFact, UPFD-PolitiFact, UPFD-GossipCop); o quarto, um *snapshot* acadêmico do Bluesky, não possui *ground-truth* e é utilizado em modo de *aplicação demonstrativa* (Apêndice D). A Tabela 3.1 resume tamanho, fonte e papel de cada um.

Tabela 3.1: Datasets utilizados, com tamanho, fonte e papel no trabalho.

Dataset	Tamanho	N classes	Fonte	Papel
FakeNewsNet PolitiFact	~754 grafos	2 (50/50)	[Shu et al. 2020]	Treino + validação
UPFD-PolitiFact	~314 grafos	2 (50/50)	[Dou et al. 2021]	Cross-dataset
UPFD-GossipCop	~5.464 grafos	2 (50/50)	[Dou et al. 2021]	Cross-dataset
Bluesky (acadêmico)	168.463 <i>posts</i> [†]	–	[Failla e Rossetti 2024]	Aplicação (sem <i>labels</i>)

[†]Posts individuais; cada um pode ser raiz de uma cascata de propagação construída em §3.3.

3.3 Construção de grafos: FakeNewsNet

A construção dos grafos do FakeNewsNet é realizada pelo *script* `00_construir_grafos_fakenewsnet`. O *script* efetua o *download* direto dos CSVs do repositório oficial do KaiDMML [Shu et al. 2020], gera o *embedding* textual do título de cada notícia via *Sentence-BERT* multilíngue (modelo `paraphrase-multilingual-mpnet-base-v2`, dimensão 768; treinado por destilação de conhecimento entre línguas a partir de uma versão monolíngue [Reimers e Gurevych 2020]) e *cacheia* o resultado em disco para evitar recomputação. Cada notícia gera um grafo em estrela: o nó raiz é a notícia em si, e seus filhos são os identificadores de *tweets* listados pelo CSV como tendo propagado a notícia.

A topologia em estrela (e não em árvore com profundidade) é imposta pelo formato do CSV bruto, que fornece apenas uma lista plana de `tweet_ids` por notícia, sem relação de parentesco entre *retweets* e sem *timestamps*: limitação herdada diretamente do repositório KaiDMML [Shu et al. 2020], não mitigável sem coleta complementar via API. Aplicam-se dois filtros: o mínimo de dois *tweets* de propagação por notícia (descarta cascatas degeneradas, sem o que o grafo de propagação seria reduzido a um único nó) e o máximo de 100 nós por grafo. A distribuição bruta de tamanhos de cascata é fortemente assimétrica, regime característico de redes sociais e consistente com *power-law* em grau de vértice [Barabási e Albert 1999, Clauset, Shalizi e Newman 2009]: a mediana é de 30 *tweets*, mas a média chega a 552 e o máximo observado a 29.060. O limite de 100 nós trunca, portanto, 50% dos grafos do *dataset*; não se trata de remoção de *outliers* raros, mas de decisão de projeto com efeito substancial. A justificativa é estrutural: em um grafo-estrela, todos os nós-filho compartilham o mesmo *embedding* BERT (replicado a partir do título), e folhas adicionais além de uma centena acrescentam informação marginal desprezível; além disso, o *global mean pool* adotado pela camada final faria com que, em um grafo de dezenas de milhares de folhas quase idênticas, a contribuição do nó raiz, único portador das *features* `is_root` e `grau_norm`, fosse diluída a uma fração ínfima do vetor agregado. Como contrapartida, os grafos truncados tornam-se indistinguíveis quanto ao tamanho absoluto da cascata (limitação retomada em §5.3).

O *script* oferece três variantes de construção, controladas pela *flag* `-feature-variant`:

`posfull` (todas as três codificações posicionais ativas, vetor nodal de 771 dimensões), `posmin` (apenas `is_root` e `pos`, com `grau_norm` zerado) e `posgrau` (apenas `is_root` e `grau_norm`, com `pos` zerado). As três variantes materializam-se em diretórios distintos em `data/fakenewsnet_<suffix>/` e são consumidas pela ablation intra-encoding (§4.4). Uma asserção de sanidade no construtor (`x.unique(dim=0).shape[0] >= min(num_nos, 3)`) garante que os vetores nodais de um mesmo grafo não sejam idênticos, prevenindo o cenário de degeneração do *message passing* descrito em §2.5.

3.4 Folds compartilhados

O *script* `gerar_folds.py` instancia `StratifiedKFold(n_splits=10, shuffle=True, random_state=42)` do *scikit-learn* sobre os 754 grafos do FakeNewsNet e persiste os índices em `data/folds_fnn.pt`. A escolha de $k = 10$ segue recomendação clássica de Kohavi [Kohavi 1995] como compromisso entre viés e variância da estimativa da métrica em *datasets* de tamanho moderado. Esse arquivo é gerado *uma única vez* e consumido por todos os experimentos do trabalho que reportam comparações pareadas: o baseline textual (§4.1), o diagnóstico de *confound* (§4.2), o teste de significância entre arquiteturas GNN, entre outros.

O teste t pareado (`scipy.stats.ttest_rel`) que usamos para comparar dois modelos exige que cada par de métricas comparado tenha sido obtido sobre os *mesmos exemplos*. Caso contrário, a variação entre folds se mistura à diferença entre modelos, reduzindo o poder do teste e tornando suas conclusões questionáveis. O compartilhamento de *folds* elimina essa fonte de ruído e é pré-requisito do protocolo de avaliação formalizado em §3.7.

3.5 Arquiteturas GNN e hiperparâmetros

Três arquiteturas representativas das principais famílias de Redes Neurais de Grafos são avaliadas: a *Graph Convolutional Network* (GCN, [Kipf e Welling 2017]), com agregação espectral normalizada pelo grau; a *Graph Attention Network* (GAT, [Veličković et al. 2018]), com pesos de aresta aprendidos via mecanismo de atenção; e o GraphSAGE ([Hamilton, Ying e Leskovec 2018]), com agregação indutiva por média dos vizinhos. Todas as três são implementadas no *PyTorch Geometric* [Fey e Lenssen 2019] e compartilham a mesma arquitetura agregada: três camadas convolucionais (limite clássico para evitar o *oversmoothing* demonstrado por Li, Han e Wu [Li, Han e Wu 2018] em GCNs profundas), com 64 canais ocultos por camada, seguidas de *global mean pool* sobre os nós (invariante a permutação de vértices, operação padrão da família agregadora discutida por Xu et al. [Xu et al. 2019]), *dropout* de 0,5 [Srivastava et al. 2014] e um classificador linear final. O otimizador é Adam [Kingma e Ba 2015] com taxa de aprendizado 10^{-3} (valor *default* do artigo original) e ℓ_2 *weight decay* de 5×10^{-4} (convenção da literatura GNN seguindo Kipf e Welling [Kipf e Welling 2017]). O *batch size* de 32 foi adotado por razões de memória

em ambiente CPU e é consistente com evidências de que *batches* pequenos melhoram a generalização em redes neurais profundas [Masters e Luschi 2018]. *Early stopping* com *patience* sobre o F_1 -macro de validação segue a recomendação de Prechelt [Prechelt 1998]. Os demais hiperparâmetros, incluindo as poucas diferenças entre as arquiteturas, estão na Tabela 3.2.

*O vetor de features de entrada de cada nó varia conforme o experimento. No benchmark cross-dataset de §4.3 sobre o UPFD, utilizamos a variante **content** (310 dimensões, combinação spaCy + profile) por restrição de memória RAM ao densificar a matriz esparsa de GossipCop em ambiente Windows/CPU: a variante **bert** (768 dimensões) reportada em [Dou et al. 2021] estoura memória nessa configuração. No FakeNewsNet, o vetor é o de 771 dimensões descrito em §3.3 (embedding BERT do título + codificações posicionais). Nos experimentos de topologia pura da §4.4, ambos os datasets têm suas features substituídas por [*is_root*, *grau_norm*] (dimensão 2).*

Tabela 3.2: Hiperparâmetros usados nos modelos GNN. Defaults são iguais entre arquiteturas; diferenças anotadas na própria tabela.

Hiperparâmetro	GCN	GAT	SAGE
hidden_channels	64	64	64
num_layers	3	3	3
dropout	0.5	0.5	0.5
num_heads (atenção)	–	4	–
pooling	global_mean_pool	idem	idem
learning_rate	0.001	0.001	0.001
weight_decay	5×10^{-4}	5×10^{-4}	5×10^{-4}
batch_size	32	32	32
optimizer	Adam	Adam	Adam
scheduler	ReduceLROnPlateau (factor=0.5, patience=5)		
early_stopping	patience=7 sobre F1-macro de validação		
max_epochs	30	30	30
seed	42 (com varredura para 10 <i>seeds</i> em §4.4)		

A opção por hiperparâmetros idênticos entre as três arquiteturas não busca otimizar cada uma ao máximo (o que tornaria a comparação dependente de quanto cada modelo foi ajustado), mas sim *isolar o efeito arquitetural*: se uma família se destaca consistentemente sob a mesma configuração básica, o sinal observado é atribuível à arquitetura, não ao *tuning*. Os defaults adotados são valores convencionais na literatura de GNNs e suficientes para conduzir o treinamento à convergência dentro do máximo de 30 épocas estabelecido.

3.6 *Baselines* não-GNN

Dois *baselines* deliberadamente simples acompanham as arquiteturas GNN ao longo do trabalho, cada um isolando uma direção do espaço de hipóteses.

O primeiro é um classificador puramente *textual*: a *Regressão Logística* aplicada sobre o *embedding* BERT da raiz da árvore de propagação (isto é, o vetor de 768 dimensões do título da notícia). Esse modelo não tem acesso a nenhuma informação estrutural: ignora o grafo inteiro e vê apenas o conteúdo textual. Estabelece, portanto, o *teto textual* do problema; qualquer GNN que não supere significativamente este *baseline* não está agregando valor sobre a informação do texto.

O segundo é um classificador puramente *estrutural tabular*: um *Random Forest* com 200 árvores, treinado sobre apenas duas *features* agregadas por grafo: o número total de nós (`num_nodes`) e o grau do nó raiz (`grau_root`). Esse modelo encarna o *confound trivial* da detecção de fake news em redes: a observação recorrente de que notícias falsas tendem a viralizar mais, gerando cascatas maiores. Se um *Random Forest* alimentado apenas com tamanho e grau atinge um F1 próximo do da GNN, o ganho aparente da GNN não vem de capturar estrutura sutil, mas apenas de reproduzir esse *confound*; se, por outro lado, o GNN supera significativamente o RF, há sinal estrutural genuíno sendo aprendido. Os dois *baselines* são confrontados, lado a lado, com as arquiteturas GNN em §4.1 e §4.2.

3.7 Protocolo de avaliação

A métrica primária adotada é o *F1-macro*, a média não ponderada dos F1 das duas classes (fake e real). Como os três *datasets* supervisionados utilizados são aproximadamente balanceados em torno de 50%/50% entre as classes (§3.2), o F1-macro é numericamente próximo da acurácia, mas com a vantagem de permanecer significativo caso futuros *datasets* apresentem desequilíbrio, por exemplo com a classe *fake* em minoria. A literatura UPFD [Dou et al. 2021] reporta acurácia; usamos F1-macro para alinhar com práticas mais recentes em classificação binária desbalanceada e marcamos expressamente a diferença quando confrontamos com valores publicados (Tabela 4.4).

Para comparar dois modelos sob o mesmo *dataset*, utilizamos o *teste t pareado* (`scipy.stats.ttest_rel`) sobre os *folds* compartilhados de §3.4. O pareamento tem duas implicações práticas: a variação entre *folds* é cancelada (cada *fold* contribui com uma diferença entre modelos, não com uma métrica absoluta), e o teste recupera o sinal mesmo em diferenças pequenas que o teste não-pareado não detectaria. No caso particular dos *subsets post-hoc* (como os recortes por profundidade da cascata em §4.9), nos quais o pareamento por fold é impossível por o *subset* ser definido sobre o conjunto de teste único, recorreremos ao *bootstrap* pareado descrito em §3.8.

Para a análise descritiva de separabilidade estrutural entre fake e real (§4.6), reportamos

o *tamanho de efeito de Cohen* (d), conforme definição clássica de [Cohen 1988], com refinamentos da escala discutidos por Sawilowsky [Sawilowsky 2009]. A escala interpretativa adotada é a usual: $|d| < 0,2$ desprezível, $0,2 \leq |d| < 0,5$ pequeno, $0,5 \leq |d| < 0,8$ médio, $|d| \geq 0,8$ grande. A tese central do trabalho está operacionalizada nesse limiar (ver §5.2).

Caveat de reprodutibilidade. Todos os experimentos foram executados em CPU (Intel Raptor Lake, 16 cores lógicos, 16 GB de RAM), sob Python 3.12.10 e PyTorch 2.10+cpu, com semente universal 42. Os resultados são reproduzíveis no mesmo ambiente, mas não bit-exato entre máquinas: operações `scatter` e `gather` do PyTorch Geometric não possuem *kernel* determinístico em GPU, e diferenças entre versões de CUDA/cuDNN ou entre CPUs distintas geram variação tipicamente na terceira casa decimal das métricas. Como contramedida, os achados centrais foram validados em 10 *seeds* independentes (§4.4) e em *bootstrap* pareado de 2.000 reamostragens (§4.9.4); as conclusões qualitativas se mantêm entre execuções.

3.8 Análise estratificada do erro

O F1-macro agregado mede *quanto* um modelo acerta, não *onde* ele acerta. Para responder a essa segunda questão, relevante para a caracterização de regimes em que cada modelo falha ou prospera, adotamos três técnicas complementares aplicadas sobre o *test set* do UPFD-GossipCop, em conjunto detalhadas em §4.9.

A primeira é uma *regressão localmente ponderada* (LOWESS) de $P(\text{acerto} \mid m)$ em função de cada métrica estrutural m , segundo a formulação de Cleveland [Cleveland 1979]. Implementamo-la via *rolling mean* de janela proporcional (10% da amostra ordenada, com mínimo absoluto de 30 observações), evitando a dependência de `statsmodels`. A vantagem sobre o *binning* discreto é dupla: visualiza-se continuamente a variação da acurácia ao longo de m , sem decidir arbitrariamente onde cortar os *bins*, o que evita o espaço para *cherry-picking*.

A segunda é a definição de *outliers* via *percentil empírico* (p5/p95) sobre o próprio *test set*, em vez de limiares baseados em *z-score*. A escolha é justificada pela forma das distribuições: métricas de cascata em redes sociais são *heavy-tail*, com cauda mais agressiva do que a lognormal, regime amplamente reportado na literatura [Barabási e Albert 1999, Clauset, Shalizi e Newman 2009]. Nesse cenário, a média não é robusta, o desvio-padrão é inflado por poucos casos extremos, e critérios baseados em σ tornam-se mal-definidos. O percentil empírico é invariante à forma da distribuição e identifica reciprocamente o 5% inferior e o 5% superior independentemente da assimetria.

A terceira é o *bootstrap pareado* (com $n_{\text{boot}} = 2.000$ reamostragens, na formulação de Efron e Tibshirani [Efron e Tibshirani 1993]) para intervalos de confiança sobre a diferença de F1 entre dois modelos avaliados no mesmo *subset*, técnica empregada em §4.9.4 para confirmar a significância do ganho do SAGE estrutural sobre o RF tabular em recortes

de profundidade da cascata. O *bootstrap* é o substituto natural do `ttest_rel` pareado por *fold* quando o pareamento por *fold* não se aplica, como ocorre em *subsets* definidos *post-hoc* sobre o teste único do UPFD.

3.9 Análise de explicabilidade

Para inspecionar o que a arquitetura SAGE estrutural efetivamente aprende do grafo de propagação, recorremos ao *GNNE explainer* [Ying et al. 2019], implementado em `torch_geometric.explainer` com algoritmo `GNNEExplainer(epochs=200)` e `edge_mask_type="object"`, em modo de classificação multi-classe sobre o grafo inteiro. O *GNNEExplainer* aprende uma máscara sobre as arestas do grafo que maximiza a informação mútua entre a sub-rede mascarada e a predição do modelo, identificando assim quais arestas são mais decisivas para a classificação de cada grafo.

A análise é aplicada sobre 20 amostras do *test set* do UPFD-GossipCop estratificadas em quatro grupos de cinco grafos cada (*fake*-pequena, *fake*-grande, *real*-pequena, *real*-grande), permitindo identificar padrões diferenciais por classe e por tamanho. Para cada amostra, calcula-se a fração de massa de importância concentrada em arestas a 1-hop (raiz $\rightarrow$ filhos diretos), 2-hops e ≥ 3 -hops da raiz. Os resultados, apresentados em §4.8, revelam uma assimetria sistemática entre *fake* e *real* no padrão espacial de importância, achado que sustenta interpretações sobre o mecanismo de classificação aprendido pelo modelo.

3.10 Classificador dual: regra de combinação *post-hoc*

Para a aplicação prática documentada no Apêndice D, combinamos o classificador textual (LogReg-BERT) e o classificador topológico (RF estrutural) por meio de uma regra de combinação heurística. Essa regra **não é uma decisão metodológica a priori**: trata-se de uma heurística derivada *post-hoc*, ou seja, após a observação empírica dos resultados de §4.7. A formulação exata da regra, os números que a justificam e as alternativas descartadas estão naquela seção, sob a equação (4.1). A regra é mencionada aqui porque a ferramenta web do Apêndice D usa o classificador combinado.

3.11 Reprodutibilidade

A reprodutibilidade depende de fixar o ambiente, controlar as fontes de aleatoriedade e expor as limitações ao determinismo. Primeiro, o ambiente de execução é fixado: Python 3.12.10, PyTorch 2.10+cpu, PyTorch Geometric 2.7.0, *scikit-learn* e demais dependências versionadas em `requirements.txt` (*pinned*). Os experimentos foram conduzidos em **ambiente CPU** (Intel *Raptor Lake*, 16 *cores* lógicos, 16 GB de RAM, Windows 11); não se utilizou GPU em nenhum momento do treinamento ou da avaliação.

Segundo, todas as fontes de aleatoriedade são semeadas com o valor 42: `torch.manual_seed`, `numpy.random.seed`, `random.seed`, `StratifiedKFold(random_state=42)` e os construtores dos classificadores do *scikit-learn* (`n_jobs=-1` é adotado para o RF, sem efeito sobre determinismo). Para os experimentos sensíveis à inicialização, conduzimos varredura explícita sobre 10 *seeds* independentes em §4.4 e reportamos média e desvio-padrão.

Terceiro, reconhecemos as limitações ao determinismo: operadores `scatter` e `gather` do PyTorch Geometric não possuem *kernel* determinístico em GPU¹, e diferenças de arquitetura de CPU ou de versão de bibliotecas geram variação tipicamente na terceira casa decimal das métricas reportadas. As conclusões qualitativas do trabalho são robustas a essa variação. O repositório oficial do código, com o `README.md` como fonte autoritativa de instruções, está documentado no Apêndice C; o *dataset* processado do Bluesky utilizado em produção está publicado no Hugging Face Hub [Sibila, Livingston e Takida 2025].

¹Referência da nota: a documentação oficial do PyTorch sobre reprodutibilidade (<https://pytorch.org/docs/stable/notes/randomness.html>).

Capítulo 4

Resultados Experimentais

Cada seção deste capítulo responde uma das perguntas de pesquisa formuladas em §1.3. Resultados negativos (em particular o desempenho dos modelos topológicos no UPFD-PolitiFact em §4.4) são reportados com a mesma extensão dos positivos: a refutação de uma hipótese tem peso evidencial equivalente à sua confirmação, e é justamente a sobreposição dos dois lados que permite caracterizar o regime de aplicabilidade do paradigma topológico. A Tabela 4.1 consolida em uma só vista as métricas-chave por (*dataset* $\times$ modelo), com código de cores que sinaliza desempenho forte, intermediário e colapso.

Tabela 4.1: Síntese de resultados: F1-macro por (*dataset* $\times$ modelo). Células verdes indicam desempenho forte ($\geq 0,80$); amarelas, médio (0,60–0,79); vermelhas, colapso ($< 0,60$). Negrito marca o melhor modelo de cada *dataset*. O contraste entre UPFD-GossipCop (todas as linhas verdes) e UPFD-PolitiFact com features estruturais puras (linha inteira em vermelho) e’ o achado central do trabalho.

Modelo / <i>features</i>	FNN	UPFD-Polit	UPFD-Goss	Fonte
<i>Baselines textuais</i>				
LogReg-BERT (título)	0,859	0,842	0,954	T1, T3
RandomForest-BERT	0,855	–	–	T1
<i>GNNs com texto (feature content/profile)</i>				
GCN	–	0,782	0,941	T3
GAT	–	0,694	0,939	T3
SAGE	–	0,817	0,945	T3
<i>Modelos topológicos puros (sem texto)</i>				
RF tabular [num_nodes, grau_root]	–	–	0,753	T6
GCN [is_root, grau_norm]	0,528	0,362	0,645	T4
GAT [is_root, grau_norm]	0,537	0,380	0,483	T4
SAGE [is_root, grau_norm]	0,536	0,331	0,810	T4
<i>Referência (Dou et al., SIGIR 2021)</i>				
GCN/GAT/SAGE publicado	–	0,846 [†]	0,971 [†]	T10

[†] Acurácia reportada por Dou et al. com *feature bert* (768d); nosso F1-macro com *content* (310d). Não bit-exact, indicativo apenas.

“Melhor da coluna” aplicado dentro de cada bloco; o negrito da linha SAGE em UPFD-PolitiFact destaca o caso de colapso (não um *m*).

4.1 *Baselines* textuais sobre BERT da raiz

O *teto* textual do problema é o desempenho que dois classificadores clássicos atingem quando recebem apenas a representação BERT do título da notícia, sem nenhuma informação topológica. Os resultados desse experimento sobre o FakeNewsNet estão na Tabela 4.2.

Tabela 4.2: Baseline textual no FakeNewsNet (k-fold estratificado, k=10).

Modelo	Folds	F1-macro	Accuracy
LogReg	10	0.8593 ± 0.0431	0.8595 ± 0.0430
RandomForest	10	0.8549 ± 0.0372	0.8555 ± 0.0369

O LogReg-BERT atinge F1-macro de $0,859 \pm 0,043$ sobre 10 *folds* estratificados; o *Random Forest* sobre o mesmo *embedding* atinge $0,855 \pm 0,037$, valor próximo. Em ambos os casos, a acurácia é essencialmente igual ao F1-macro (consistente com o balanço 50/50 do FNN, §3.2).

A leitura desse resultado define o *teto textual* do problema neste *dataset*: *o texto da raiz da árvore de propagação, isoladamente, já carrega quase todo o sinal classificatório recuperável*. Modelos baseados em grafos só se justificam, no FakeNewsNet, se o ganho que trazem sobre esse teto for estatisticamente distinguível, o que se mostrará, em §4.4, *não ocorrer*: as arquiteturas GNN com *features* estruturais puras sequer alcançam 0,55, e mesmo as variantes com texto têm ganho marginal sobre o LogReg-BERT. Em §4.6 discutiremos por que esse teto textual tão alto e a ausência de ganho topológico no FNN são coerentes com a tese central do trabalho.

4.2 Diagnóstico de *confound* topológico

Notícias falsas tendem, na literatura de detecção em redes sociais, a viralizar mais que notícias verdadeiras e gerar cascatas maiores. Essa correlação cria um *confound* trivial: o desempenho que se atribui a uma GNN pode, em última instância, não estar capturando estrutura sutil alguma: pode estar apenas reproduzindo o atalho “*fake* = grafo maior”. Para testá-lo diretamente, treinamos um *Random Forest* (§3.6) no FakeNewsNet alimentado *apenas* com a *feature* `num_nodes`. O F1-macro resultante é de $\approx 0,523$, valor próximo do nível de chance (0,50 em problema balanceado) e bem abaixo do limiar de 0,65 que adotaríamos *a priori* como sinal de *confound* dominante. Sendo assim, o tamanho do grafo *contribui*, mas não *explica* o sinal capturado pelos modelos posteriores: há ruído demais na correlação entre tamanho e veracidade para que um classificador trivial dela extraia valor preditivo. O ganho que se observa nas GNNs vem, portanto, de outras fontes: textuais, no caso do FNN; estruturais multi-hop, no caso do UPFD-GossipCop (cuja decomposição por profundidade da cascata é quantificada em §4.9).

4.3 Cross-dataset UPFD: nossos resultados *versus* literatura

Os números deste trabalho só sustentam os achados sobre topologia se estiverem *calibrados* contra a literatura: sob diferenças conhecidas e declaradas de configuração, eles estão no envelope dos publicados? A Tabela 4.3 reporta o desempenho das três arquiteturas GNN nas duas variantes do UPFD; a Tabela 4.4 confronta esses mesmos valores com os de Dou et al. [Dou et al. 2021].

Tabela 4.3: Benchmark cross-dataset UPFD (PolitiFact + GossipCop) – GCN/GAT/SAGE vs baseline textual.

Dataset	Modelo	Seeds/Folds	F1-macro
gossipcop	GAT	3	0.9390 ± 0.0050
gossipcop	GCN	3	0.9411 ± 0.0059
gossipcop	LogReg_root	1	0.9540 ± 0.0000
gossipcop	SAGE	3	0.9448 ± 0.0041
politifact	GAT	5	0.6936 ± 0.1865
politifact	GCN	5	0.7816 ± 0.0548
politifact	LogReg_root	1	0.8415 ± 0.0000
politifact	SAGE	5	0.8166 ± 0.0095

Tabela 4.4: Comparacao com baselines do UPFD original (Dou et al., SIGIR 2021, Tabela 4). Nota: nossos resultados sao F1-macro sobre k-fold com feature 'content' (310d); valores publicados sao accuracy com feature 'bert' (768d). Comparacao indicativa, nao bit-exact.

Dataset	Modelo	F1-macro (nosso)	Acc (Dou et al.)
politifact	GCN	0.782 ± 0.055	0.846
politifact	GAT	0.694 ± 0.186	0.846
politifact	SAGE	0.817 ± 0.010	0.846
gossipcop	GCN	0.941 ± 0.006	0.972
gossipcop	GAT	0.939 ± 0.005	0.971
gossipcop	SAGE	0.945 ± 0.004	0.971

O contraste entre os dois domínios já está presente aqui: no UPFD-GossipCop as três arquiteturas convergem para F1-macro em torno de 0,94, próximas do *baseline* textual (0,954); no UPFD-PolitiFact, os modelos espalham-se entre 0,69 (GAT) e 0,82 (SAGE), com o próprio LogReg-BERT atingindo 0,84, isto é, no PolitiFact a variação entre arquiteturas é muito maior, e nenhuma supera o *baseline* textual em margem significativa. No confronto

direto com Dou et al., o nosso UPFD-PolitiFact fica em torno de 0,78–0,82 (vs. 0,846 publicado) e o UPFD-GossipCop em torno de 0,94–0,95 (vs. 0,971 publicado).

Esta comparação é *aproximada, não replicação exata*: as razões precisam ser declaradas explicitamente. Três diferenças deliberadas afastam nossa configuração da deles: (i) utilizamos a *feature content* (310 dimensões, combinação de *spaCy* e *profile*) ao invés da *feature bert* (768 dimensões), por restrição de memória RAM na densificação da matriz esparsa do GossipCop em ambiente Windows/CPU; (ii) adotamos hiperparâmetros próprios ($lr = 0,001$, $hidden = 64$, três camadas), uma vez que a configuração exata de [Dou et al. 2021] não é totalmente especificada no artigo; (iii) reportamos F1-macro enquanto Dou et al. reportam acurácia. O propósito da comparação não é *ranking* competitivo com a literatura, mas *calibração*: verificar que nosso *pipeline*, com diferenças conhecidas e declaradas, está *no envelope* dos valores publicados: condição necessária para que os achados subsequentes deste capítulo sejam tomados como informativos sobre o problema, e não como artefatos de implementação defeituosa.

4.4 Topologia sem texto: o achado central (RQ3, parte a)

A pergunta operacional desta seção, e o achado mais central do trabalho, é a seguinte: *é possível treinar uma GNN para detectar fake news sem fornecer texto a ela, apenas com sinal estrutural sobre o grafo de propagação?* Para responder, substituímos as *features* nodais por um vetor de apenas duas dimensões estruturais ($[is_root, grau_norm]$) em cada um dos três *datasets* e treinamos as três arquiteturas (GCN, GAT, SAGE). O resultado está sintetizado na Tabela 4.5 e visualizado, em forma de *heatmap*, na Figura 4.1.

Tabela 4.5: Topologia SEM texto: features $[is_root, grau_norm]$ – sinal estrutural puro por dataset/arch.

Dataset	Modelo	Seeds/Folds	F1-macro
fnn	GAT	10	0.5372 ± 0.0709
fnn	GCN	10	0.5275 ± 0.0678
fnn	SAGE	10	0.5362 ± 0.0747
upfd_gossipcop	GAT	10	0.4834 ± 0.1075
upfd_gossipcop	GCN	10	0.6445 ± 0.0190
upfd_gossipcop	SAGE	10	0.8097 ± 0.0023
upfd_politifact	GAT	10	0.3800 ± 0.0802
upfd_politifact	GCN	10	0.3621 ± 0.0554
upfd_politifact	SAGE	10	0.3314 ± 0.0093




Figura 4.1: F1-macro por (arquitetura $\times$ *feature variant* $\times$ *dataset*). Verde = modelo aprende; vermelho = colapsa. SAGE em UPFD-GossipCop com apenas duas *features* estruturais atinge $F1 \approx 0.81$.

A combinação **SAGE + UPFD-GossipCop + *features* estruturais puras** [`is_root`, `grau_norm`] (vetor nodal de apenas duas dimensões, nenhuma das quais contém texto) atinge F1-macro de $0,810 \pm 0,002$, média sobre dez *seeds* independentes. O mesmo modelo, treinado nos outros dois *datasets*, colapsa: $F1 \approx 0,33$ em UPFD-PolitiFact (abaixo do nível de chance) e $F1 \approx 0,54$ em FakeNewsNet. As outras duas arquiteturas testadas no UPFD-GossipCop ficam atrás do SAGE (GCN 0,64, GAT 0,48), reforçando que a agregação indutiva por média do GraphSAGE é particularmente adequada à estrutura em estrela do dataset. *Sem nenhum acesso ao texto da notícia, apenas com duas dimensões estruturais por nó, o SAGE no UPFD-GossipCop alcança 81% de F1-macro, a 13 pontos percentuais do baseline textual (0,954) e a 14 pontos do SAGE com texto (0,945).* Este é o resultado central que responde afirmativamente à parte (a) da RQ3: é viável detectar fake news apenas pela topologia da propagação, *desde que* o domínio ofereça sinal estrutural mensurável (condição examinada em §4.6).

A baixa variância em torno desse F1 de 0,81 ($\sigma = 0,002$ sobre dez *seeds*) merece justificativa, pois é atipicamente pequena para um experimento de aprendizado profundo. Auditoria do *script* de execução confirma que (i) `torch.manual_seed` e `np.random.seed` são chamados antes de cada execução independente; (ii) o `DataLoader` com `shuffle=True` consome do gerador semeado; (iii) o construtor da `SAGEClassifier` recebe `seed=seed` explicitamente. A baixa variância é, portanto, comportamento genuíno do experimento, e é consequência da combinação de três fatores: (a) o vetor de entrada tem apenas duas dimensões, oferecendo pouco espaço para que diferenças de inicialização se tornem diferenças de convergência; (b) o sinal estrutural no UPFD-GossipCop é muito forte (Cohen’s $d = +1,53$ no *branching factor*, §4.6), conduzindo o otimizador ao mesmo ótimo independentemente da semente; (c) o *split* treino/validação/teste do UPFD é fixo, isolando completamente a fonte de variação do *dataset*. Como controle negativo, a mesma

arquitetura SAGE aplicada ao UPFD-PolitiFact (onde nenhum Cohen’s d atinge efeito médio) produz $\sigma \approx 0,009$, cerca de quatro vezes maior; isto é, o σ baixo é função do *dataset*, não de *bug* de semente.

4.5 Consistência de *score* topológico entre idiomas (RQ3, parte b)

O que este experimento mede precisa ser delimitado com precisão. O *snapshot* acadêmico do Bluesky utilizado aqui *não possui rótulos fake/real*, e portanto este experimento **não mede detecção** em português, alemão ou qualquer outro idioma. Mede, em vez disso, a *consistência da distribuição do score* que o classificador estrutural, treinado em UPFD-GossipCop e arquiteturalmente cego ao texto, produz quando aplicado a posts em diferentes idiomas. Essa consistência é condição *necessária mas não suficiente* para detecção multilíngue: distribuições discrepantes indicariam que o mecanismo estrutural responde sistematicamente ao idioma do post (por confounders de comunidade, volume ou regime de engajamento), refutando a independência linguística do mecanismo; distribuições equivalentes *não garantem* acurácia preditiva em produção, apenas que o classificador não introduz viés sistemático por idioma.

Tabela 4.6: Comparacao da distribuicao de score topologico no Bluesky entre idiomas (RQ3 parte b). PT vs EN: efeito desprezível ($|d| < 0.2$); DE vs EN: efeito medio ($|d| = 0.47$). Interpretacao com 3 hipoteses alternativas em §4.4-bis (shift dominio, vies amostral, desbalanco).

Par	n_a	n_b	$\bar{s}_a$	$\bar{s}_b$	Cohen’s d	KS p
por vs eng	2661	132312	0.381	0.398	-0.057	2.69e-42
deu vs eng	9686	132312	0.259	0.398	-0.468	0.00e+00
por vs deu	2661	9686	0.381	0.259	+0.739	5.48e-321




Figura 4.2: Distribuição do *score* topológico do RF-estrutural (treinado em UPFD-GossipCop) aplicado a posts do Bluesky por idioma. EN ($n=132.312$), DE ($n=9.686$) e PT ($n=2.661$) médias indicadas na legenda. PT e EN são praticamente indistinguíveis ($d=-0.057$); DE difere por efeito médio ($d=-0.468$).

A Tabela 4.6 e a Figura 4.2 resumem o experimento. Quanto ao par português *versus* inglês, Cohen's $d = -0,057$ é *desprezível* pela escala de [Cohen 1988]. Os testes de Kolmogorov-Smirnov e Mann-Whitney rejeitam a hipótese nula de mesma distribuição com $p < 10^{-5}$, mas é preciso enfatizar que isso ocorre porque $n_{EN} = 132.312$ torna estatisticamente detectável praticamente qualquer diferença real, por menor que seja sua importância prática. O tamanho de efeito, métrica que não se infla com n , é o critério adequado neste regime; e o efeito está bem abaixo do limiar de efeito *pequeno* ($|d| < 0,2$ pela escala de Cohen). Concluímos, portanto, que a diferença entre PT e EN é *estatisticamente detectável mas praticamente irrelevante*. O par alemão *versus* inglês, em contraste, exibe $d = -0,468$ (pequeno, no topo da faixa, próximo do limiar de efeito médio $|d| = 0,5$): posts em alemão apresentam *score* topológico sistematicamente mais baixo (média 0,26, contra 0,40 do inglês). O par PT *versus* DE apresenta $d = +0,739$ (médio-grande), consistente com os pares anteriores: PT está mais próximo de EN do que de DE.

A interpretação da divergência DE *versus* EN exige cautela. É plausível atribuí-la a padrões de engajamento da comunidade germânica no Bluesky, que adotou a plataforma mais tarde e tende a formar um grupo autoselecionado. Mas *hipóteses alternativas são igualmente válidas e não podem ser descartadas sem experimentos adicionais*: (1) *shift* de domínio: o classificador foi treinado em notícias de celebridade/entretenimento (UPFD-GossipCop), enquanto posts DE no Bluesky podem ter perfil temático mais político ou

profissional; (2) viés amostral: os usuários alemães no Bluesky podem constituir subgrupo demográfico específico (*early adopters*, comunidade tech) e não a comunidade germânica como um todo; (3) desbalanço de cobertura: $n_{PT} = 2.661$, $n_{DE} = 9.686$, $n_{EN} = 132.312$ são suficientes para a estimativa pontual do Cohen’s d , mas a cobertura de regimes raros de engajamento é necessariamente desigual.

A resposta refinada à parte (b) da RQ3 é portanto a seguinte: o classificador estrutural *não processa texto algum*, e portanto seu mecanismo é *arquiteturalmente independente do idioma do post*. A consistência empírica dessa independência foi confirmada para o par PT *versus* EN; foi parcialmente refutada para DE *versus* EN, com a causa exata não isolada entre fatores de idioma, de comunidade, de *shift* de domínio e de amostragem.

4.6 Por que GossipCop funciona e PolitiFact não? (RQ2)

A §4.4 mostrou que o desempenho dos modelos topológicos depende drasticamente do *dataset*. A causa estrutural dessa dependência pode ser quantificada antes mesmo de qualquer treinamento, através do tamanho de efeito de Cohen (d) entre as classes *fake* e *real* nas métricas de cascata. A Tabela 4.7 reporta d nas duas métricas de maior efeito (`num_nodes` e `branching_avg`) nos três *datasets*; a Figura 4.3 amplia a análise para quatro métricas (acrescentando `width_max` e `depth_max`) em *forest plot* com os limiares de Cohen sobrepostos.

Tabela 4.7: Análise estrutural fake vs real – separabilidade por métrica topológica. Cohen’s d : $|d| \geq 0.5$ medio, ≥ 0.8 grande.

Dataset	Métrica	media _{fake}	media _{real}	Cohen’s d	p -valor
fnn	num_nodes	69.67	60.91	+0.223	0.002331
fnn	branching_avg	68.67	59.91	+0.223	0.002331
upfd_politifact	num_nodes	114.92	146.57	-0.245	0.03147
upfd_politifact	branching_avg	7.33	7.01	+0.059	0.6057
upfd_gossipcop	num_nodes	76.16	38.87	+0.905	0
upfd_gossipcop	branching_avg	23.61	7.50	+1.534	0




Figura 4.3: *Forest plot* de Cohen's d entre fake e real para cada métrica estrutural, em cada *dataset*. Linhas pontilhadas indicam limiares de Cohen (0.2 / 0.5 / 0.8). UPFD-GossipCop apresenta efeito *grande* ($d=+1.53$) em *branching factor*; UPFD-PolitiFact e FakeNewsNet ficam abaixo do limiar de efeito *médio* ($|d| < 0.5$); o máximo é $|d| \approx 0.25$.

A diferença entre domínios é drástica: o UPFD-GossipCop apresenta $d = +1.53$ em *branching factor* (efeito *grande* pela escala de Cohen) e $d = +0.91$ em *num_nodes*; ambas as métricas mostram cascatas sistematicamente maiores e mais ramificadas nas notícias falsas. O UPFD-PolitiFact, em contraste, não alcança nem mesmo um efeito médio em nenhuma das métricas avaliadas: o máximo é $|d| = 0.25$ em *num_nodes*, abaixo do limiar de 0.5. O FakeNewsNet apresenta $|d| \approx 0.22$ em *num_nodes* e *branching_avg*, valores matematicamente idênticos porque, em grafo-estrela, o *branching* médio coincide com *num_nodes*−1, dado que apenas o nó raiz é não-folha.

Um padrão transversal merece registro: nas três bases, a métrica *depth_max* concentra os menores tamanhos de efeito: $d = 0.00$ no FNN, $d = -0.17$ no UPFD-PolitiFact e $d = -0.07$ no UPFD-GossipCop. Em palavras, em *nenhum* dos três *datasets* notícias falsas se propagam de forma mais profunda que verdadeiras. O que distingue *fake* de *real* em UPFD-GossipCop, quando distingue, é a *extensão horizontal* da difusão (largura, ramificação e número total de participantes), *não* o alongamento vertical das cadeias de recompartilhamento. Esta assimetria entre eixos tem consequência direta sobre quais *features* concentram sinal: *branching_avg* e *num_nodes* discriminam onde há sinal para discriminar; *depth_max* permanece, em todos os domínios, métrica de *contexto estrutural*, não de classe.

Este resultado tem fundamentação teórica na literatura de *homofilia* e *assortatividade* em redes. Newman [Newman 2003] estabelece que redes nas quais nós da mesma classe

se conectam preferencialmente exibem assortatividade alta; Pei et al. [Pei et al. 2020] demonstram que GNNs convolucionais dependem justamente de assortatividade por classe para serem efetivas. Em UPFD-GossipCop, *fake* e *real* são *estruturalmente assortativos* no sentido de Pei: cada classe forma cascatas com perfis de *branching* distintos e o operador de agregação do GNN tira proveito dessa separação. Em UPFD-PolitiFact, a ausência de assortatividade impede o operador de construir representações nodais que distingam as classes; qualquer arquitetura, não apenas SAGE, colapsa sob essa condição.

A tese central deste trabalho está operacionalizada nesse fenômeno: *modelos topológicos exigem diferença estrutural entre classes da ordem de magnitude de um efeito médio de Cohen ($|d| \geq 0,5$) em pelo menos uma métrica de cascata para serem efetivos*. Sua formulação deliberadamente falsificável e o critério de contra-evidência estão em §2.9.6.

4.7 Concordância textual $\times$ topológico (RQ1)

A pergunta interessante a respeito do classificador textual e do topológico tomados em conjunto não é qual dos dois é melhor (isso já foi respondido em §4.3), mas *onde os dois discordam e quem acerta nas discordâncias*. Para respondê-la, aplicamos os dois classificadores aos 3.826 grafos do *test set* do UPFD-GossipCop e cruzamos suas predições. A Tabela 4.8 reporta as taxas agregadas; a Figura 4.4 mostra a distribuição dos *scores* em *scatter* bidimensional, com os quadrantes indicando concordância e discordância.

Tabela 4.8: Comparacao TEXTUAL vs TOPOLOGICO no UPFD-GossipCop – concordancia, kappa, e desempenho condicional.

Metrica	Valor
F1-macro textual (LogReg-content)	0.9540
F1-macro topologico (RF estrutural)	0.7534
Agreement rate	0.7588
Cohen’s kappa	0.5179
F1 quando AMBOS concordam	0.9662
F1 textual quando DISCORDAM	0.9139
F1 topologico quando DISCORDAM	0.0845




Figura 4.4: *Scatter score* textual (LogReg-BERT) $\times$ topológico (SAGE estrutural) no UPFD-GossipCop *test*. Quadrantes indicam concordância em FAKE (canto inferior-esquerdo) e em REAL (canto superior-direito); discordância ocupa os outros dois quadrantes.

Tomados isoladamente, o textual atinge F1-macro de 0,954 e o topológico, 0,753, conforme reportado na Tabela 4.8. A taxa de concordância agregada é de 75,9% (Cohen’s $\kappa = 0,518$, concordância moderada). Quando ambos concordam, o F1 conjunto é de 0,966, próximo do máximo teórico. Quando discordam, o textual mantém F1 de 0,914, mas o topológico cai a **0,085**.

Esse valor de 0,085 merece interpretação cuidadosa. Ele está *substancialmente abaixo* de duas referências: do nível de chance ($\approx 0,50$ em problema balanceado) e da predição puramente majoritária ($\approx 0,33$). No subconjunto de discordância, portanto, o classificador topológico erra abaixo do que erraria uma predição aleatória: seus rótulos estão anticorrelacionados com a classe verdadeira, ou seja, sistematicamente invertidos. A explicação desse fenômeno é uma *inversão distributiva*: a relação entre estrutura e classe está aproximadamente espelhada nesse subconjunto, em relação ao que prevalece no treinamento.

O RF aprendeu a regra geral “*fake* = grau de raiz alto” no UPFD-GossipCop (Cohen’s $d = +1,53$ em *branching*, §4.6, confirma essa regra no agregado), mas as previsões em que discorda do textual são justamente: (i) notícias *reais* que viralizaram fortemente, com grau de raiz alto, levando o RF a prever *fake* e errar; e (ii) notícias *fake* de propagação contida, com grau de raiz baixo, levando o RF a prever *real* e errar. A §4.9.3 caracteriza esses dois subgrupos numericamente, confirmando que o SAGE acerta zero de 31 *fakes* contidos e apenas 43% dos 60 *reais* virais.

Esse comportamento de inversão *justifica* a regra dual apresentada a seguir, não a contradiz: o topológico só é confiável quando concorda com o textual; quando discorda, está sinalizando precisamente o subconjunto em que sua regra estrutural falha por construção. A regra adotada na ferramenta web, Equação (4.1) e Figura 4.5, encarna essa lógica: pesos iguais quando os dois concordam, peso 4 vezes maior para o textual quando discordam.

$$\text{score}_{\text{final}} = \begin{cases} 0.5 \cdot s_T + 0.5 \cdot s_K & \text{se } \text{pred}_T = \text{pred}_K \\ 0.8 \cdot s_T + 0.2 \cdot s_K & \text{se } \text{pred}_T \neq \text{pred}_K \end{cases} \quad (4.1)$$




Figura 4.5: Fluxograma da regra dual de combinação textual × topológico, derivada *post-hoc* dos resultados de §4.7.

4.8 GNNExplainer: o que o SAGE aprendeu

Mostrar que o SAGE estrutural atinge $F1 = 0,810$ no UPFD-GossipCop não explica *qual sinal* o modelo está usando para decidir. Para abrir essa caixa-preta, aplicamos o GNNExplainer [Ying et al. 2019] sobre 20 grafos do *test set*, estratificados em quatro

células (classe $\times$ tamanho da cascata), e agregamos a massa de importância atribuída pelo método às arestas, segmentada por *hop distance* a partir da raiz. A Figura 4.6 reporta a fração de massa em arestas a 1-hop, 2-hop e 3+ hops, para cada um dos quatro estratos.




Figura 4.6: Fração de massa de importância em arestas a 1-hop, 2-hop e 3+ hops da raiz, agregado por estrato (classe $\times$ tamanho). Assimetria FAKE *vs* REAL: para FAKE, o SAGE concentra quase toda a decisão em arestas 1-hop (raiz $\rightarrow$ filhos diretos); para REAL-grande, distribui entre *hops* mais distantes.

O achado central é uma *assimetria sistemática por classe* no padrão de importância espacial. Para os grafos da classe *fake* (pequenos e grandes, $N = 10$), a fração de massa em arestas a 1-hop, da raiz a seus filhos diretos, está praticamente saturada, entre 0,97 e 1,00. Para a classe *real*-grande ($N = 5$), a fração a 1-hop cai para 0,50 a 0,62, com massa significativa redistribuída para arestas mais distantes da raiz. Os cinco grafos *real*-pequena não exibem padrão consistente e são reportados aqui como observação preliminar, dado o N insuficiente para conclusão firme.

A interpretação desta assimetria é que o SAGE estrutural aprendeu uma heurística diferenciada para cada classe: para *detectar fake*, ele se detém quase exclusivamente no entorno imediato da raiz (consistente com o sinal de *branching factor* alto que caracteriza fake news na agregação da §4.6); para *confirmar real*, sobretudo em cascatas grandes, ele precisa *buscar* informação mais profundamente na árvore. Quantitativamente, esse esforço adicional rende ganho: o RF tabular alimentado apenas com `[num_nodes, grau_root]` atinge F1-macro de 0,753 no mesmo *test set*, ao passo que o SAGE atinge 0,814, diferença de +6,1 pontos percentuais absolutos atribuível ao acesso à topologia multi-hop. A §4.9.4 estratifica esse ganho por profundidade de cascata e mostra que ele se concentra fortemente nos grafos mais profundos, consistente com a leitura dada aqui pelo *GNNEExplainer*.

A mesma análise aplicada ao UPFD-PolitiFact (painel direito da Figura 4.6) oferece confirmação mecanicista do colapso reportado em §4.4: a assimetria classe-a-classe *desaparece*, e tanto grafos *fake* quanto *real* apresentam massa de importância concentrada em 1-hop, sem diferenciar a heurística entre as classes. É o que se espera quando não há sinal

estrutural a explorar (cf. Cohen’s d desprezível em todas as métricas, §4.6): o modelo se reduz a uma regra única e degenerada, e o $F1 \approx 0,33$ que observa-se no agregado não é falha de implementação, mas referência adicional para a leitura dada acima.

Esta assimetria tem implicação prática para a ferramenta web documentada no Apêndice D: a concentração de massa em *1-hop* pode ser exposta na interface como *proxy de confiança* do modelo: predições *fake* com $h_1 \approx 1$ correspondem a casos em que o modelo decidiu sob sinal forte; predições *real* com $h_1 < 0,7$ correspondem a casos em que o modelo precisou de mais informação para concluir, sinalizando incerteza relativa.

4.9 Análise estratificada do erro

As seções anteriores reportam o $F1$ *agregado* do SAGE estrutural em UPFD-GossipCop ($F1 = 0,810$). Este número único esconde três comportamentos distintos do modelo, que a presente seção isola com três lentes complementares aplicadas sobre os 3.826 grafos do *test* sem nenhum re-treino do classificador (*leakage* controlado por construção): uma lente *contínua* (regressão local LOWESS da probabilidade de acerto em função das métricas estruturais), uma lente *categórica* (seis subgrupos extremos definidos *post-hoc* via percentil empírico) e uma lente *ordinal* (estratificação por profundidade da cascata, com intervalos de confiança *bootstrap*). Os achados desta seção transformam o resultado agregado em diagnóstico operacional sobre *onde* cada modelo funciona e *onde* colapsa: distribuição mais pesada que lognormal, inversão distributiva confirmada em subgrupos nomeados, e *gap* SAGE–RF crescendo monotonicamente com a profundidade da cascata.

4.9.1 Distribuição estrutural: *heavy-tail* mais agressivo que log-normal

A escolha entre estratificar por percentil ou por *z-score* depende de qual família de distribuições descreve adequadamente as métricas estruturais do *test set*. A Figura 4.7 ajusta uma distribuição lognormal a cada uma das três métricas (`num_nodes`, `depth_max`, `branching_avg`) e submete o ajuste a teste de Kolmogorov-Smirnov.




Figura 4.7: Histograma das três métricas estruturais (eixo x em escala logarítmica para `num_nodes`) com ajuste de distribuição lognormal sobreposto. Teste KS rejeita o *fit* em todas ($p < 10^{-11}$), indicando cauda mais pesada que lognormal.

O *fit* é rejeitado nas três métricas ($p < 10^{-11}$ em todas), o que indica que a cauda das distribuições estruturais é *mais agressiva* do que aquilo que uma lognormal descreve, regime consistente com a literatura clássica de redes sociais, em que distribuições de grau e de cascata seguem tipicamente leis de potência ou variantes *power-law-like* [Barabási e Albert 1999, Clauset, Shalizi e Newman 2009, Newman 2003]. A consequência metodológica é direta: *z-score* como critério de outlier seria mal-definido neste regime, porque a média e o desvio-padrão amostrais são dominados por poucos pontos da cauda e não caracterizam o “centro” da distribuição. Adotamos, portanto, **percentil empírico** (p5/p95 sobre o próprio *test*) como definição de extremo em todas as análises desta seção, e *plots* envolvendo `num_nodes` usam eixo logarítmico em x por consistência com a forma da distribuição subjacente.

4.9.2 LOWESS: onde o modelo degrada

A primeira lente é *contínua*: para cada uma das três métricas estruturais, estima-se uma curva de probabilidade de acerto em função da métrica, com suavização por *rolling-mean* (LOWESS, [Cleveland 1979]) em janela proporcional. A Figura 4.8 mostra essas curvas para o RF tabular e para o SAGE estrutural lado a lado; a Figura 4.9 repete a leitura em versão discreta por tercil estrutural, para ancorar quantitativamente o que a curva suavizada indica.




Figura 4.8: Probabilidade de acerto suavizada (*rolling-mean* de janela proporcional, 10% da amostra) do RF tabular e do SAGE estrutural em função de cada métrica estrutural no UPFD-GossipCop test. Linha pontilhada cinza marca o *chance level*. SAGE supera RF de forma crescente em **num_nodes** e **depth_max**; o gap em **branching_avg** é maior na região mediana.




Figura 4.9: F1-macro de RF e SAGE por tercil estrutural – versão discreta da Figura 4.8. Em **num_nodes**, SAGE cresce monotonicamente (T1 $\rightarrow$ T3); RF decresce. Em **depth_max**, distribuição discreta colapsa o tercil intermédio.

A leitura combinada das duas representações é que *não existe um modelo globalmente superior*: o RF tabular e o SAGE estrutural atravessam suas curvas em pontos distintos do espaço de métricas. Em **num_nodes**, o SAGE *sobe* ao longo dos tercis enquanto o RF *desce*, cruzamento que indica que a vantagem da rede neural concentra-se em grafos suficientemente grandes para que haja estrutura de propagação a ser explorada por agregação *multi-hop*; em grafos pequenos, a topologia degenera para padrão próximo da estrela rasa e o operador de agregação perde poder discriminativo (compatível com a interpretação mecanicista da §4.6, em que o sinal estrutural de UPFD-GossipCop está no *branching factor*). Em **branching_avg**, o padrão é em U: ambos os modelos erram mais nos extremos. A curva por **depth_max** antecipa o achado mais quantificado da §4.9.4: o *gap* SAGE–RF cresce com a profundidade. As duas subseções seguintes isolam numericamente esses dois fenômenos: a inversão do modelo em subgrupos extremos (§4.9.3) e o crescimento do *gap* com a profundidade (§4.9.4).

4.9.3 Outliers e a inversão distributiva

A segunda lente é *categórica*: usa o percentil empírico definido na §4.9.1 para isolar seis subgrupos extremos do *test set* e mede acurácia do RF e do SAGE em cada um deles. A Tabela 4.9 reporta os tamanhos e as acurácias por subgrupo; a Figura 4.10 traz a mesma leitura em barras com *baseline* agregado sobreposto, e a Figura 4.11 contrasta a composição real de cada subgrupo com a proporção predita pelo modelo, expondo visualmente onde a regra estrutural se inverte.

Tabela 4.9: Acuracia do RF estrutural e do SAGE em seis subgrupos extremos do UPFD-GossipCop *test*. Subgrupos derivados *post-hoc* via percentil empírico (não *z*-score, justificado pela rejeição do *fit* lognormal em §4.9.1). Δ = diferença vs. acurácia agregada (RF=0.754, SAGE=0.814). *Subgrupos com classe única não admitem F1-macro.

Subgrupo	<i>N</i>	acc RF (Δ)	acc SAGE (Δ)	F1m RF	F1m SAGE
real_viral	60	0.233 (−0.520)	0.433 (−0.381)	—*	—*
fake_contido	31	0.000 (−0.754)	0.000 (−0.814)	—*	—*
cauda_alta_n	192	0.547 (−0.207)	0.823 (+0.009)	0.506	0.816
cauda_baixa_n	265	0.913 (+0.160)	0.913 (+0.099)	0.477	0.477
deep_extreme	256	0.531 (−0.222)	0.762 (−0.052)	0.528	0.741
wide_extreme	192	0.932 (+0.179)	0.974 (+0.160)	0.600	0.493




Figura 4.10: Acurácia do RF e do SAGE em seis subgrupos extremos definidos *post-hoc* via percentil empírico (p5/p95 sobre o *test*). Linhas pontilhadas indicam baselines agregados. O subgrupo *fake_contido* (notas falsas com baixo engajamento) e o *real_viral* (notícias verdadeiras que viralizaram) caem abaixo da chance – confirmam a inversão distributiva descrita em §4.7.




Figura 4.11: Composição real (% *fake* verdadeira) *vs.* proporção predita pelo modelo, por subgrupo. Linhas com cor diferente em uma mesma coluna indicam que o modelo não reproduz a distribuição de classes do subgrupo – característico de `real_viral` (linha “% predito fake” alta enquanto “% fake verdadeira” = 0).

A §4.7 descreveu narrativamente a inversão distributiva do classificador estrutural: no subconjunto de discordância com o textual, o SAGE atingia $F1 = 0,085$: *abaixo* do nível da chance. Aqui esse efeito aparece quantificado, subgrupo a subgrupo. Os seis subgrupos são todos derivados de cortes em percentis empíricos do próprio *test*: `fake_contido` (*fakes* com grau de raiz $\leq p5$), `real_viral` (*reais* com grau de raiz $\geq p95$), `cauda_alta_n` e `cauda_baixa_n` (extremos de tamanho da cascata), `deep_extreme` (profundidade ≥ 5) e `wide_extreme` (*branching factor* acima do $p95$).

Três achados se destacam. O primeiro: dos 31 grafos de `fake_contido`, o SAGE acerta **zero** (acurácia 0,000, inversão total da regra aprendida). O segundo: dos 60 grafos de `real_viral`, o SAGE acerta apenas 26 (acurácia 0,433), *abaixo da chance* de 0,50 em problema balanceado. Esses dois subgrupos são os contra-exemplos exatos da regra implicitamente aprendida pelo classificador estrutural (“*fake* = cascata grande, *real* = cascata pequena”): *fakes* contidas violam o primeiro laço da regra, *reais* virais violam o segundo, e o modelo erra precisamente nesses violadores. É a *inversão distributiva* já descrita em §4.7, agora localizada nos dois subgrupos que a produzem. O terceiro achado oferece o contraponto positivo: em `cauda_alta_n` ($N = 192$ grafos com `num_nodes` acima do $p95$), o SAGE atinge 0,823 contra 0,547 do RF, *gap* de aproximadamente 28 pontos percentuais absolutos. Quando a topologia oferece estrutura suficiente, a arquitetura neural extrai sinal que o tabular não alcança.

Esta subseção fornece a justificativa empírica mais forte para a assimetria 0,8/0,2 da regra dual (§4.7): quando o classificador estrutural discorda do textual, está sinalizando que possivelmente caiu em um dos subgrupos onde sua regra falha; pesar quatro vezes

mais o textual nesse regime é instanciação direta do diagnóstico aqui construído. A caracterização explícita dos subgrupos onde o modelo erra sistematicamente também é insumo direto para a discussão de limitações (Capítulo 5, §5.3) e para o desenho da interface da ferramenta web descrita no Apêndice D, em que predições nesses subgrupos podem ser sinalizadas como “requer revisão humana”.

4.9.4 Cascatas profundas: o ganho cresce com a profundidade

A terceira lente é *ordinal*: estratifica o *test set* por profundidade da cascata e mede separadamente o desempenho do RF tabular e do SAGE estrutural em cada estrato. Essa lente só faz sentido se houver cascatas profundas suficientes no *dataset*: a Figura 4.12 mostra a distribuição da profundidade máxima no *test*.




Figura 4.12: Distribuição de profundidade máxima da cascata (*depth_max*) no UPFD-GossipCop *test*. 70% dos grafos tem profundidade 2 (estrela rasa); 30% tem profundidade ≥ 3 , com cauda estendendo-se até 9 *hops*. Contraria a premissa comum de que UPFD é “somente estrela plana”.

Confirmada a heterogeneidade, prosseguimos com a estratificação. A Tabela 4.10 reporta o *F1*-macro do RF tabular e do SAGE estrutural acumulado em três *subsets* de profundidade crescente, com intervalos de confiança *bootstrap*; a Figura 4.13 desagrega esses mesmos dados por valor exato de *depth_max*, e a Figura 4.14 mostra o *gap* SAGE–RF com barras de IC para os três *subsets*.

Tabela 4.10: Ganho do SAGE estrutural sobre o RF tabular em subsets de profundidade da cascata no UPFD-GossipCop *test*. Intervalo de confiança 95% via *bootstrap* pareado ($n_{boot} = 2000$). Todos os *subsets* apresentam ganho do SAGE significativo (IC não cruza zero). A magnitude do ganho cresce com a profundidade – consistente com a tese de que o SAGE explora propagação multi-hop, não apenas tamanho.

Subset	N	F1m RF	F1m SAGE	Diff	IC 95%
$\text{depth} \geq 1$ (todos)	3826	0.753	0.814	+0.060	[+0.047, +0.074]
$\text{depth} \geq 3$	1143	0.657	0.791	+0.134	[+0.103, +0.165]
$\text{depth} \geq 5$	256	0.528	0.741	+0.213	[+0.139, +0.287]




Figura 4.13: F1-macro do RF tabular e do SAGE estrutural por valor exato de `depth_max`. O *gap* cresce monotonicamente: +0.029 em `depth=2`, +0.130 em `depth=3`, +0.230 em `depth=5`, +0.383 em `depth=7`.




Figura 4.14: Diferença $F1(\text{SAGE}) - F1(\text{RF})$ em *subsets* de profundidade crescente, com IC 95% *bootstrap* ($n_{boot} = 2000$). Barras verdes indicam *subsets* onde o IC inferior é estritamente positivo (SAGE significativamente melhor). O *gap* em $\text{depth} \geq 5$ é $3,5 \times$ o agregado – evidência direta de que o SAGE explora propagação *multi-hop*, não só tamanho.

A Figura 4.12 desfaz uma premissa comum sobre o *dataset*: o UPFD-GossipCop oficial *não é* composto apenas por estrelas rasas. Dos 3.826 grafos do *test*, 2.683 (70,1%) têm profundidade máxima 2 (de fato estrelas), mas os 1.143 restantes (29,9%) têm profundidade ≥ 3 , com cauda estendendo-se até 9 *hops*. Esta heterogeneidade estrutural é o que permite a estratificação seguinte.

O *gap* entre RF e SAGE cresce monotonicamente: +0,029 em $\text{depth} = 2$, +0,130 em $\text{depth} = 3$, +0,230 em $\text{depth} = 5$ e +0,383 em $\text{depth} = 7$. Em valores acumulados, o *gap* é de +0,060 no agregado (todos os 3.826 grafos, $IC_{95\%} [+0,047, +0,074]$), sobe para +0,134 em $\text{depth} \geq 3$ ($N = 1.143$, $IC_{95\%} [+0,103, +0,165]$) e atinge +0,213 em $\text{depth} \geq 5$ ($N = 256$, $IC_{95\%} [+0,139, +0,287]$). Os intervalos de confiança foram obtidos por *bootstrap* pareado de 2.000 reamostragens [Efron e Tibshirani 1993] e **não cruzam zero em nenhum dos recortes**; o SAGE é significativamente melhor que RF em todos os três. A Figura 4.14 sintetiza visualmente: a razão entre o *gap* em $\text{depth} \geq 5$ e o agregado é de aproximadamente $3,5 \times$, evidência direta de que o ganho da arquitetura neural sobre o tabular *não é uniforme*: concentra-se justamente onde existe estrutura *multi-hop* a ser explorada.

A leitura mecanicista coerente com este achado encontra-se na §4.8: o GNNExplainer mostrou que o SAGE, em grafos *fake* (tipicamente de *branching* alto), concentra quase toda a massa de importância em arestas a 1-*hop* da raiz, portanto exatamente o sinal que o RF tabular acessa via `[num_nodes, grau_root]`; em grafos *real* de cascata grande, o SAGE redistribui importância para *hops* mais distantes, acessando informação que o

tabular não consegue representar. É essa segunda capacidade, a propagação multi-hop, que se materializa numericamente no *gap* crescente da Figura 4.13.

Vale uma distinção terminológica: a observação de que “UPFD-GossipCop oficial possui 30% de grafos com $\text{depth} \geq 3$ ” contradiz a leitura simplificada de que “UPFD é tudo estrela”. Esta segunda formulação, que encontramos em discussões preliminares deste trabalho, *não se aplica* ao *dataset* oficial de Dou et al. [Dou et al. 2021]; aplica-se apenas ao FakeNewsNet que construímos a partir do repositório CSV (limitação (a) da §5.3), em que a ausência de parentesco entre *retweets* força o grafo a degenerar em estrela rasa.

Síntese da §4.9

A estratificação agregou três contribuições ao trabalho. Primeira: confirmou numericamente, com N s explícitos e acurácias nominais, a inversão distributiva que a §4.7 havia descrito apenas em forma narrativa, localizando-a especificamente em `fake_contido` ($N = 31$, acurácia 0,000) e em `real_viral` ($N = 60$, acurácia 0,433). Segunda: demonstrou que o $F1 = 0,810$ agregado do SAGE em UPFD-GossipCop não se distribui uniformemente: o *gap* sobre o RF tabular cresce de +0,060 no agregado para +0,213 em cascatas com $\text{depth} \geq 5$, com IC *bootstrap* que não cruza zero. Terceira: caracterizou explicitamente os subgrupos em que o modelo falha, fornecendo material direto para a discussão de limitações (§5.3) e para o desenho da interface da aplicação demonstrativa (Apêndice D).

4.10 Painel mestre dos achados

Para encerrar o capítulo, condensamos em uma única figura o conjunto de F1-macro produzidos pelos experimentos das seções anteriores, de modo a permitir tanto a comparação *entre domínios* (fixando o tipo de modelo) quanto *entre tipos de modelo* (fixando o domínio). A Figura 4.15 traz essa consolidação, com três barras por *dataset* codificadas por cor: **azul** para o modelo textual (LogReg-BERT-raiz), **verde** para o modelo topológico puro (GNN sem texto) e **vermelho** para o modelo completo (GNN com *feature* textual).




Figura 4.15: Painel mestre: F1-macro por *dataset* $\times$ tipo de modelo. Azul = textual (LogReg-BERT-raiz); verde = topológico puro (GNN sem texto); vermelho = completo (GNN com *feature* textual). O contraste entre GossipCop e PolitiFact é manifesto: topologia pura aproxima-se da textual no primeiro; despenca para próximo de *chance* no segundo.

A leitura horizontal, entre *datasets* dentro de uma mesma cor, expõe a desigualdade que fundamenta a tese central: em UPFD-GossipCop, o modelo topológico puro aproxima-se do textual e se reconcilia com ele no modelo completo; em UPFD-PolitiFact, o topológico puro despenca para nível próximo da chance enquanto o textual mantém desempenho elevado, e o modelo completo não recupera nada além do que o texto já oferecia. A leitura vertical, entre cores dentro de um mesmo *dataset*, expõe o achado complementar: a *magnitude do ganho* aportado pela topologia ao texto depende criticamente do domínio, e essa dependência está operacionalizada pelo Cohen's d entre as classes (§4.6). É a esses dois eixos (horizontal e vertical) que os Capítulos seguintes voltarão para discutir limitações e direções futuras.

Capítulo 5

Discussão e Conclusão

Este capítulo é o lugar onde se assume responsabilidade pelo que os experimentos efetivamente mostraram. Cada afirmação quantitativa aqui apresentada é ancorada na tabela, figura ou seção que a sustenta; afirmações sem essa âncora foram deliberadamente excluídas.

5.1 Síntese dos achados por pergunta de pesquisa

RQ1: a topologia carrega sinal acima do que o texto da raiz já fornece? A resposta depende do *dataset* e do regime de *features*. No FakeNewsNet, o texto da raiz isoladamente já satura o sinal: o *baseline* LogReg-BERT atinge $F1\text{-macro} = 0,859 \pm 0,043$ sobre 10 *folds* (Tabela 4.2), e nenhuma das três arquiteturas GNN adicionada ao mesmo protocolo (GCN, GAT e SAGE com *features* estruturais sobre o FNN *posfull*) difere significativamente desse valor pelo *ttest_rel* pareado (todos ranqueados como não-significantes em §3.7). No UPFD-GossipCop, ao contrário, a topologia agrega ganho mensurável: o SAGE com *features* estruturais puras atinge $F1 = 0,810 \pm 0,002$ (Tabela 4.5), e a análise estratificada da §4.9 mostrou que esse ganho *cresce monôtonicamente com a profundidade da cascata*: de $+0,060$ no agregado para $+0,213$ em $\text{depth} \geq 5$, com intervalo de confiança *bootstrap* de 2.000 reamostragens que não cruza zero em nenhum dos recortes (Tabela 4.10). Em UPFD-PolitiFact, finalmente, não se detecta ganho topológico significativo: a mesma arquitetura SAGE sem texto colapsa para $F1 = 0,331 \pm 0,009$ (Tabela 4.5), valor abaixo do nível de chance (0,50 em problema balanceado), e as outras duas arquiteturas testadas no mesmo regime ficam pouco acima (0,362 para GCN; 0,380 para GAT), todas em colapso equivalente.

RQ2: sob quais condições estruturais? A resposta foi operacionalizada via tamanho de efeito de Cohen (d) entre as classes em métricas de cascata (§4.6 e Tabela 4.7). O UPFD-GossipCop apresenta $d = +1,53$ no *branching factor* (efeito *grande* pela escala de Cohen) e $d = +0,91$ em *num_nodes* (também grande); o UPFD-PolitiFact não alcança

sequer um efeito médio em nenhuma métrica avaliada, com $|d|$ máximo de **0,25** em `num_nodes`; e o FakeNewsNet apresenta $|d| \approx 0,22$ em `num_nodes` e `branching_avg`, valores matematicamente idênticos por consequência direta da topologia em estrela (em estrela, $\text{branching avg} = \text{num_nodes} - 1$). Este contraste sustenta a **tese central**, que formulamos de modo deliberadamente falsificável:

Modelos topológicos exigem diferença estrutural entre classes da ordem de magnitude de um efeito médio de Cohen ($|d| \geq 0,5$) em pelo menos uma métrica de cascata para serem efetivos; abaixo desse limiar, colapsam, independentemente da arquitetura GNN escolhida.

A tese é refutável: a apresentação de um *dataset* com $0,2 < |d| < 0,5$ no qual uma arquitetura GNN atinja desempenho significativamente acima do *baseline* textual e do RF tabular constituiria contra-evidência direta.

RQ3: é viável detectar fake news apenas pela topologia, em cenários sem texto explorável? A resposta se divide nas duas partes embutidas na pergunta. Quanto à parte (a), viável sem texto algum?, a Tabela 4.5 mostra que sim, mas *condicional* à condição da RQ2: SAGE com duas dimensões estruturais por nó (`is_root`, `grau_norm`) atinge $F1 = 0,810$ em GossipCop, sem nenhum acesso ao conteúdo textual da notícia. Quanto à parte (b), indiferente ao idioma do post?, a §4.5 aplicou o RF estrutural sobre subconjuntos monolíngues do Bluesky e encontrou $\mathbf{d} = -0,057$ entre português e inglês (efeito desprezível) e $\mathbf{d} = -0,468$ entre alemão e inglês (efeito pequeno, no topo da faixa) (Tabela 4.6). Como o classificador estrutural *não processa texto*, seu mecanismo é arquiteturalmente independente do idioma; a divergência DE *vs.* EN não pôde ser isolada entre fator linguístico, fator de comunidade, *shift* de domínio e desbalanço amostral.

5.2 Achado negativo é achado

O resultado de UPFD-PolitiFact merece tratamento explícito porque é metodologicamente tão importante quanto o resultado positivo de UPFD-GossipCop. Não se trata de falha de implementação: a mesma arquitetura, com o mesmo *pipeline*, atinge $F1 = 0,810$ quando treinada em um *dataset* estruturalmente assortativo (Tabela 4.5). Tampouco se trata de inadequação da família GNN em geral: as três arquiteturas testadas (GCN, GAT, SAGE) colapsam de forma equivalente em PolitiFact, respectivamente para 0,362, 0,380 e 0,331. O Cohen’s d desprezível naquele domínio (Tabela 4.7) mostra, no plano descritivo, que *fake* e *real* são *estruturalmente indistinguíveis* nas métricas de cascata avaliadas, e é justamente isso que a tese da §4.6 prevê: causa estrutural identificada, não falha de modelo.

Reportar este achado com a mesma extensão dos achados positivos não é formalismo: é exigência da tese central. Uma teoria que afirma “topologia funciona sob a condição X ” é

fortalecida, não enfraquecida, pela demonstração de que ela *não funciona* quando X falha. A literatura de detecção de fake news com GNNs tende a reportar predominantemente resultados positivos; ao trazer explicitamente o caso negativo, este trabalho oferece o diagnóstico de aplicabilidade, e não apenas mais uma demonstração, que propõe como contribuição primária.

Uma evidência complementar reforça a leitura. A §4.9.3 mostrou que, mesmo no UPFD-GossipCop (onde o modelo *funciona*), há subgrupos extremos em que a regra estrutural aprendida pelo SAGE falha de forma concentrada: dos 31 grafos do subgrupo **fake_contido** (*fakes* com grau de raiz no percentil 5 inferior), o SAGE acerta **zero**; dos 60 grafos do subgrupo **real_viral** (*reais* com grau de raiz no percentil 95 superior), acerta apenas 43%, desempenho abaixo da chance (Tabela 4.9). Esses subgrupos demarcam o *limite operacional* do mecanismo topológico: ele depende de que a regra “*fake* = cascata maior” valha, e erra justamente nos casos em que essa regra não se aplica.

5.3 Limitações

Reconhecemos sete limitações do trabalho, listadas em ordem de importância decrescente.

- (a) **Topologia em estrela no FakeNewsNet construído por nós.** O grafo gerado por `00_construir_grafos_fakenewsnet.py` (§3.3) é sempre uma estrela rasa, pois o CSV bruto do repositório KaiDMML não fornece parentesco entre *retweets* nem *timestamps*. Adicionalmente, o filtro de `MAX_NOS=100` adotado trunca metade dos grafos do *dataset* (verificação matemática em §3.3 mostrou que a distribuição bruta tem média 552 e máximo 29.060 *tweets* por notícia), tornando os 377 grafos truncados indistinguíveis quanto ao tamanho absoluto da cascata. Esta limitação vale exclusivamente para o FakeNewsNet que construímos: no UPFD-GossipCop oficial, 30% dos grafos possuem profundidade ≥ 3 , com cauda até profundidade 9 (§4.9.4).
- (b) **Regra dual derivada *post-hoc* de um único experimento.** A combinação textual + topológico exposta na §4.7 usa pesos 0,8/0,2 derivados após a observação da inversão distributiva no UPFD-GossipCop. Sua generalização a outros domínios é uma conjectura a ser testada, não um resultado validado.
- (c) **Bluesky sem rótulos de veracidade.** O *dataset* de Failla e Rossetti [Failla e Rossetti 2024] não traça rótulos *fake/real*, o que restringe seu uso à parte (b) da RQ3 (§4.5) e à aplicação demonstrativa documentada no Apêndice D, impedindo validação supervisionada nesta fonte. Os rótulos heurísticos por palavras-chave que acompanham nossa publicação do *dataset* processado não foram empregados como supervisão.
- (d) **Reprodutibilidade não *bit-exact*.** Embora todos os *seeds* sejam fixados (42 como semente universal), o não-determinismo de operadores `scatter/gather` do

PyTorch Geometric e a sensibilidade aritmética entre versões de biblioteca podem produzir variações na terceira casa decimal das métricas reportadas. As conclusões qualitativas são robustas a essa variação: os achados centrais foram validados em 10 *seeds* independentes (§4.4) e em *bootstrap* pareado de 2.000 reamostragens (§4.9.4).

- (e) **Ausência de comparativo numérico direto com BiGCN e GCNFN.** Não foi viável re-implementar essas arquiteturas dentro do escopo do trabalho; a comparação com Dou et al. [Dou et al. 2021] é indicativa (Tabela 4.4) por três diferenças declaradas: *feature content* (310d) em vez de *bert* (768d), hiperparâmetros próprios, e métrica F1-macro em vez de acurácia.
- (f) **Bluesky é *snapshot* temporal.** O dado coletado por [Failla e Rossetti 2024] cobre 11 *feeds* temáticos da plataforma em janela de aproximadamente um ano; generalização para janelas temporais futuras não é garantida.
- (g) **Ambiente exclusivamente CPU.** Todos os experimentos foram executados em CPU (Intel *Raptor Lake*, 16 *cores* lógicos, 16 GB de RAM, PyTorch 2.10+cpu). Hiperparâmetros adotados podem ser subótimos em ambientes com GPU; o *pipeline*, no entanto, é portátil.

5.4 Trabalhos futuros

A partir dos resultados obtidos, identificamos quatro direções de continuidade.

(1) Pseudo-rótulos no Bluesky para retreino especializado. A inferência *cross-domain* demonstrada no Apêndice D poderia ser convertida em ciclo de auto-treinamento: usar o LogReg-BERT treinado em FakeNewsNet como oráculo para gerar pseudo-rótulos em um subconjunto de alta confiança do Bluesky, e então retreinar classificadores estruturais especializados para a plataforma. Os 168.463 posts disponíveis (§D.1) tornariam o experimento tratável.

(2) Calibração de probabilidades. O *score* produzido pelo RF estrutural sobre o Bluesky é empregado como *proxy* ordinal (§D.2); transformá-lo em probabilidade calibrada exigiria técnicas como *Platt scaling* ou regressão isotônica, o que demanda subconjunto rotulado no domínio-alvo.

(3) Expansão para *datasets* de noticiário contemporâneo. A existência de pelo menos um domínio com $|d| < 0,5$ (UPFD-PolitiFact) sugere que a tese central possa ser refinada com mais *datasets* de diferentes plataformas (Mastodon, Threads, X pós-2023) e diferentes janelas temporais, testando se o limiar de 0,5 é exato ou apenas ordem de magnitude.

(4) Replicação direta de BiGCN e GCNFN. Para preencher a limitação (e) acima, vale re-implementar essas arquiteturas e submetê-las ao mesmo protocolo de avaliação adotado aqui (mesmo k -fold, mesmo $ttest_rel$ pareado), permitindo confronto *bit-exact* com a literatura.

5.5 Considerações finais

Este trabalho não propôs uma nova arquitetura de Rede Neural de Grafos. Propôs, em seu lugar, um *diagnóstico*: sob quais condições a topologia da propagação detecta fake news, e quando não detecta. Três *datasets*, três arquiteturas e mais de uma dezena de métricas (Tabela 4.1) convergem para uma tese única e refutável: a aplicabilidade depende de assortatividade estrutural mensurável ($|d| \geq 0,5$). A defesa de um resultado negativo (UPFD-PolitiFact) lado a lado de um resultado positivo (UPFD-GossipCop), ancorada em estatística de tamanho de efeito e validada por análise estratificada do erro com *bootstrap* pareado, é a contribuição metodológica que pretendemos seja reaplicável para além deste *dataset* específico. O código, os pesos persistidos no Hugging Face Hub e a ferramenta web (Apêndice D) permitem que esta posição seja contestada empiricamente em outros domínios, exatamente como a tese, por ser falsificável, exige.

Referências Bibliográficas

- [Allcott e Gentzkow 2017]ALLCOTT, H.; GENTZKOW, M. Social media and fake news in the 2016 election. *Journal of Economic Perspectives*, v. 31, n. 2, p. 211–236, 2017.
- [Arias-Mendoza, González-Pardo e Cortés-Peña 2023]ARIAS-MENDOZA, D.; GONZÁLEZ-PARDO, R. E.; CORTÉS-PEÑA, O. Post-truth and fake news in scientific communication in ibero-american journals. *Comunicación y Sociedad*, p. e8442, 2023. Disponível em: <https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S0188-252X2023000100410>.
- [Bakshy, Messing e Adamic 2015]BAKSHY, E.; MESSING, S.; ADAMIC, L. A. Exposure to ideologically diverse news and opinion on facebook. *Science*, v. 348, n. 6239, p. 1130–1132, 2015.
- [Barabási e Albert 1999]BARABÁSI, A.-L.; ALBERT, R. Emergence of scaling in random networks. *Science*, v. 286, n. 5439, p. 509–512, 1999.
- [Bian et al. 2020]BIAN, T. et al. Rumor detection on social media with bi-directional graph convolutional networks. In: *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*. [s.n.], 2020. p. 549–556. Disponível em: <<https://arxiv.org/abs/2001.06362>>.
- [Bronstein et al. 2017]BRONSTEIN, M. M. et al. Geometric deep learning: Going beyond Euclidean data. *IEEE Signal Processing Magazine*, v. 34, n. 4, p. 18–42, 2017.
- [Chu, Xie e Wang 2020]CHU, S. K.-W.; XIE, R.; WANG, Y. Cross-language fake news detection. *Data and Information Management*, v. 5, n. 1, p. 100–109, 2020.
- [Clauset, Shalizi e Newman 2009]CLAUSET, A.; SHALIZI, C. R.; NEWMAN, M. E. J. Power-law distributions in empirical data. *SIAM Review*, v. 51, n. 4, p. 661–703, 2009.
- [Cleveland 1979]CLEVELAND, W. S. Robust locally weighted regression and smoothing scatterplots. *Journal of the American Statistical Association*, v. 74, n. 368, p. 829–836, 1979.
- [Cohen 1988]COHEN, J. *Statistical Power Analysis for the Behavioral Sciences*. 2. ed. Hillsdale, NJ: Lawrence Erlbaum Associates, 1988. ISBN 978-0805802832.

- [Cunha 2021]CUNHA, L. *FakeWhatsApp.BR: Detecção de Desinformação e Desinformadores em Grupos Públicos do WhatsApp em PT-BR*. Dissertação (Mestrado) — Universidade Federal do Ceará, 2021. Disponível em: <https://repositorio.ufc.br/bitstream/riufc/63379/3/2021_dis_lcccunha.pdf>.
- [Demšar 2006]DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006.
- [Devlin et al. 2019]DEVLIN, J. et al. BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT 2019*, 2019. Disponível em: <<https://arxiv.org/abs/1810.04805>>.
- [Dou et al. 2021]DOU, Y. et al. User preference-aware fake news detection. In: *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*. [s.n.], 2021. p. 2051–2055. Disponível em: <<https://arxiv.org/abs/2104.12259>>.
- [Efron e Tibshirani 1993]EFRON, B.; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*. [S.l.]: Chapman & Hall/CRC, 1993.
- [Failla e Rossetti 2024]FAILLA, A.; ROSSETTI, G. “I’m in the Bluesky Tonight”: Insights from a Year’s Worth of Social Data. *PLOS ONE*, v. 19, n. 11, p. e0310330, 2024. Dataset utilizado no Cap 5; disponível no Zenodo, DOI 10.5281/zenodo.14258401.
- [Fan, Hu e Zhao 2025]FAN, H.; HU, X.; ZHAO, G. Cross-lingual social misinformation detector based on hierarchical mixture-of-experts adapter. In: *Proceedings of the 31st International Conference on Computational Linguistics (COLING 2025)*. [s.n.], 2025. Disponível em: <<https://aclanthology.org/2025.coling-main.484.pdf>>.
- [Fey e Lenssen 2019]FEY, M.; LENNSEN, J. E. *Fast Graph Representation Learning with PyTorch Geometric*. 2019. ICLR Workshop on Representation Learning on Graphs and Manifolds. Disponível em: <<https://arxiv.org/abs/1903.02428>>.
- [Gharpure et al. 2020]GHARPURE, R. et al. Knowledge and practices regarding safe household cleaning and disinfection for COVID-19 prevention — united states, may 2020. *MMWR. Morbidity and Mortality Weekly Report*, v. 69, n. 23, p. 705–709, 2020.
- [Hamilton, Ying e Leskovec 2017]HAMILTON, W. L.; YING, R.; LESKOVEC, J. Inductive representation learning on large graphs. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [s.n.], 2017. Disponível em: <<https://arxiv.org/abs/1706.02216>>.

- [Hu, Mao e Zhang 2025]HU, B.; MAO, Z.; ZHANG, Y. An overview of fake news detection: From a new perspective. *Fundamental Research*, v. 5, n. 1, p. 332–346, 2025. Disponível em: <<https://pmc.ncbi.nlm.nih.gov/articles/PMC11955031/>>.
- [Hu et al. 2025]HU, J. et al. Integrating message content and propagation path for enhanced false information detection using bidirectional graph convolutional neural networks. *Applied Sciences*, v. 15, n. 7, p. 3457, 2025.
- [Hussain et al. 2025]HUSSAIN, F. G. et al. Fake news detection landscape: Datasets, data modalities, AI approaches, their challenges, and future perspectives. *IEEE Access*, v. 13, p. 54757–54778, 2025.
- [Jadhav et al. 2025]JADHAV, R. et al. Explainable multilingual and multimodal fake-news detection: toward robust and trustworthy AI for combating misinformation. *Frontiers in Artificial Intelligence*, v. 8, p. 1690616, 2025.
- [Jr., Lim e Ling 2018]JR., E. C. T.; LIM, Z. W.; LING, R. Defining “fake news”: A typology of scholarly definitions. *Digital Journalism*, v. 6, n. 2, p. 137–153, 2018.
- [Kingma e Ba 2015]KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. In: *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*. [s.n.], 2015. Disponível em: <<https://arxiv.org/abs/1412.6980>>.
- [Kipf e Welling 2017]KIPF, T. N.; WELLING, M. Semi-supervised classification with graph convolutional networks. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2017. Disponível em: <<https://arxiv.org/abs/1609.02907>>.
- [Kleppmann et al. 2024]KLEPPMANN, M. et al. *Bluesky and the AT Protocol: Usable Decentralized Social Media*. 2024. ArXiv preprint arXiv:2402.03239. Disponível em: <<https://arxiv.org/abs/2402.03239>>.
- [Kohavi 1995]KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*. [S.l.: s.n.], 1995. p. 1137–1143.
- [Li, Han e Wu 2018]LI, Q.; HAN, Z.; WU, X.-M. Deeper insights into graph convolutional networks for semi-supervised learning. In: *Proceedings of the 32nd AAAI Conference on Artificial Intelligence (AAAI)*. [S.l.: s.n.], 2018. p. 3538–3545.
- [Masters e Luschi 2018]MASTERS, D.; LUSCHI, C. *Revisiting Small Batch Training for Deep Neural Networks*. 2018.
- [McPherson, Smith-Lovin e Cook 2001]MCPHERSON, M.; SMITH-LOVIN, L.; COOK, J. M. Birds of a feather: Homophily in social networks. *Annual Review of Sociology*, v. 27, p. 415–444, 2001.

- [Mikolov et al. 2013]MIKOLOV, T. et al. Efficient estimation of word representations in vector space. In: *International Conference on Learning Representations (ICLR), Workshop Track*. [s.n.], 2013. Disponível em: <<https://arxiv.org/abs/1301.3781>>.
- [Monti et al. 2019]MONTI, F. et al. *Fake News Detection on Social Media using Geometric Deep Learning*. 2019. ArXiv preprint arXiv:1902.06673. Disponível em: <<https://arxiv.org/abs/1902.06673>>.
- [Newman 2003]NEWMAN, M. E. J. Mixing patterns in networks. *Physical Review E*, v. 67, n. 2, p. 026126, 2003. Disponível em: <<https://arxiv.org/abs/cond-mat/0209450>>.
- [Newman 2003]NEWMAN, M. E. J. The structure and function of complex networks. *SIAM Review*, v. 45, n. 2, p. 167–256, 2003.
- [Pei et al. 2020]PEI, H. et al. Geom-gcn: Geometric graph convolutional networks. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2020. Disponível em: <<https://arxiv.org/abs/2002.05287>>.
- [Phan, Nguyen e Hwang 2023]PHAN, H. T.; NGUYEN, N. T.; HWANG, D. Fake news detection: A survey of graph neural network methods. *Applied Soft Computing*, v. 139, p. 110235, 2023. Disponível em: <<https://pmc.ncbi.nlm.nih.gov/articles/PMC10036155/>>.
- [Prechelt 1998]PRECHELT, L. Early stopping — but when? In: ORR, G. B.; MÜLLER, K.-R. (Ed.). *Neural Networks: Tricks of the Trade*. [S.l.]: Springer, 1998, p. 55–69.
- [Reimers e Gurevych 2019]REIMERS, N.; GUREVYCH, I. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. [s.n.], 2019. p. 3982–3992. Disponível em: <<https://arxiv.org/abs/1908.10084>>.
- [Reimers e Gurevych 2020]REIMERS, N.; GUREVYCH, I. Making monolingual sentence embeddings multilingual using knowledge distillation. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. [S.l.: s.n.], 2020. p. 4512–4525.
- [Roumeliotis, Tselikas e Nasiopoulos 2025]ROUMELIOTIS, K. I.; TSELIKAS, N. D.; NASIOPOULOS, D. K. Fake news detection and classification: A comparative study of convolutional neural networks, large language models, and natural language processing models. *Future Internet*, v. 17, n. 1, p. 28, 2025.
- [Sawilowsky 2009]SAWILOWSKY, S. S. New effect size rules of thumb. *Journal of Modern Applied Statistical Methods*, v. 8, n. 2, p. 597–599, 2009.

- [Shu et al. 2020]SHU, K. et al. FakeNewsNet: A data repository with news content, social context, and spatiotemporal information for studying fake news on social media. *Big Data*, v. 8, n. 3, p. 171–188, 2020. Disponível em: <<https://arxiv.org/abs/1809.01286>>.
- [Sibila, Livingston e Takida 2025]SIBILA, C. A.; LIVINGSTON, A. M.; TAKIDA, E. K. *Bluesky Fake News Dataset: A Curated Snapshot of Bluesky Posts and Repost Cascades*. 2025. Hugging Face Datasets. Curado pelos autores a partir do *snapshot* acadêmico de Failla e Rossetti [Failla e Rossetti 2024]; rótulos heurísticos por palavra-chave acompanham o repositório. Disponível em: <<https://huggingface.co/datasets/Zaras210/bluesky-fake-news-dataset>>.
- [Souza 2023]SOUZA, C. E. d. *Deteccão de Fake News em Redes Sociais com o Uso de Redes Neurais Recorrentes, Redes Neurais Gráficas e Transformers*. Dissertação (Mestrado) — Pontifícia Universidade Católica de São Paulo, 2023. Disponível em: <<https://tede2.pucsp.br/bitstream/handle/39999/1/Carlos%20Eduardo%20de%20Souza.pdf>>.
- [Souza 2023]SOUZA, M. C. d. *Deteccão de Desinformação em Redes Sociais com Mecanismos de Atenção*. Tese (Doutorado) — Universidade de São Paulo, 2023. Disponível em: <<https://www.teses.usp.br/teses/disponiveis/55/55134/tde-22122023-125502/>>.
- [Srivastava et al. 2014]SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, v. 15, n. 56, p. 1929–1958, 2014.
- [Vaswani et al. 2017]VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2017. p. 5998–6008.
- [Veličković et al. 2018]VELIČKOVIĆ, P. et al. Graph attention networks. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2018. Disponível em: <<https://arxiv.org/abs/1710.10903>>.
- [Vicario et al. 2016]VICARIO, M. D. et al. The spreading of misinformation online. *Proceedings of the National Academy of Sciences (PNAS)*, v. 113, n. 3, p. 554–559, 2016.
- [Vosoughi, Roy e Aral 2018]VOSOUGHI, S.; ROY, D.; ARAL, S. The spread of true and false news online. *Science*, v. 359, n. 6380, p. 1146–1151, 2018.
- [Watts e Strogatz 1998]WATTS, D. J.; STROGATZ, S. H. Collective dynamics of ‘small-world’ networks. *Nature*, v. 393, n. 6684, p. 440–442, 1998.
- [Xu 2025]XU, K. *Enhancing Fake-News Detection with Node-Level Topological Features*. 2025. ArXiv preprint arXiv:2512.09974. Disponível em: <<https://arxiv.org/abs/2512.09974>>.

- [Xu et al. 2019]XU, K. et al. How powerful are graph neural networks? In: *Proceedings of the 7th International Conference on Learning Representations (ICLR)*. [s.n.], 2019. Disponível em: <<https://arxiv.org/abs/1810.00826>>.
- [Yi et al. 2025]YI, J. et al. *Challenges and Innovations in LLM-Powered Fake News Detection: A Synthesis of Approaches and Future Directions*. 2025. ArXiv preprint arXiv:2502.00339. Disponível em: <<https://arxiv.org/abs/2502.00339>>.
- [Ying et al. 2019]YING, Z. et al. GNNExplainer: Generating explanations for graph neural networks. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [s.n.], 2019. Disponível em: <<https://arxiv.org/abs/1903.03894>>.
- [Yuan et al. 2023]YUAN, H. et al. Explainability in graph neural networks: A taxonomic survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 45, n. 5, p. 5782–5799, 2023.
- [Zhou, Tao e Zhang 2023]ZHOU, L.; TAO, J.; ZHANG, D. Does fake news in different languages tell the same story? an analysis of multi-level thematic and emotional characteristics of news about COVID-19. *Information Systems Frontiers*, v. 25, n. 2, p. 493–512, 2023.

Apêndices

Apêndice A

Hiperparâmetros completos

Este apêndice consolida, para referência integral e reprodução, todos os hiperparâmetros utilizados nos experimentos do Capítulo 4. A Tabela A.1 reproduz a configuração das três arquiteturas GNN; a Tabela A.2 documenta os classificadores *baseline* textuais e tabulares; a Tabela A.3 reúne os parâmetros do protocolo de avaliação estatística; e a Tabela A.5 sumariza o ambiente de execução adotado.

A.1 Arquiteturas GNN

Tabela A.1: Hiperparâmetros das arquiteturas GNN avaliadas em GCN, GAT e SAGE. Defaults idênticos onde não indicado; diferenças anotadas na coluna respectiva.

Hiperparâmetro	GCN	GAT	SAGE
hidden_channels	64	64	64
num_layers	3	3	3
dropout	0,5	0,5	0,5
num_heads (atenção)	–	4	–
aggregator	–	–	mean
pooling	global_mean_pool		
activation	ReLU		
optimizer	Adam [Kingma e Ba 2015]		
learning_rate	10^{-3}	10^{-3}	10^{-3}
weight_decay	5×10^{-4}	5×10^{-4}	5×10^{-4}
batch_size	32	32	32
scheduler	ReduceLROnPlateau (factor = 0,5, patience = 5)		
early_stopping	patience = 7 sobre F1-macro de validação		
max_epochs	30	30	30
seed	42 (com varredura para 10 <i>seeds</i> em §4.4)		

Vetor de entrada por nó:

UPFD (variante profile)	10 dimensões pré-computadas pelo <i>dataset</i>
UPFD (variante content)	310 dimensões (<i>spaCy</i> + <i>profile</i>)
FakeNewsNet (variância posfull)	771 dimensões (768 BERT + 3 posicionais)
Topologia pura (§4.4)	2 dimensões: [is_root, grau_norm]

A.2 Classificadores *baseline*

Tabela A.2: Hiperparâmetros dos classificadores *baseline* textuais e tabulares utilizados nos experimentos.

Classificador	Configuração	Onde usado
LogReg-BERT-título	LogisticRegression(C=1.0, max_iter=1000, class_weight=None) de <i>scikit-learn</i> ; entrada = <i>embedding</i> BERT de 768 dimensões do título.	§4.1
LogReg-BERT- <i>content</i>	Idem acima, sobre a <i>feature content</i> do UPFD (310 dimensões).	§4.3
Random Forest BERT-título	RandomForestClassifier(n_estimators=4200, max_depth=None, min_samples_split=2, random_state=42).	§4.2
Random Forest estrutural	RandomForestClassifier(n_estimators=4200, max_depth=10, min_samples_leaf=5, random_state=42); entrada = [num_nodes, grau_root].	§4.2
Random Forest <i>confound</i>	Idem acima; entrada = apenas num_nodes (1 dimensão).	§4.2

A.3 Protocolo de avaliação estatística

Tabela A.3: Parâmetros do protocolo estatístico adotado.

Parâmetro	Valor / referência
k -fold estratificado	$k = 10$ [Kohavi 1995]
Semente do <code>StratifiedKFold</code>	<code>random_state = 42</code>
Compartilhamento de <i>folds</i>	sim (mesmos <i>folds</i> para todos os modelos comparados)
Teste de significância entre arquiteturas	<code>scipy.stats.ttest_rel</code> (t pareado por <i>fold</i>)
Tamanho de efeito	Cohen's d [Cohen 1988, Sawilowsky 2009]
Limiar adotado para tese central	$ d \geq 0,5$ (efeito médio)
Bootstrap pareado	$n_{\text{boot}} = 2.000$ [Efron e Tibshirani 1993]
Intervalo de confiança	95% (percentis 2,5 e 97,5)
Varredura de <i>seeds</i> (§4.4)	10 <i>seeds</i> independentes (42, 123, 456, 789, 1024, 2048, 4096, 8192)
Critério de decisão final	F1-macro (média sobre <i>folds</i>)

A.4 Construção do FakeNewsNet

Tabela A.4: Parâmetros adotados na construção dos grafos do FakeNewsNet (script `00_construir_grafos_fakenewsnet.py`).

Parâmetro	Valor
Fonte dos CSVs	Repositório KaiDMML/FakeNewsNet [Shu et al. 2020]
Mínimo de <i>tweets</i> por notícia	2 (descarta cascatas degeneradas)
Máximo de nós por grafo	100 (trunca 50% dos grafos, ver §3.3)
Modelo de <i>embedding</i> textual	<code>paraphrase-multilingual-mpnet-base-v2</code> [Reimers e Gurevych 2020]
Dimensões do vetor textual	768
Cache de <i>embeddings</i>	ativado (em disco)
Codificações posicionais	[<code>is_root</code> , <code>grau_norm</code> , <code>pos</code>] (3 dimensões)
Variâncias geradas	<code>posfull</code> , <code>posmin</code> , <code>posgrau</code> (§3.3)
Asserção de sanidade	<code>x.unique(dim=0).shape[0] >= min(num_nos, 3)</code>

A.5 Ambiente de execução

Tabela A.5: Configuração do ambiente computacional adotado em todos os experimentos.

Componente	Configuração
Sistema operacional	Windows 11
Processador	Intel <i>Raptor Lake</i> , 16 <i>cores</i> lógicos
Memória RAM	16 GB
Acelerador gráfico	Não utilizado (todos os experimentos em CPU)
Python	3.12.10
PyTorch	2.10.0+cpu
PyTorch Geometric	2.6.1 [Fey e Lenssen 2019]
scikit-learn	1.5.x
Transformers (Hugging Face)	4.x (para Sentence-BERT)
scipy	1.13.x (para <code>ttest_rel</code> , bootstrap)
Semente universal	42
<i>Tamanho típico de modelo persistido</i>	
LogReg-BERT-título	$\approx 6,9$ KB
Random Forest estrutural	$\approx 9,6$ MB
SAGE estrutural (PyTorch state dict)	≈ 71 KB
<i>Tempo de inferência por amostra (CPU)</i>	
LogReg-BERT-título	$\approx 0,07$ ms
Random Forest estrutural	$\approx 50,8$ ms
SAGE estrutural	$\approx 0,56$ ms
<i>Embedding</i> BERT (<i>forward</i>)	$\approx 17,9$ ms

A reprodução integral dos experimentos requer apenas os artefatos persistidos descritos no Apêndice C e a configuração do ambiente registrada acima. As ressalvas de *não-determinismo* numérico entre máquinas distintas estão documentadas em §3.7.

Apêndice B

Índice geral de figuras e tabelas

Este apêndice consolida em formato único todas as tabelas e figuras geradas pelo *pipeline* experimental do trabalho, indicando para cada artefato o capítulo e a seção em que é referenciado, o conteúdo síntese e o *script* gerador. É referência rápida para auditoria por avaliadores e para reprodução seletiva de subconjuntos do trabalho. As listas formais por página constam dos pré-textuais (Lista de figuras e Lista de tabelas).

B.1 Tabelas

Tabela B.1: Tabelas geradas pelo trabalho, seus papéis no texto e *scripts* geradores.

ID	Conteúdo	Aparece em	Script gerador
T1	<i>Baseline</i> textual (LogReg-BERT, RF-BERT) sobre o FakeNewsNet	§4.1	09_baselines_textuais.py
T2	Significância entre arquiteturas no FNN <i>posfull</i> (<i>ttest_rel</i>)	§4.3	12_signif_archs.py
T3	<i>Cross-dataset</i> UPFD: GCN/GAT/SAGE em PolitiFact e GossipCop	§4.3	13_cross_dataset.py
T4	Topologia <i>sem</i> texto — achado central	§4.4	14_topo_sem_texto.py
T5	Cohen’s <i>d</i> estrutural entre <i>fake</i> e <i>real</i> por métrica	§4.6	15_cohens_d.py
T6	Concordância textual $\times$ topológico em UPFD-GossipCop	§4.7	20_concordancia.py
T7	Decisão bloco único <i>versus mini</i> (<i>deploy</i>)	Ap. D	21_bloco_vs_mini.py
T8	Bluesky: <i>ranking</i> de <i>feeds</i> por <i>score</i> estrutural	Ap. D (§D.2)	18_bluesky_inferencia.py
T9	Bluesky: concordância por bin de tamanho da cascata	Ap. D	22_bluesky_concord.py
T10	UPFD: nossos resultados <i>versus</i> valores publicados em [Dou et al. 2021]	§4.3	13_cross_dataset.py
T11	RQ3 multilíngue: <i>d</i> entre PT/EN/DE no Bluesky	§4.5	19_rq3_multilingual.py
T12	Acurácia em 6 subgrupos extremos definidos <i>post-hoc</i>	§4.9.3	29_outliers.py
T13	<i>Gap</i> F1(SAGE)–F1(RF) por recortes de profundidade	§4.9.4	30_gap_profundidade.py
T14	Síntese de resultados (<i>data-set</i> $\times$ modelo)	§4 (abertura)	24_consolidar_tcc.py

B.2 Figuras

Tabela B.2: Figuras geradas pelo trabalho. Identificadores F1–F35 correspondem aos arquivos persistidos em `Imagens/` do repositório.

ID	Conteúdo	Aparece em	Script
F1	Separabilidade Cohen’s d por métrica e <i>dataset</i>	— (não referenciada na versão final)	15
F2	Distribuições <i>fake vs real</i> por métrica	— (idem)	15
F3	<i>Scatter score</i> textual $\times$ topológico, UPFD-GossipCop	§4.7	20
F4	MINI <i>vs</i> BLOCO grande por <i>dataset</i>	Ap. D	21
F5	Bluesky: distribuições de <i>likes/reposts/replies</i> por <i>feed</i>	—	17
F6	Bluesky: <i>heatmap</i> de Cohen’s d entre <i>feeds</i>	—	17
F7	Bluesky: distribuição de <i>score</i> “ <i>fake-like</i> ” por <i>feed</i>	Ap. D (§D.2)	18
F8	Bluesky: matriz de confusão 2×2 textual $\times$ topológico	— (substituída pelo texto descritivo do Ap. D)	22
F9	Bluesky: concordância por bin de <code>num_nodes</code>	—	22
F10	Bluesky: concordância por <i>feed</i>	—	22
F11	Bluesky: concordância por comprimento de texto	—	22
F13	Visualizações de 6 <i>threads</i> reais do Bluesky com <i>score</i> sobreposto	— (material de portfólio)	23
F14	RQ3: distribuição do <i>score</i> topológico por idioma (PT/EN/DE)	§4.5	19
F15	RQ3: Q-Q plot PT <i>vs</i> EN, DE <i>vs</i> EN	— (matéria suplementar)	19
F16	Painel mestre: F1 por <i>dataset</i> $\times$ tipo de modelo	§4.10	24/27b
F17	<i>Forest plot</i> de Cohen’s d por (métrica $\times$ <i>dataset</i>)	§4.6	15
F18	<i>Heatmap</i> (arquitetura $\times$ <i>feature variant</i> $\times$ <i>dataset</i>)	§4.4	14
F19	GNNExplainer: massa de importância por <i>hop</i>	§4.8	16
F20	Bluesky: <i>cross-tab</i> textual $\times$ topológico	— (substituída no Ap. D)	22/27c
F23	Bluesky: <i>score</i> médio por (<i>feed</i> $\times$ mo-	—	17/27b

Figuras não referenciadas no corpo principal. Os artefatos marcados como “—” na coluna “Aparece em” foram gerados pelo *pipeline* e estão disponíveis no repositório, mas não foram citados na versão final do texto por razões editoriais: ou foram substituídos por descrições textuais condensadas (caso do material Bluesky reposicionado no Apêndice D), ou constituem material suplementar para portfólio e relatórios internos (caso de `F13_threads_bluesky/` e das matrizes de confusão individuais). Sua presença no repositório sustenta reprodutibilidade integral do *pipeline*, não apenas dos gráficos selecionados para o texto.

B.3 *Scripts* de geração

A numeração `NN_*.py` acima refere-se aos *scripts* em `Training/03_Mega_Research/` do repositório, descritos em maior detalhe no Apêndice C. A execução sequencial dos *scripts* 00 a 32, sob o ambiente documentado no Apêndice A, regenera todos os artefatos catalogados neste índice.

Apêndice C

Estrutura do repositório de código

O repositório Git que acompanha este trabalho está organizado em cinco diretórios de primeiro nível, cada um cobrindo uma fase distinta do ciclo experimental: **Training/** concentra os *scripts* de construção de grafos, treinamento e avaliação; **Execution/** arquiva os artefatos persistidos (pesos, resultados, figuras); **Material/** contém os *datasets* brutos e os arquivos do TCC; **Interface/** abriga a aplicação web demonstrativa do Apêndice D; e o nível raiz contém os documentos de controle do trabalho.

C.1 Training/ — *scripts* experimentais

Subdivide-se em três fases históricas, das quais a relevante para a versão final é **Training/03_Mega_Research/**. Os diretórios **01_BlueSky_Pipe/** e **02_UPFD_Benchmark/** correspondem a iterações anteriores do *pipeline* e são mantidos para referência histórica; suas funcionalidades estão consolidadas, em forma refatorada, em **03_Mega_Research/**.

A pasta **Training/03_Mega_Research/** contém 30 *scripts* numerados de 00 a 32 (com sufixos 27b, 27c, 31), organizados pelo papel no *pipeline*:

Construção de grafos:00_construir_grafos_fakenewsnet.py, 01_baixar_dataset_hf.py, 02_construir_grafos_bluesky.py.

Treinamento e benchmark de arquiteturas:03_treinar_gat.py, 04_comparar_gcn_gat.py, 05_treinar_sage.py, 06_comparar_gcn_gat_sage.py, 07_upfd_benchmark_triplo.py, 13_benchmark_upfd_oficial.py.

Avaliação estatística:09_teste_significancia.py (ttest_rel pareado por *fold*); 15_analise_es (Cohen's *d*, T5/F17).

Baselines e diagnósticos:10_baseline_textual.py (LogReg-BERT e RF, T1), 11_diagnostico_ (RF sobre num_nodes), 20_textual_vs_topologico.py (concordância, T6/F3).

Ablation de features:12_ablation_intra_encoding.py, 14_topologia_sem_texto.py (T4/F18, achado central).

Explicabilidade:16_gnn_explainer_upfd.py (F19, F12).

Persistência de modelos:17_persistir_modelos_finais.py (salva LogReg-BERT, RF estrutural e SAGE estrutural em Execution/weights/).

Bluesky:18_analise_bluesky_crossfeed.py, 19_aplicar_modelo_bluesky.py, 22_concordancia.py, 23_visualizar_threads_bluesky.py, 26_rq3_multilingual.py (T11/F14).

Consolidação e publicação:21_bloco_vs_mini.py (T7/F4), 24_consolidar_tcc.py (gera o INDICE.md), 25_publicar_huggingface.py, 27_figuras_comparativas.py, 27b_repintar_figuras_orientador.py (paleta semântica), 27c_matrizes_confusao_mono.py (F33–F35).

Fase 9, estratificação do erro:28_distribuicao_e_estratificacao.py (F25–F27), 29_outliers.py (T12/F29/F30), 30_cascatas_profundas.py (T13/F28/F31/F32).

Anotação de figuras:31_anotar_figuras_cap4.py (sobrepõe círculos+texto em PNGs para versões destacadas em Imagens/anotadas/).

Os *scripts* de definição de arquitetura (gcn_model.py, gat_model.py, sage_model.py) e o utilitário gerar_folds.py ficam na raiz de 03_Mega_Research/.

C.2 Execution/ — artefatos persistidos

Execution/weights/Pesos persistidos dos três classificadores finais empregados no Apêndice D (LogReg-BERT, RF estrutural e SAGE estrutural), produzidos por 17_persistir_modelos.py. Os tamanhos típicos constam da Tabela A.5.

Execution/results/Saídas tabulares (CSVs) e arquivos de relatório (TXT) de cada experimento. Cada *script* de 03_Mega_Research/ grava aqui o conjunto de métricas brutas que alimenta as tabelas e figuras do trabalho. A **figuras_tcc/** subdiretório contém cópias finais das figuras incorporadas no TCC.

Execution/scripts/Utilitários de orquestração (execução em lote, limpeza de cache, sincronização com Hugging Face).

C.3 Material/ — *datasets* e o TCC

Material/politifact/, gossipcop/CSVs brutos do FakeNewsNet baixados do repositório KaiDMML [Shu et al. 2020].

Material/gossipcop_pyg/Versão do GossipCop construída em formato *PyTorch Geometric*.

Material/LIAR/Dataset alternativo usado em ensaios iniciais; não integrado à versão final.

Material/GNN_TCC_atualizado/Fonte canonica deste TCC: arquivos `.tex`, `.bib`, figuras e tabelas. A compilação ocorre nesta pasta. O `abntex2-alf.bst` e o `stub abntex2.cls` acompanham o repositório para garantir compilação em ambientes sem o pacote `abntex2` instalado.

Material/GNN_TCC_extraido/Versões anteriores do TCC, mantidas para referência histórica.

C.4 Interface/ — aplicação web demonstrativa

Interface/frontend/Aplicação Next.js + FastAPI documentada no Apêndice D. O *backend* expõe o *endpoint* `/api/result` que recebe um *post* candidato e devolve os três *scores* (textual, topológico, combinado) acompanhados de *flag* de concordância.

Interface/supabase/Configuração de persistência opcional para histórico de consultas (não essencial à demonstração).

C.5 Documentos de controle (raiz do repositório)

A raiz do repositório contém documentos de controle do trabalho que não integram o texto do TCC mas governam a escrita e a auditoria:

FATOS_TCC.mdCatálogo de fatos verificados (números, métricas, decisões), com estado (✓ verificado, Δ discrepante, ? a verificar) e lista de seis discrepâncias entre o *draft* antigo e os dados reais (D1–D6).

PENDENCIAS_TCC.mdDecisões pendentes e mudanças planejadas mas não executadas; auditoria de cada decisão estrutural do trabalho.

REVISAO_CARA_DE_IA.mdItens pendentes de revisão estilística gerados por análise adversarial automática.

HISTORIA_FASE9.md, MUDANCAS_FASE9.mdDocumentos internos sobre a evolução da análise estratificada (Fase 9).

GUIA_COAUTORES_TCC.md, PROMPT_IA_TCC.mdConvenções de escrita para coautores e para sessões de assistência automatizada.

C.6 Reprodução integral do *pipeline*

Sob o ambiente documentado no Apêndice A (Python 3.12, PyTorch 2.10 + CPU, semente universal 42), a execução sequencial dos *scripts* numerados em `Training/03_Mega_Research/` regenera, na ordem, todos os artefatos catalogados no Apêndice B. A reprodução não é *bit-exact* entre máquinas distintas devido ao não-determinismo de `scatter/gather` do *PyTorch Geometric* (caveat documentado em §3.7); as conclusões qualitativas são robustas a essa variação.

A versão desta tese registrada no Git em `main` corresponde ao *commit* de submissão; futuras iterações do trabalho serão publicadas em *branches* marcadas no mesmo repositório.

Apêndice D

Aplicação demonstrativa: Bluesky e ferramenta web

Este apêndice documenta a aplicação dos modelos persistidos sobre o *dataset* acadêmico do Bluesky e a ferramenta web que integra os classificadores textual e topológico. É matéria *demonstrativa*, não validatória: o Bluesky não possui rótulos *fake/real*, e portanto nenhum *claim* supervisionado é feito a partir deste material. A validação quantitativa do trabalho está inteiramente no Capítulo 4; a parte referente à independência linguística (RQ3-b) está na §4.5.

D.1 O *dataset* Bluesky

Utilizamos o *snapshot* acadêmico publicado por Failla e Rossetti [Failla e Rossetti 2024], que cobre 168.463 posts distribuídos em 11 *feeds* temáticos (*Blacksky*, *News*, *Science*, *Political Science*, entre outros), coletados via AT Protocol [Kleppmann et al. 2024]. O dado é *snapshot* e não amostra probabilística: a limitação temporal está registrada como item (f) da §5.3. O empacotamento publicado pelos autores deste trabalho no Hugging Face Hub [Sibila, Livingston e Takida 2025] preserva a estrutura original dos *feeds* e adiciona rótulos heurísticos por palavra-chave que *não foram empregados* como supervisão em momento algum do *pipeline*.

D.2 Inferência *cross-domain* dos modelos persistidos

Aplicamos o classificador textual (LogReg-BERT-*content* treinado em FakeNewsNet Poli-tiFact) e o classificador topológico (RF estrutural treinado em UPFD-GossipCop) sobre os 168.463 posts e organizamos a saída em duas representações complementares. A Tabela D.1 reporta a média do *score* “*fake-like*” do RF estrutural por *feed*, permitindo o *ranking* relativo entre comunidades; a Figura D.1 mostra a distribuição completa do *score* por *feed*,

expondo a dispersão interna em torno das médias da tabela.

Tabela D.1: Aplicacao do RF estrutural (treinado em GossipCop) sobre 168k posts do Bluesky – ranking de feeds por score ‘fake-like’.

Feed Bluesky	N	Score medio	% pred=fake
Political Science	357	0.6663	69.2%
Blacksky	86490	0.4391	32.0%
What’s History	161	0.3665	28.0%
#Disability	566	0.3475	17.1%
#UkrainianView	2098	0.3377	26.1%
Science	33831	0.3374	23.0%
BookSky	638	0.3210	12.5%
GreenSky	662	0.3120	14.2%
AcademicSky	913	0.3095	10.0%
Game Dev	635	0.2809	4.4%
News	42112	0.2704	6.7%




Figura D.1: Distribuição do *score* “fake-like” produzido pelo RF estrutural sobre os 168.463 posts do Bluesky, estratificada por *feed*.

Limitação explícita de interpretação. O *score* reportado *não é probabilidade calibrada*. É a saída `predict_proba` do RF treinado em UPFD-GossipCop, aplicada a um domínio diferente (Bluesky), sem *ground-truth* que permita calibração por *Platt scaling* ou regressão isotônica. A interpretação correta é como *proxy ordinal*: útil para o *ranking* relativo entre *feeds* reportado na Tabela D.1, não para decisão absoluta. Trabalho futuro (§5.4, item 2) discute essa calibração.

D.3 Concordância textual $\times$ topológico

Sobre uma amostra estratificada de 3.728 posts com cascata mínima para visualização da árvore de propagação, comparamos as predições do classificador textual com as do topológico (novamente: sem *ground-truth*, apenas concordância entre classificadores). A taxa de concordância agregada é moderada, seguindo o mesmo padrão observado em UPFD-GossipCop (§4.7): a faixa $20 \leq n_{\text{nodes}} < 100$ atinge 74,0% de concordância, e a faixa $n_{\text{nodes}} \geq 100$ cai para 55,9%, ainda acima do agregado mas consideravelmente abaixo do pico anterior; *posts* de tamanho médio ($2 \leq n_{\text{nodes}} < 20$) caem na zona cinzenta (42% a 44%). O *feed Political Science* atinge 88,7% de concordância agregada, o mais alto da amostra. Como se trata de um único *feed* e a métrica é apenas concordância entre os dois classificadores (sem *ground-truth*), não é possível afirmar a causa; uma hipótese a investigar é que conteúdo político produza texto e padrão de propagação mais consistentes entre si.

D.4 Ferramenta web

A aplicação web (FastAPI *backend* + Next.js *frontend*) integra os três modelos persistidos em papéis distintos no *endpoint* `/api/result`: o LogReg-BERT-*content* fornece o *score* textual (s_T); o RF estrutural sobre `[num_nodes, grau_root]` fornece o *score* topológico (s_K) que entra na regra dual; e o SAGE estrutural é usado como operando do GNNExplainer para gerar uma justificativa visual da predição em termos de importância por aresta. A combinação $s_T \times s_K$ segue a regra dual derivada *post-hoc* dos resultados do Capítulo 4 (Equação 4.1 e Figura 4.5):

Listing D.1: Trecho da regra dual no *backend* FastAPI.

```
def _combinar_scores(score_textual, score_topo):
    pred_t = score_textual >= 0.5
    pred_k = score_topo >= 0.5
    if pred_t == pred_k:
        return 0.5 * score_textual + 0.5 * score_topo, True
    return 0.8 * score_textual + 0.2 * score_topo, False
```

Os pesos dos três classificadores são carregados a partir de `Execution/weights/` do repositório Git do trabalho (Apêndice C); o *dataset* processado do Bluesky utilizado em produção (com a estrutura de *feeds* e os rótulos heurísticos por palavra-chave aplicados pelos autores) está publicado no Hugging Face Hub [Sibila, Livingston e Takida 2025]. O código da *API*, os *scripts* de inferência e o *frontend* integram o repositório Git. A ferramenta foi construída como prova de conceito de *deploy*, não como produto auditado para uso em moderação real — decisões sobre conteúdo a partir desses *scores* devem

respeitar as limitações documentadas no Capítulo 5, em especial a ausência de calibração de probabilidades e a dependência de assortatividade estrutural do domínio-alvo.