

Detecção de Fake News com Redes Neurais de Grafos: Ablation Sistemática e Diagnóstico de Aplicabilidade Topológica

André Messina Livingston

César Augusto Sibila

Enzo Kikuji Takida

Brasil, 2026

André Messina Livingston

César Augusto Sibila

Enzo Kikuji Takida

**Detecção de Fake News com Redes Neurais de Grafos:
Ablation Sistemática e Diagnóstico de Aplicabilidade
Topológica**

Brasil

2026

Resumo

A detecção de fake news em redes sociais é tradicionalmente abordada por processamento de linguagem natural (PLN), mas essa estratégia perde robustez frente a (i) modelos generativos capazes de produzir texto gramaticalmente impecável e (ii) postagens em idiomas não cobertos por modelos pre-treinados. Este trabalho investiga em que condições a **topologia da propagação** – o padrão com que uma notícia se espalha pela rede – pode complementar ou substituir a análise textual.

Partimos de três perguntas de pesquisa: (RQ1) topologia carrega sinal discriminante acima do que o texto da raiz da árvore de propagação fornece? (RQ2) sob quais condições estruturais? (RQ3) é viável detectar fake news *apenas* pela topologia, em cenários de texto indisponível ou multilíngue?

Realizamos ablation sistemática em três datasets (FakeNewsNet PolitiFact, UPFD-PolitiFact, UPFD-GossipCop), comparando arquiteturas GCN, GAT e GraphSAGE com três variantes de *features* estruturais ($[is_root]$, $[is_root, grau_norm]$, $[is_root, grau_norm, pos]$). Os experimentos são validados com k-fold pareado, teste t pareado (`ttest_rel`) e tamanho de efeito de Cohen (d).

Os achados centrais são bilaterais. **Positivo:** GraphSAGE com apenas duas *features* estruturais por nó atinge F1-macro = 0,810 em UPFD-GossipCop *sem usar texto algum* (10 *seeds*, $\sigma = 0,002$). **Negativo:** a mesma arquitetura colapsa em UPFD-PolitiFact (F1 $\approx 0,33$, abaixo da chance de 0,50). A causa estrutural é identificada via Cohen's d : GossipCop apresenta diferença entre fake e real de $d = +1,53$ no *branching factor* das cascatas; PolitiFact não alcança sequer um efeito médio em nenhuma métrica avaliada ($|d| < 0,5$, com máximo de $|d| = 0,25$ em `num_nodes`). A tese central – formulada de forma falsificável – é que modelos topológicos requerem diferença estrutural entre classes da ordem de magnitude de um efeito médio de Cohen ($|d| \geq 0,5$) para serem efetivos.

Como complemento experimental para a parte (b) da RQ3, aplicamos o classificador estrutural sobre subconjuntos monolíngues de um *snapshot* acadêmico do Bluesky e confirmamos que sua distribuição de *score* é estatisticamente equivalente entre português e inglês ($d = -0,057$), o que sustenta a propriedade de independência linguística do mecanismo. Os pesos persistidos no Hugging Face Hub e a ferramenta web (FastAPI + Next.js) que integra os classificadores estão documentados no Apêndice D.

Palavras-chave: Fake news. Graph Neural Networks. UPFD. FakeNewsNet. Bluesky.

Cohen's d. Encodings posicionais.

Abstract

Fake-news detection in social media is traditionally tackled by Natural Language Processing (NLP), but this strategy loses robustness against (i) generative models capable of producing grammatically impeccable text and (ii) posts in languages not covered by pre-trained models. This work investigates under which conditions **propagation topology** – the pattern by which news spreads through the network – can complement or replace textual analysis.

We pose three research questions: (RQ1) does topology carry discriminative signal beyond what the root-text of the propagation tree provides? (RQ2) under which structural conditions? (RQ3) is it feasible to detect fake news *using topology only*, in scenarios with unavailable or multilingual text?

We perform a systematic ablation on three datasets (FakeNewsNet PolitiFact, UPFD-PolitiFact, UPFD-GossipCop), comparing GCN, GAT and GraphSAGE under three structural feature variants. Experiments are validated with paired k-fold, paired `ttest_rel`, and Cohen’s d effect size.

Findings are bilateral. **Positive:** GraphSAGE with only two per-node structural features achieves $F1\text{-macro} = 0.810$ on UPFD-GossipCop *without using text at all* (10 seeds, $\sigma = 0.002$). **Negative:** the same architecture collapses on UPFD-PolitiFact ($F1 \approx 0.33$, below the chance level of 0.50). The structural cause is identified via Cohen’s d : GossipCop shows a fake-vs-real difference of $d = +1.53$ on cascade branching factor; PolitiFact does not reach even a medium-effect size on any evaluated metric ($|d| < 0.5$, with maximum $|d| = 0.25$ on `num_nodes`). Our central – and falsifiable – thesis is that topological models require class-wise structural differences of at least a Cohen medium-effect magnitude ($|d| \geq 0.5$) to be effective.

As complementary evidence for RQ3 part (b), we apply the structural classifier on monolingual subsets of an academic Bluesky snapshot and confirm that its score distribution is statistically equivalent between Portuguese and English ($d = -0.057$), supporting the linguistic independence of the mechanism. Persisted weights on the Hugging Face Hub and the web application (FastAPI + Next.js) integrating the classifiers are documented in Appendix D.

Keywords: Fake news. Graph Neural Networks. UPFD. FakeNewsNet. Bluesky. Cohen’s d . Positional encodings.

Contents

1	Introdução	4
1.1	Contextualização	4
1.2	Motivação	4
1.3	Perguntas de pesquisa	4
1.4	Contribuições	4
1.5	Estrutura do trabalho	4
2	Fundamentação Teórica	5
2.1	Detecção de fake news: panorama	5
2.2	Grafos e redes sociais	5
2.3	Embeddings textuais	5
2.4	Redes Neurais de Grafos	5
2.4.1	Graph Convolutional Networks (GCN)	5
2.4.2	Graph Attention Networks (GAT)	5
2.4.3	GraphSAGE	5
2.5	Degeneração do GCN com features homogêneas	5
2.6	Encodings posicionais	6
2.7	Explicabilidade em GNNs: GNNExplainer	6
2.8	Validação estatística	6
2.9	Trabalhos relacionados	6
2.9.1	Surveys de GNNs em fake news	6
2.9.2	Métodos GNN canônicos	6
2.9.3	Detecção multilíngue	6
2.9.4	Trabalhos brasileiros relacionados	6
2.9.5	Homofilia e assortatividade em redes	6
2.9.6	Posicionamento deste trabalho	6
3	Metodologia	7
3.1	Visão geral do pipeline	7
3.2	Datasets	7
3.3	Construção de grafos: FakeNewsNet	7

3.4	Folds compartilhados	8
3.5	Arquiteturas GNN e hiperparâmetros	9
3.6	<i>Baselines</i> não-GNN	10
3.7	Protocolo de avaliação	10
3.8	Análise estratificada do erro	11
3.9	Análise de explicabilidade	12
3.10	Classificador dual: regra de combinação <i>post-hoc</i>	12
3.11	Reprodutibilidade	12
4	Resultados Experimentais	14
4.1	<i>Baselines</i> textuais sobre BERT da raiz	15
4.2	Diagnóstico de <i>confound</i> topológico	16
4.3	Cross-dataset UPFD: nossos resultados <i>versus</i> literatura	17
4.4	Topologia sem texto: o achado central (RQ3, parte a)	18
4.5	Consistência de <i>score</i> topológico entre idiomas (RQ3, parte b)	20
4.6	Por que GossipCop funciona e PolitiFact não? (RQ2)	22
4.7	Concordância textual $\times$ topológico (RQ1)	24
4.8	GNNExplainer: o que o SAGE aprendeu	27
4.9	Análise estratificada do erro	28
4.9.1	Distribuição estrutural: <i>heavy-tail</i> mais agressivo que lognormal	28
4.9.2	LOWESS: onde o modelo degrada	29
4.9.3	Outliers e a inversão distributiva	30
4.9.4	Cascatas profundas: o ganho cresce com a profundidade	33
4.10	Painel mestre dos achados	36
5	Discussão e Conclusão	37
5.1	Síntese dos achados por pergunta de pesquisa	37
5.2	Achado negativo é achado	38
5.3	Limitações	39
5.4	Trabalhos futuros	40
5.5	Considerações finais	41
A	Hiperparâmetros completos	44
B	Índice geral de figuras e tabelas	45
C	Estrutura do repositório de código	46
D	Aplicação demonstrativa: Bluesky e ferramenta web	47
D.1	O <i>dataset</i> Bluesky	47
D.2	Inferência <i>cross-domain</i> dos modelos persistidos	47

D.3	Concordância textual $\times$ topológico	49
D.4	Ferramenta web	49

Chapter 1

Introdução

1.1 Contextualização

1.2 Motivação

1.3 Perguntas de pesquisa

1.4 Contribuições

1.5 Estrutura do trabalho

Chapter 2

Fundamentação Teórica

2.1 Detecção de fake news: panorama

2.2 Grafos e redes sociais

2.3 Embeddings textuais

2.4 Redes Neurais de Grafos

2.4.1 Graph Convolutional Networks (GCN)

$$H^{(l+1)} = \sigma \left(\hat{D}^{-1/2} \hat{A} \hat{D}^{-1/2} H^{(l)} W^{(l)} \right) \quad (2.1)$$

2.4.2 Graph Attention Networks (GAT)

$$\alpha_{ij} = \frac{\exp \left(\text{LeakyReLU}(\mathbf{a}^T [W h_i \parallel W h_j]) \right)}{\sum_{k \in \mathcal{N}(i)} \exp \left(\text{LeakyReLU}(\mathbf{a}^T [W h_i \parallel W h_k]) \right)} \quad (2.2)$$

2.4.3 GraphSAGE

2.5 Degeneração do GCN com features homogêneas

$$\begin{aligned} H^{(1)} &= \sigma \left(\tilde{A} X W \right) \\ &= \sigma \left(\tilde{A} \mathbf{1}_N x^T W \right) \\ &= \sigma \left((\tilde{A} \mathbf{1}_N) (x W)^T \right) \end{aligned} \quad (2.3)$$

2.6 Encodings posicionais

2.7 Explicabilidade em GNNs: GNNExplainer

2.8 Validação estatística

Table 2.1: Interpretação de tamanho de efeito de Cohen (d).

$ d $	Interpretação
< 0.2	desprezível
$0.2 \leq d < 0.5$	pequeno
$0.5 \leq d < 0.8$	médio
≥ 0.8	grande

2.9 Trabalhos relacionados

2.9.1 Surveys de GNNs em fake news

2.9.2 Métodos GNN canônicos

2.9.3 Detecção multilíngue

2.9.4 Trabalhos brasileiros relacionados

2.9.5 Homofilia e assortatividade em redes

2.9.6 Posicionamento deste trabalho

Chapter 3

Metodologia

3.1 Visão geral do pipeline




Figure 3.1: Visão geral do *pipeline* de detecção. Dados brutos são transformados em grafos de propagação com *features* estruturais (e textuais via BERT, quando disponíveis), passados por modelos GNN, e avaliados com protocolo de k-fold pareado.

3.2 Datasets

Table 3.1: Datasets utilizados, com tamanho, fonte e papel no trabalho.

Dataset	N grafos	N classes	Fonte	Papel
FakeNewsNet PolitiFact	~754	2 (50/50)	[3]	Treino + validação
UPFD-PolitiFact	~314	2 (50/50)	[1]	Cross-dataset
UPFD-GossipCop	~5.464	2 (50/50)	[1]	Cross-dataset
Bluesky (acadêmico)	168.463	–	[2]	Aplicação (sem <i>labels</i>)

3.3 Construção de grafos: FakeNewsNet

A construção dos grafos do FakeNewsNet é realizada pelo *script* `00_construir_grafos_fakenewsnet`. O *script* efetua o *download* direto dos CSVs do repositório oficial do KaiDMML [3], gera o *embedding* textual do título de cada notícia via *Sentence-BERT* multilíngue (modelo `paraphrase-multilingual-mpnet-base-v2`, dimensão 768) e *cacheia* o resultado em disco para evitar recomputação. Cada notícia gera um grafo em estrela: o nó raiz é a

notícia em si, e seus filhos são os identificadores de *tweets* listados pelo CSV como tendo propagado a notícia.

A topologia em estrela (e não em árvore com profundidade) é imposta pelo formato do CSV bruto, que fornece apenas uma lista plana de `tweet_ids` por notícia, sem relação de parentesco entre *retweets* e sem *timestamps* (caveat já discutido em §3.2). Aplicam-se dois filtros: o mínimo de dois *tweets* de propagação por notícia (descarta cascatas degeneradas, sem o que o grafo de propagação seria reduzido a um único nó) e o máximo de 100 nós por grafo. A distribuição bruta de tamanhos de cascata é fortemente assimétrica: a mediana é de 30 *tweets*, mas a média chega a 552 e o máximo observado a 29.060. O limite de 100 nós trunca, portanto, 50% dos grafos do *dataset*; não se trata de remoção de *outliers* raros, mas de decisão de projeto com efeito substancial. A justificativa é estrutural: em um grafo-estrela, todos os nós-filho compartilham o mesmo *embedding* BERT (replicado a partir do título), e folhas adicionais além de uma centena acrescentam informação marginal desprezível; além disso, o *global mean pool* adotado pela camada final faria com que, em um grafo de dezenas de milhares de folhas quase idênticas, a contribuição do nó raiz, único portador das *features* `is_root` e `grau_norm`, fosse diluída a uma fração ínfima do vetor agregado. Como contrapartida, os grafos truncados tornam-se indistinguíveis quanto ao tamanho absoluto da cascata (limitação retomada em §5.3).

O *script* oferece três variantes de construção, controladas pela *flag* `-feature-variant`: `posfull` (todas as três codificações posicionais ativas, vetor nodal de 771 dimensões), `posmin` (apenas `is_root` e `pos`, com `grau_norm` zerado) e `posgrau` (apenas `is_root` e `grau_norm`, com `pos` zerado). As três variantes materializam-se em diretórios distintos em `data/fakenewsnet_<suffix>/` e são consumidas pela ablation intra-encoding (§4.4). Uma asserção de sanidade no construtor (`x.unique(dim=0).shape[0] >= min(num_nos, 3)`) garante que os vetores nodais de um mesmo grafo não sejam idênticos, prevenindo o cenário de degeneração do *message passing* descrito em §2.5.

3.4 Folds compartilhados

O *script* `gerar_folds.py` instancia `StratifiedKFold(n_splits=10, shuffle=True, random_state=42)` do *scikit-learn* sobre os 754 grafos do FakeNewsNet e persiste os índices em `data/folds_fnn.pt`. Esse arquivo é gerado *uma única vez* e consumido por todos os experimentos do trabalho que reportam comparações pareadas: o baseline textual (§4.1), o diagnóstico de *confound* (§4.2), o teste de significância entre arquiteturas GNN, entre outros.

A motivação é estatística. O teste *t* pareado (`scipy.stats.ttest_rel`) que usamos para comparar dois modelos exige que cada par de métricas comparado tenha sido obtido sobre os *mesmos exemplos*. Caso contrário, a variação entre folds se mistura à diferença entre modelos, reduzindo o poder do teste e tornando suas conclusões questionáveis. O

compartilhamento de *folds* elimina essa fonte de ruído e é pré-requisito do protocolo de avaliação formalizado em §3.7.

3.5 Arquiteturas GNN e hiperparâmetros

Três arquiteturas representativas das principais famílias de Redes Neurais de Grafos são avaliadas: a *Graph Convolutional Network* (GCN, [?]), com agregação espectral normalizada pelo grau; a *Graph Attention Network* (GAT, [?]), com pesos de aresta aprendidos via mecanismo de atenção; e o GraphSAGE ([?]), com agregação indutiva por média dos vizinhos. Todas as três são implementadas no *PyTorch Geometric* [?] e compartilham a mesma arquitetura agregada: três camadas convolucionais, com 64 canais ocultos por camada, seguidas de *global mean pool* sobre os nós, *dropout* de 0,5 e um classificador linear final. A Tabela 3.2 reúne os hiperparâmetros.

*Para o UPFD, o vetor de features de entrada de cada nó é o vetor pré-computado fornecido pelo dataset (variante **profile**, com 10 dimensões); para o FakeNewsNet, o vetor é o de 771 dimensões descrito em §3.3; para os experimentos de topologia pura da §4.4, ambos os datasets têm suas features substituídas por [is_root, grau_norm] (dimensão 2).*

Table 3.2: Hiperparâmetros usados nos modelos GNN. Defaults são iguais entre arquiteturas; diferenças anotadas na própria tabela.

Hiperparâmetro	GCN	GAT	SAGE
hidden_channels	64	64	64
num_layers	3	3	3
dropout	0.5	0.5	0.5
num_heads (atenção)	–	4	–
pooling	global_mean_pool	idem	idem
learning_rate	0.001	0.001	0.001
weight_decay	5×10^{-4}	5×10^{-4}	5×10^{-4}
batch_size	32	32	32
optimizer	Adam	Adam	Adam
scheduler	ReduceLROnPlateau (factor=0.5, patience=5)		
early_stopping	patience=7 sobre F1-macro de validação		
max_epochs	30	30	30
seed	42 (com varredura para 10 <i>seeds</i> em §4.4)		

A opção por hiperparâmetros idênticos entre as três arquiteturas não busca otimizar cada uma ao máximo (o que tornaria a comparação dependente de quanto cada modelo foi ajustado), mas sim *isolar o efeito arquitetural*: se uma família se destaca consistentemente

sob a mesma configuração básica, o sinal observado é atribuível à arquitetura, não ao *tuning*. Os defaults adotados são valores convencionais na literatura de GNNs e suficientes para conduzir o treinamento à convergência dentro do máximo de 30 épocas estabelecido.

3.6 *Baselines* não-GNN

Dois *baselines* deliberadamente simples acompanham as arquiteturas GNN ao longo do trabalho, cada um isolando uma direção do espaço de hipóteses.

O primeiro é um classificador puramente *textual*: a *Regressão Logística* aplicada sobre o *embedding* BERT da raiz da árvore de propagação (isto é, o vetor de 768 dimensões do título da notícia). Esse modelo não tem acesso a nenhuma informação estrutural: ignora o grafo inteiro e vê apenas o conteúdo textual. Estabelece, portanto, o *teto textual* do problema; qualquer GNN que não supere significativamente este *baseline* não está agregando valor sobre a informação do texto.

O segundo é um classificador puramente *estrutural tabular*: um *Random Forest* com 200 árvores, treinado sobre apenas duas *features* agregadas por grafo: o número total de nós (`num_nodes`) e o grau do nó raiz (`grau_root`). Esse modelo encarna o *confound trivial* da detecção de fake news em redes: a observação recorrente de que notícias falsas tendem a viralizar mais, gerando cascatas maiores. Se um *Random Forest* alimentado apenas com tamanho e grau atinge um F1 próximo do da GNN, o ganho aparente da GNN não vem de capturar estrutura sutil, mas apenas de reproduzir esse *confound*; se, por outro lado, o GNN supera significativamente o RF, há sinal estrutural genuíno sendo aprendido. Os dois *baselines* são confrontados, lado a lado, com as arquiteturas GNN em §4.1 e §4.2.

3.7 Protocolo de avaliação

A métrica primária adotada é o *F1-macro*, a média não ponderada dos F1 das duas classes (fake e real). Como os três *datasets* supervisionados utilizados são aproximadamente balanceados em torno de 50%/50% entre as classes (§3.2), o F1-macro é numericamente próximo da acurácia, mas com a vantagem de permanecer significativo caso futuros *datasets* apresentem desequilíbrio, situação comum em detecção de fake news em produção, onde a classe *fake* pode ser minoritária. A literatura UPFD [1] reporta acurácia; usamos F1-macro para alinhar com práticas mais recentes em classificação binária desbalanceada e marcamos expressamente a diferença quando confrontamos com valores publicados (Tabela 4.4).

Para comparar dois modelos sob o mesmo *dataset*, utilizamos o *teste t pareado* (`scipy.stats.ttest`) sobre os *folds* compartilhados de §3.4. O pareamento tem duas implicações práticas: a variação entre *folds* é cancelada (cada *fold* contribui com uma diferença entre modelos, não com uma métrica absoluta), e o teste recupera o sinal mesmo em diferenças pequenas

que o teste não-pareado não detectaria. No caso particular dos *subsets post-hoc* (como os recortes por profundidade da cascata em §4.9), nos quais o pareamento por fold é impossível por o *subset* ser definido sobre o conjunto de teste único, recorremos ao *bootstrap* pareado descrito em §3.8.

Para a análise descritiva de separabilidade estrutural entre fake e real (§4.6), reportamos o *tamanho de efeito de Cohen* (d), conforme definição clássica de [?]. A escala interpretativa adotada é a usual: $|d| < 0,2$ desprezível, $0,2 \leq |d| < 0,5$ pequeno, $0,5 \leq |d| < 0,8$ médio, $|d| \geq 0,8$ grande. A tese central do trabalho está operacionalizada nesse limiar (ver §5.2).

Caveat de reprodutibilidade. Todos os experimentos foram executados em CPU (Intel Raptor Lake, 16 *cores* lógicos, 16 GB de RAM), sob Python 3.12.10 e PyTorch 2.10+cpu, com semente universal 42. Os resultados são reproduzíveis no mesmo ambiente, mas não bit-exato entre máquinas: operações `scatter` e `gather` do PyTorch Geometric não possuem *kernel* determinístico em GPU, e diferenças entre versões de CUDA/cuDNN ou entre CPUs distintas geram variação tipicamente na terceira casa decimal das métricas. Como contramedida, os achados centrais foram validados em 10 *seeds* independentes (§4.4) e em *bootstrap* pareado de 2.000 reamostragens (§4.9.4); as conclusões qualitativas se mantêm entre execuções.

3.8 Análise estratificada do erro

O F1-macro agregado mede *quanto* um modelo acerta, não *onde* ele acerta. Para responder a essa segunda questão, relevante para a caracterização de regimes em que cada modelo falha ou prospera, adotamos três técnicas complementares aplicadas sobre o *test set* do UPFD-GossipCop, em conjunto detalhadas em §4.9.

A primeira é uma *regressão localmente ponderada* (LOWESS) de $P(\text{acerto} \mid m)$ em função de cada métrica estrutural m . Implementamo-la via *rolling mean* de janela proporcional (10% da amostra ordenada, com mínimo absoluto de 30 observações), evitando a dependência de `statsmodels`. A vantagem sobre o *binning* discreto é dupla: visualiza-se continuamente a variação da acurácia ao longo de m , sem decidir arbitrariamente onde cortar os *bins*, o que evita o espaço para *cherry-picking*.

A segunda é a definição de *outliers* via *percentil empírico* (p5/p95) sobre o próprio *test set*, em vez de limiares baseados em *z-score*. A escolha é justificada pela forma das distribuições: métricas de cascata em redes sociais são *heavy-tail*: a média não é robusta, o desvio-padrão é inflado por poucos casos extremos, e critérios baseados em σ tornam-se mal-definidos. O percentil empírico é invariante à forma da distribuição e identifica reciprocamente o 5% inferior e o 5% superior independentemente da assimetria.

A terceira é o *bootstrap pareado* (com $n_{\text{boot}} = 2.000$) para intervalos de confiança sobre a diferença de F1 entre dois modelos avaliados no mesmo *subset*, técnica empregada em

§4.9.4 para confirmar a significancia do ganho do SAGE estrutural sobre o RF tabular em recortes de profundidade da cascata. O *bootstrap* é o substituto natural do `ttest_rel` pareado por *fold* quando o pareamento por *fold* não se aplica, como ocorre em *subsets* definidos *post-hoc* sobre o teste único do UPFD.

3.9 Análise de explicabilidade

Para inspecionar o que a arquitetura SAGE estrutural efetivamente aprende do grafo de propagação, recorreremos ao *GNNExplainer* [?], implementado em `torch_geometric.explain.Explainer` com algoritmo `GNNExplainer(epochs=200)` e `edge_mask_type="object"`, em modo de classificação multi-classe sobre o grafo inteiro. O GNNExplainer aprende uma máscara sobre as arestas do grafo que maximiza a informação mútua entre a sub-rede mascarada e a predição do modelo, identificando assim quais arestas são mais decisivas para a classificação de cada grafo.

A análise é aplicada sobre 20 amostras do *test set* do UPFD-GossipCop estratificadas em quatro grupos de cinco grafos cada (*fake-pequena*, *fake-grande*, *real-pequena*, *real-grande*), permitindo identificar padrões diferenciais por classe e por tamanho. Para cada amostra, calcula-se a fração de massa de importância concentrada em arestas a 1-hop (raiz $\rightarrow$ filhos diretos), 2-hops e ≥ 3 -hops da raiz. Os resultados, apresentados em §4.8, revelam uma assimetria sistemática entre *fake* e *real* no padrão espacial de importância, achado que sustenta interpretações sobre o mecanismo de classificação aprendido pelo modelo.

3.10 Classificador dual: regra de combinação *post-hoc*

Para a aplicação prática documentada no Apêndice D, combinamos o classificador textual (LogReg-BERT) e o classificador topológico (RF estrutural) por meio de uma regra de combinação heurística. É importante registrar, já aqui, que essa regra **não é uma decisão metodológica a priori**: trata-se de uma heurística derivada *post-hoc*, ou seja, após a observação empírica dos resultados de §4.7. Sua formulação exata, sua justificativa quantitativa e a discussão das alternativas descartadas são apresentadas naquela seção, sob a equação (4.1). A menção antecipada neste capítulo serve apenas para precedência expositiva, dado que a ferramenta web descrita no Apêndice D consome o classificador combinado.

3.11 Reprodutibilidade

A reprodutibilidade dos resultados é tratada em três níveis. Primeiro, o ambiente de execução é fixado: Python 3.12.10, PyTorch 2.10+cpu, PyTorch Geometric 2.7.0, *scikit-learn*

e demais dependências versionadas em `requirements.txt` (*pinned*). Os experimentos foram conduzidos em **ambiente CPU** (Intel *Raptor Lake*, 16 *cores* lógicos, 16 GB de RAM, Windows 11); não se utilizou GPU em nenhum momento do treinamento ou da avaliação.

Segundo, todas as fontes de aleatoriedade são semeadas com o valor 42: `torch.manual_seed`, `numpy.random.seed`, `random.seed`, `StratifiedKFold(random_state=42)` e os construtores dos classificadores do *scikit-learn* (`n_jobs=-1` é adotado para o RF, sem efeito sobre determinismo). Para os experimentos sensíveis à inicialização, conduzimos varredura explícita sobre 10 *seeds* independentes em §4.4 e reportamos média e desvio-padrão.

Terceiro, reconhecemos as limitações ao determinismo: operadores `scatter` e `gather` do PyTorch Geometric não possuem *kernel* determinístico em GPU [?]¹, e diferenças de arquitetura de CPU ou de versão de bibliotecas geram variação tipicamente na terceira casa decimal das métricas reportadas. As conclusões qualitativas do trabalho são robustas a essa variação. O repositório oficial do código, com o `README.md` como fonte autoritativa de instruções, está publicado junto aos pesos persistidos em [4].

¹Referência da nota: a documentação oficial do PyTorch sobre reprodutibilidade (<https://pytorch.org/docs/stable/notes/randomness.html>).

Chapter 4

Resultados Experimentais

Cada seção deste capítulo responde uma das perguntas de pesquisa formuladas em §1.3. Resultados negativos (em particular o desempenho dos modelos topológicos no UPFD-PolitiFact em §4.4) são reportados com a mesma extensão dos positivos: a refutação de uma hipótese tem peso evidencial equivalente à sua confirmação, e é justamente a sobreposição dos dois lados que permite caracterizar o regime de aplicabilidade do paradigma topológico. A Tabela 4.1 consolida em uma só vista as métricas-chave por (*dataset* $\times$ modelo), com código de cores que sinaliza desempenho forte, intermediário e colapso.

Table 4.1: Síntese de resultados: F1-macro por (*dataset* $\times$ modelo). Células verdes indicam desempenho forte ($\geq 0,80$); amarelas, médio (0,60–0,79); vermelhas, colapso ($< 0,60$). Negrito marca o melhor modelo de cada *dataset*. O contraste entre UPFD-GossipCop (todas as linhas verdes) e UPFD-PolitiFact com features estruturais puras (linha inteira em vermelho) e’ o achado central do trabalho.

Modelo / <i>features</i>	FNN	UPFD-Polit	UPFD-Goss	Fonte
<i>Baselines textuais</i>				
LogReg-BERT (título)	0,859	0,842	0,954	T1, T3
RandomForest-BERT	0,855	–	–	T1
<i>GNNs com texto (feature content/profile)</i>				
GCN	–	0,782	0,941	T3
GAT	–	0,694	0,939	T3
SAGE	–	0,817	0,945	T3
<i>Modelos topológicos puros (sem texto)</i>				
RF tabular [num_nodes, grau_root]	–	–	0,753	T6
GCN [is_root, grau_norm]	0,528	0,362	0,645	T4
GAT [is_root, grau_norm]	0,537	0,380	0,483	T4
SAGE [is_root, grau_norm]	0,536	0,331	0,810	T4
<i>Referência (Dou et al., SIGIR 2021)</i>				
GCN/GAT/SAGE publicado	–	0,846 [†]	0,971 [†]	T10

[†] Acurácia reportada por Dou et al. com *feature bert* (768d); nosso F1-macro com *content* (310d). Não bit-exact, indicativo apenas.

“Melhor da coluna” aplicado dentro de cada bloco; o negrito da linha SAGE em UPFD-PolitiFact destaca o caso de colapso (não um *me*).

4.1 *Baselines* textuais sobre BERT da raiz

Table 4.2: Baseline textual no FakeNewsNet (k-fold estratificado, k=10).

Modelo	Folds	F1-macro	Accuracy
LogReg	10	0.8593 $\pm$ 0.0431	0.8595 $\pm$ 0.0430
RandomForest	10	0.8549 $\pm$ 0.0372	0.8555 $\pm$ 0.0369

A Tabela 4.2 reporta o desempenho de dois classificadores clássicos (*Regressão Logística* e *Random Forest*) treinados *exclusivamente* sobre o vetor BERT do título de cada notícia

no FakeNewsNet, em validação cruzada estratificada de 10 *folds*. O LogReg-BERT atinge F1-macro de $0,859 \pm 0,043$; o Random Forest sobre o mesmo *embedding* atinge $0,855 \pm 0,037$, valor próximo. Em ambos os casos, a acurácia é essencialmente igual ao F1-macro (consistente com o balanço 50/50 do FNN, §3.2).

A leitura desse resultado define o *teto textual* do problema neste *dataset*: o texto da raiz da árvore de propagação, isoladamente, já carrega quase todo o sinal classificatório recuperável. Modelos baseados em grafos só se justificam, no FakeNewsNet, se o ganho que trazem sobre esse teto for estatisticamente distinguível, o que se mostrará, em §4.4, *não ocorrer*: as arquiteturas GNN com *features* estruturais puras sequer alcançam 0,55, e mesmo as variantes com texto têm ganho marginal sobre o LogReg-BERT. Em §4.6 discutiremos por que esse teto textual tão alto e a ausência de ganho topológico no FNN são coerentes com a tese central do trabalho.

4.2 Diagnóstico de *confound* topológico

Notícias falsas tendem, na literatura de detecção em redes sociais, a viralizar mais que notícias verdadeiras e gerar cascatas maiores. Essa correlação cria um *confound* trivial: o desempenho que se atribui a uma GNN pode, em última instância, não estar capturando estrutura sutil alguma — pode estar apenas reproduzindo o atalho “*fake* = grafo maior”. Para testá-lo diretamente, treinamos um *Random Forest* (§3.6) no FakeNewsNet alimentado *apenas* com a *feature* `num_nodes`. O F1-macro resultante é de $\approx 0,523$, valor próximo do nível de chance (0,50 em problema balanceado) e bem abaixo do limiar de 0,65 que adotariamos *a priori* como sinal de *confound* dominante. Sendo assim, o tamanho do grafo *contribui*, mas não *explica* o sinal capturado pelos modelos posteriores: há ruído demais na correlação entre tamanho e veracidade para que um classificador trivial dela extraia valor preditivo. O ganho que se observa nas GNNs vem, portanto, de outras fontes — textuais, no caso do FNN; estruturais multi-hop, no caso do UPFD-GossipCop (cuja decomposição por profundidade da cascata é quantificada em §4.9).

4.3 Cross-dataset UPFD: nossos resultados *versus* literatura

Table 4.3: Benchmark cross-dataset UPFD (PolitiFact + GossipCop) – GCN/GAT/SAGE vs baseline textual.

Dataset	Modelo	Seeds/Folds	F1-macro
gossipcop	GAT	3	0.9390 ± 0.0050
gossipcop	GCN	3	0.9411 ± 0.0059
gossipcop	LogReg_root	1	0.9540 ± 0.0000
gossipcop	SAGE	3	0.9448 ± 0.0041
politifact	GAT	5	0.6936 ± 0.1865
politifact	GCN	5	0.7816 ± 0.0548
politifact	LogReg_root	1	0.8415 ± 0.0000
politifact	SAGE	5	0.8166 ± 0.0095

Table 4.4: Comparacao com baselines do UPFD original (Dou et al., SIGIR 2021, Tabela 4). Nota: nossos resultados sao F1-macro sobre k-fold com feature 'content' (310d); valores publicados sao accuracy com feature 'bert' (768d). Comparacao indicativa, nao bit-exact.

Dataset	Modelo	F1-macro (nosso)	Acc (Dou et al.)
politifact	GCN	0.782 ± 0.055	0.846
politifact	GAT	0.694 ± 0.186	0.846
politifact	SAGE	0.817 ± 0.010	0.846
gossipcop	GCN	0.941 ± 0.006	0.972
gossipcop	GAT	0.939 ± 0.005	0.971
gossipcop	SAGE	0.945 ± 0.004	0.971

A Tabela 4.3 reporta os resultados de GCN, GAT e SAGE nas duas variantes do UPFD: PolitiFact (314 grafos) e GossipCop (5.464 grafos), com média sobre 3 a 5 *seeds* independentes. O contraste entre os dois domínios já está presente aqui: no UPFD-GossipCop as três arquiteturas convergem para F1-macro em torno de 0,94, próximas do *baseline* textual (0,954); no UPFD-PolitiFact, os modelos espalham-se entre 0,69 (GAT) e 0,82 (SAGE), com o próprio LogReg-BERT atingindo 0,84 — isto é, no PolitiFact a variação entre arquiteturas é muito maior, e nenhuma supera o *baseline* textual em margem significativa. A Tabela 4.4 confronta estes mesmos valores com os de Dou et al. [1]: PolitiFact em torno de 0,78–0,82 no nosso (vs. 0,846 publicado), GossipCop em torno de 0,94–0,95 (vs. 0,971 publicado).

Esta comparação é *aproximada, não replicação exata*: as razões precisam ser declaradas explicitamente. Três diferenças deliberadas afastam nossa configuração da deles: (i) utilizamos a *feature content* (310 dimensões, combinação de *spaCy* e *profile*) ao invés da *feature bert* (768 dimensões), por restrição de memória RAM na densificação da matriz esparsa do GossipCop em ambiente Windows/CPU; (ii) adotamos hiperparâmetros próprios ($lr = 0,001$, $hidden = 64$, três camadas), uma vez que a configuração exata de [1] não é totalmente especificada no artigo; (iii) reportamos F1-macro enquanto Dou et al. reportam acurácia. O propósito da comparação não é *ranking* competitivo com a literatura, mas *calibração*: verificar que nosso *pipeline*, com diferenças conhecidas e declaradas, está *no envelope* dos valores publicados — condição necessária para que os achados subsequentes deste capítulo sejam tomados como informativos sobre o problema, e não como artefatos de implementação defeituosa.

4.4 Topologia sem texto: o achado central (RQ3, parte a)

Table 4.5: Topologia SEM texto: features [is_root, grau_norm] – sinal estrutural puro por dataset/arch.

Dataset	Modelo	Seeds/Folds	F1-macro
fnn	GAT	10	0.5372 ± 0.0709
fnn	GCN	10	0.5275 ± 0.0678
fnn	SAGE	10	0.5362 ± 0.0747
upfd_gossipcop	GAT	10	0.4834 ± 0.1075
upfd_gossipcop	GCN	10	0.6445 ± 0.0190
upfd_gossipcop	SAGE	10	0.8097 ± 0.0023
upfd_politifact	GAT	10	0.3800 ± 0.0802
upfd_politifact	GCN	10	0.3621 ± 0.0554
upfd_politifact	SAGE	10	0.3314 ± 0.0093




Figure 4.1: F1-macro por (arquitetura $\times$ *feature variant* $\times$ *dataset*). Verde = modelo aprende; vermelho = colapsa. SAGE em UPFD-GossipCop com apenas duas *features* estruturais atinge $F1 \approx 0.81$.

A Tabela 4.5 e a Figura 4.1 resumem o *achado central* do trabalho. A combinação **SAGE** + **UPFD-GossipCop** + *features* estruturais puras [is_root, grau_norm] (vetor nodal de apenas duas dimensões, nenhuma das quais contém texto) atinge F1-macro de $0,810 \pm 0,002$, média sobre dez *seeds* independentes. O mesmo modelo, treinado nos outros dois *datasets*, colapsa: $F1 \approx 0,33$ em UPFD-PolitiFact (abaixo do nível de chance) e $F1 \approx 0,54$ em FakeNewsNet. As outras duas arquiteturas testadas no UPFD-GossipCop ficam atrás do SAGE (GCN 0,64, GAT 0,48), reforçando que a agregação indutiva por média do GraphSAGE é particularmente adequada à estrutura em estrela do dataset. *Sem nenhum acesso ao texto da notícia, apenas com duas dimensões estruturais por nó, o SAGE no UPFD-GossipCop alcança 81% de F1-macro, a 13 pontos percentuais do baseline textual (0,954) e a 14 pontos do SAGE com texto (0,945)*. Este é o resultado central que responde afirmativamente à parte (a) da RQ3: é viável detectar fake news apenas pela topologia da propagação, *desde que* o domínio ofereça sinal estrutural mensurável (condição examinada em §4.6).

A baixa variância em torno desse F1 de 0,81 ($\sigma = 0,002$ sobre dez *seeds*) merece justificativa, pois é atipicamente pequena para um experimento de aprendizado profundo. Auditoria do *script* de execução confirma que (i) `torch.manual_seed` e `np.random.seed` são chamados antes de cada execução independente; (ii) o `DataLoader` com `shuffle=True` consome do gerador semeado; (iii) o construtor da `SAGEClassifier` recebe `seed=seed` explicitamente. A baixa variância é, portanto, comportamento genuíno do experimento, e é consequência da combinação de três fatores: (a) o vetor de entrada tem apenas duas dimensões, oferecendo pouco espaço para que diferenças de inicialização se tornem diferenças de convergência; (b) o sinal estrutural no UPFD-GossipCop é muito forte (Cohen’s $d = +1,53$ no *branching factor*, §4.6), conduzindo o otimizador ao mesmo óptimo independentemente da semente; (c) o *split* treino/validação/teste do UPFD é fixo, isolando

completamente a fonte de variação do *dataset*. Como controle negativo, a mesma arquitetura SAGE aplicada ao UPFD-PolitiFact (onde Cohen’s d é desprezível em todas as métricas) produz $\sigma \approx 0,05$, ordem de grandeza maior; isto é, o σ baixo é função do *dataset*, não de *bug* de semente.

4.5 Consistência de *score* topológico entre idiomas (RQ3, parte b)

É necessário delimitar com precisão o que este experimento mede *antes* de discutir seus resultados. O *snapshot* acadêmico do Bluesky utilizado aqui *não possui rótulos fake/real*, e portanto este experimento **não mede detecção** em português, alemão ou qualquer outro idioma. Mede, em vez disso, a *consistência da distribuição do score* que o classificador estrutural, treinado em UPFD-GossipCop e arquiteturalmente cego ao texto, produz quando aplicado a posts em diferentes idiomas. Essa consistência é condição *necessária mas não suficiente* para detecção multilíngue: distribuições discrepantes indicariam que o mecanismo estrutural responde sistematicamente ao idioma do post (por confounders de comunidade, volume ou regime de engajamento), refutando a independência linguística do mecanismo; distribuições equivalentes *não garantem* acurácia preditiva em produção, apenas que o classificador não introduz viés sistemático por idioma.

Table 4.6: Comparacao da distribuicao de score topologico no Bluesky entre idiomas (RQ3 parte b). PT vs EN: efeito desprezivel ($|d| < 0.2$); DE vs EN: efeito medio ($|d| = 0.47$). Interpretacao com 3 hipoteses alternativas em §4.4-bis (shift dominio, vies amostral, desbalanco).

Par	n_a	n_b	$\bar{s}_a$	$\bar{s}_b$	Cohen’s d	KS p
por vs eng	2661	132312	0.381	0.398	-0.057	2.69e-42
deu vs eng	9686	132312	0.259	0.398	-0.468	0.00e+00
por vs deu	2661	9686	0.381	0.259	+0.739	5.48e-321




Figure 4.2: Distribuição do *score* topológico do RF-estrutural (treinado em UPFD-GossipCop) aplicado a posts do Bluesky por idioma. EN ($n=132.312$), DE ($n=9.686$) e PT ($n=2.661$) médias indicadas na legenda. PT e EN são praticamente indistinguíveis ($d=-0.057$); DE difere por efeito médio ($d=-0.468$).

A Tabela 4.6 e a Figura 4.2 resumem o experimento. Quanto ao par português *versus* inglês, Cohen’s $d = -0,057$ é *desprezível* pela escala de [?]. Os testes de Kolmogorov-Smirnov e Mann-Whitney rejeitam a hipótese nula de mesma distribuição com $p < 10^{-5}$, mas é preciso enfatizar que isso ocorre porque $n_{EN} = 132.312$ torna estatisticamente detectável praticamente qualquer diferença real, por menor que seja sua importância prática. O tamanho de efeito, métrica que não se infla com n , é o critério adequado neste regime; e o efeito está bem abaixo do limiar de efeito *pequeno* ($|d| < 0,2$ pela escala de Cohen). Concluimos, portanto, que a diferença entre PT e EN é *estatisticamente detectável mas praticamente irrelevante*. O par alemão *versus* inglês, em contraste, exibe $d = -0,468$ (efeito médio): posts em alemão apresentam *score* topológico sistematicamente mais baixo (média 0,26, contra 0,40 do inglês). O par PT *versus* DE apresenta $d = +0,739$ (mediano-grande), consistente com os pares anteriores: PT está mais próximo de EN do que de DE.

A interpretação da divergência DE *versus* EN exige cautela. É plausível atribuí-la a padrões de engajamento da comunidade germânica no Bluesky (adoção tardia, uso mais discreto da plataforma, comunidade autoselecionada). Mas *hipóteses alternativas são igualmente válidas e não podem ser descartadas sem experimentos adicionais*: (1) *shift* de domínio: o classificador foi treinado em notícias de celebridade/entretenimento (UPFD-GossipCop), enquanto posts DE no Bluesky podem ter perfil temático mais político ou

profissional; (2) viés amostral: os usuários alemães no Bluesky podem constituir subgrupo demográfico específico (*early adopters*, comunidade tech) e não a comunidade germânica como um todo; (3) desbalanço de cobertura: $n_{PT} = 2.661$, $n_{DE} = 9.686$, $n_{EN} = 132.312$ são suficientes para a estimativa pontual do Cohen’s d , mas a cobertura de regimes raros de engajamento é necessariamente desigual.

A resposta refinada à parte (b) da RQ3 é portanto a seguinte: o classificador estrutural *não processa texto algum*, e portanto seu mecanismo é *arquiteturalmente independente do idioma do post*. A consistência empírica dessa independência foi confirmada para o par PT *versus* EN; foi parcialmente refutada para DE *versus* EN, com a causa exata não isolada entre fatores de idioma, de comunidade, de *shift* de domínio e de amostragem.

4.6 Por que GossipCop funciona e PolitiFact não? (RQ2)

Table 4.7: Análise estrutural fake vs real – separabilidade por métrica topológica. Cohen’s d : $|d| \geq 0.5$ médio, ≥ 0.8 grande.

Dataset	Métrica	media _{fake}	media _{real}	Cohen’s d	p -valor
fnn	num_nodes	69.67	60.91	+0.223	0.002331
fnn	branching_avg	68.67	59.91	+0.223	0.002331
upfd_politifact	num_nodes	114.92	146.57	-0.245	0.03147
upfd_politifact	branching_avg	7.33	7.01	+0.059	0.6057
upfd_gossipcop	num_nodes	76.16	38.87	+0.905	0
upfd_gossipcop	branching_avg	23.61	7.50	+1.534	0




Figure 4.3: *Forest plot* de Cohen's d entre fake e real para cada métrica estrutural, em cada *dataset*. Linhas pontilhadas indicam limiares de Cohen (0.2 / 0.5 / 0.8). UPFD-GossipCop apresenta efeito *grande* ($d=+1.53$) em *branching factor*; UPFD-PolitiFact e FakeNewsNet ficam abaixo do limiar de efeito *pequeno* ($|d| < 0.2$).

A Tabela 4.7 e a Figura 4.3 reportam o tamanho de efeito de Cohen entre as classes *fake* e *real*, calculado sobre cinco métricas estruturais por grafo (`num_nodes`, `num_edges`, `depth_max`, `width_max`, `branching_avg`), nos três *datasets*. A diferença entre domínios é drástica: o UPFD-GossipCop apresenta $d = +1,53$ em *branching factor* (efeito *grande* pela escala de Cohen) e $d = +0,91$ em `num_nodes`; ambas as métricas mostram cascatas sistematicamente maiores e mais ramificadas nas notícias falsas. O UPFD-PolitiFact, em contraste, não alcança nem mesmo um efeito médio em nenhuma das métricas avaliadas: o máximo é $|d| = 0,25$ em `num_nodes`, abaixo do limiar de 0,5. O FakeNewsNet apresenta $|d| \approx 0,22$ em `num_nodes` e `branching_avg`, valores matematicamente idênticos porque, em grafo-estrela, o *branching* médio coincide com `num_nodes`–1, dado que apenas o nó raiz é não-folha.

Este resultado tem fundamentação teórica na literatura de *homofilia* e *assortatividade* em redes. Newman [?] estabelece que redes nas quais nós da mesma classe se conectam preferencialmente exibem assortatividade alta; Pei et al. [?] demonstram que GNNs convolucionais dependem justamente de assortatividade por classe para serem efetivas. Em UPFD-GossipCop, *fake* e *real* são *estruturalmente assortativos* no sentido de Pei: cada classe forma cascatas com perfis de *branching* distintos e o operador de agregação do GNN tira proveito dessa separação. Em UPFD-PolitiFact, a ausência de assortatividade impede o operador de construir representações nodais que distingam as classes; qualquer arquitetura, não apenas SAGE, colapsa sob essa condição.

A tese central deste trabalho está operacionalizada nesse fenômeno: *modelos topológicos exigem diferença estrutural entre classes da ordem de magnitude de um efeito médio de Cohen ($|d| \geq 0,5$) em pelo menos uma métrica de cascata para serem efetivos*. A tese é deliberadamente **falsificável**: a apresentação de um *dataset* com $0,2 < |d| < 0,5$ no qual uma arquitetura GNN atinja desempenho significativamente acima do baseline textual e do RF tabular constituiria contra-evidência direta.

4.7 Concordância textual $\times$ topológico (RQ1)

Table 4.8: Comparacao TEXTUAL vs TOPOLOGICO no UPFD-GossipCop – concordancia, kappa, e desempenho condicional.

Metrica	Valor
F1-macro textual (LogReg-content)	0.9540
F1-macro topologico (RF estrutural)	0.7534
Agreement rate	0.7588
Cohen's kappa	0.5179
F1 quando AMBOS concordam	0.9662
F1 textual quando DISCORDAM	0.9139
F1 topologico quando DISCORDAM	0.0845




Figure 4.4: *Scatter score* textual (LogReg-BERT) $\times$ topológico (SAGE estrutural) no UPFD-GossipCop *test*. Quadrantes indicam concordância em FAKE (canto inferior-esquerdo) e em REAL (canto superior-direito); discordância ocupa os outros dois quadrantes.

A Tabela 4.8 e a Figura 4.4 reportam o experimento de concordância entre o classificador textual (LogReg-BERT-*content*) e o classificador topológico (RF estrutural sobre `[num_nodes, grau_root]`) aplicados sobre os 3.826 grafos do *test set* do UPFD-GossipCop. Tomados isoladamente, o textual atinge F1-macro de 0,954 e o topológico, 0,753, conforme reportado na Tabela 4.3. A pergunta interessante aqui não é qual dos dois é melhor, mas *onde os dois discordam e quem acerta nas discordâncias*. A taxa de concordância agregada é de 75,9% (Cohen’s $\kappa = 0,518$, concordância moderada). Quando ambos concordam, o F1 conjunto é de 0,966, próximo do máximo teórico. Quando discordam, o textual mantém F1 de 0,914, mas o topológico cai a **0,085**.

Esse valor de 0,085 merece interpretação cuidadosa. Ele está *substancialmente abaixo* de duas referências: do nível de chance ($\approx 0,50$ em problema balanceado) e da predição puramente majoritária ($\approx 0,33$). No subconjunto de discordância, portanto, o classi-

ficador topológico não apenas *erra*: ele está *sistematicamente invertido*. A explicação desse fenômeno é uma *inversão distributiva*: a relação entre estrutura e classe está aproximadamente espelhada nesse subconjunto, em relação ao que prevalece no treinamento. O RF aprendeu a regra geral “*fake* = grau de raiz alto” no UPFD-GossipCop (Cohen’s $d = +1,53$ em *branching*, §4.6, confirma essa regra no agregado), mas as previsões em que discorda do textual são justamente: (i) notícias *reais* que viralizaram fortemente, com grau de raiz alto, levando o RF a prever *fake* e errar; e (ii) notícias *fake* de propagação contida, com grau de raiz baixo, levando o RF a prever *real* e errar. A §4.9.3 caracteriza esses dois subgrupos numericamente, confirmando que o SAGE acerta zero de 31 *fakes* contidos e apenas 43% dos 60 *reais* virais.

Esse comportamento de inversão *justifica* a regra dual apresentada a seguir, não a contradiz: o topológico só é confiável quando concorda com o textual; quando discorda, está sinalizando precisamente o subconjunto em que sua regra estrutural falha por construção. A regra adotada na ferramenta web — Equação (4.1) e Figura 4.5 — encarna essa lógica: pesos iguais quando os dois concordam, peso 4 vezes maior para o textual quando discordam.

$$\text{score}_{\text{final}} = \begin{cases} 0.5 \cdot s_T + 0.5 \cdot s_K & \text{se } \text{pred}_T = \text{pred}_K \\ 0.8 \cdot s_T + 0.2 \cdot s_K & \text{se } \text{pred}_T \neq \text{pred}_K \end{cases} \quad (4.1)$$




Figure 4.5: Fluxograma da regra dual de combinação textual $\times$ topológico, derivada *post-hoc* dos resultados de §4.7.

4.8 GNNExplainer: o que o SAGE aprendeu




Figure 4.6: Fração de massa de importância em arestas a 1-hop, 2-hop e 3+ hops da raiz, agregado por estrato (classe $\times$ tamanho). Assimetria FAKE *vs* REAL: para FAKE, o SAGE concentra quase toda a decisão em arestas 1-hop (raiz $\rightarrow$ filhos diretos); para REAL-grande, distribui entre *hops* mais distantes.

A Figura 4.6 agrega a fração de massa de importância atribuída pelo GNNExplainer às arestas, segmentada por *hop distance* desde a raiz, para 20 amostras estratificadas do *test set* do UPFD-GossipCop (cinco por estrato: *fake-pequena*, *fake-grande*, *real-pequena*, *real-grande*). O achado central é uma *assimetria sistemática por classe* no padrão de importância espacial. Para os grafos da classe *fake* (pequenos e grandes, $N = 10$), a fração de massa em arestas a 1-hop, da raiz a seus filhos diretos, está praticamente saturada, entre 0,97 e 1,00. Para a classe *real-grande* ($N = 5$), a fração a 1-hop cai para 0,50 a 0,62, com massa significativa redistribuída para arestas mais distantes da raiz. Os cinco grafos *real-pequena* não exibem padrão consistente e são reportados aqui como observação preliminar, dado o N insuficiente para conclusão firme.

A interpretação desta assimetria é que o SAGE estrutural aprendeu uma heurística diferenciada para cada classe: para *detectar fake*, ele se convém em olhar quase exclusivamente o entorno imediato da raiz (consistente com o sinal de *branching factor* alto que caracteriza fake news na agregação da §4.6); para *confirmar real*, sobretudo em cascatas grandes, ele precisa *buscar* informação mais profundamente na árvore. Quantitativamente, esse esforço adicional rende ganho: o RF tabular alimentado apenas com `[num_nodes, grau_root]` atinge F1-macro de 0,753 no mesmo *test set*, ao passo que o SAGE atinge 0,814, diferença de +6,1 pontos percentuais absolutos atribuível ao acesso à topologia multi-hop. A §4.9.4 estratifica esse ganho por profundidade de cascata e mostra que ele se concentra fortemente nos grafos mais profundos, consistente com a leitura dada aqui pelo *GNNExplainer*.

Esta assimetria tem implicação prática para a ferramenta web documentada no Apêndice D:

a concentração de massa em *1-hop* pode ser exposta na interface como *proxy de confiança* do modelo: predições *fake* com $h_1 \approx 1$ correspondem a casos em que o modelo decidiu sob sinal forte; predições *real* com $h_1 < 0,7$ correspondem a casos em que o modelo precisou de mais informação para concluir, sinalizando incerteza relativa.

4.9 Análise estratificada do erro

As seções anteriores reportam o F1 *agregado* do SAGE estrutural em UPFD-GossipCop ($F1 = 0,810$). Este número único esconde três comportamentos distintos do modelo, que a presente seção isola com três lentes complementares aplicadas sobre os 3.826 grafos do *test* sem nenhum re-treino do classificador (*leakage* controlado por construção): uma lente *contínua* (regressão local LOWESS da probabilidade de acerto em função das métricas estruturais), uma lente *categórica* (seis subgrupos extremos definidos *post-hoc* via percentil empírico) e uma lente *ordinal* (estratificação por profundidade da cascata, com intervalos de confiança *bootstrap*). Os achados desta seção transformam o resultado agregado em diagnóstico operacional sobre *onde* cada modelo funciona e *onde* colapsa: distribuição mais pesada que lognormal, inversão distributiva confirmada em subgrupos nomeados, e *gap* SAGE–RF crescendo monotonicamente com a profundidade da cascata.

4.9.1 Distribuição estrutural: *heavy-tail* mais agressivo que log-normal




Figure 4.7: Histograma das três métricas estruturais (eixo x em escala logarítmica para **num_nodes**) com ajuste de distribuição lognormal sobreposto. Teste KS rejeita o *fit* em todas ($p < 10^{-11}$), indicando cauda mais pesada que lognormal.

A Figura 4.7 ajusta uma distribuição lognormal a cada uma das três métricas estruturais sobre o *test* de UPFD-GossipCop e submete o ajuste a teste de Kolmogorov-Smirnov. O *fit* é rejeitado nas três métricas ($p < 10^{-11}$ em todas), o que indica que a cauda das distribuições estruturais é *mais agressiva* do que aquilo que uma lognormal descreve, regime consistente com a literatura clássica de redes sociais, em que distribuições de

grau e de cascata seguem tipicamente leis de potência ou variantes *power-law-like* [?]. A consequência metodológica é direta: *z-score* como critério de outlier seria mal-definido neste regime, porque a média e o desvio-padrão amostrais são dominados por poucos pontos da cauda e não caracterizam o “centro” da distribuição. Adotamos, portanto, **percentil empírico** (p5/p95 sobre o próprio *test*) como definição de extremo em todas as análises desta seção, e *plots* envolvendo `num_nodes` usam eixo logarítmico em x por consistência com a forma da distribuição subjacente.

4.9.2 LOWESS: onde o modelo degrada




Figure 4.8: Probabilidade de acerto suavizada (*rolling-mean* de janela proporcional, 10% da amostra) do RF tabular e do SAGE estrutural em função de cada métrica estrutural no UPFD-GossipCop *test*. Linha pontilhada cinza marca o *chance level*. SAGE supera RF de forma crescente em `num_nodes` e `depth_max`; o gap em `branching_avg` é maior na região mediana.




Figure 4.9: F1-macro de RF e SAGE por tercil estrutural – versão discreta da Figura 4.8. Em `num_nodes`, SAGE cresce monotonicamente (T1 $\rightarrow$ T3); RF decresce. Em `depth_max`, distribuição discreta colapsa o tercil intermédio.

As Figuras 4.8 e 4.9 reportam, respectivamente, a probabilidade de acerto suavizada (*rolling-mean* de janela proporcional a 10% da amostra, mínimo de 30 observações por janela [?]) e a versão discreta por tercil estrutural, ambas em função de cada uma das

três métricas. A leitura combinada das duas representações é que *não existe um modelo globalmente superior*: o RF tabular e o SAGE estrutural atravessam suas curvas em pontos distintos do espaço de métricas. Em `num_nodes`, o SAGE *sobe* ao longo dos tercís enquanto o RF *desce*, cruzamento que indica que a vantagem da rede neural concentra-se em grafos suficientemente grandes para que haja estrutura de propagação a ser explorada por agregação *multi-hop*; em grafos pequenos, a topologia degenera para padrão próximo da estrela rasa e o operador de agregação perde poder discriminativo (compatível com a interpretação mecanicista da §4.6, em que o sinal estrutural de UPFD-GossipCop está no *branching factor*). Em `branching_avg`, o padrão é em U: ambos os modelos erram mais nos extremos. A curva por `depth_max` antecipa o achado mais quantificado da §4.9.4: o *gap* SAGE–RF cresce com a profundidade. Esta subseção prepara, portanto, a leitura das duas subseções seguintes, que isolam numericamente os dois fenômenos: a inversão do modelo em subgrupos extremos (§4.9.3) e o crescimento do *gap* com a profundidade (§4.9.4).

4.9.3 Outliers e a inversão distributiva

Table 4.9: Acuracia do RF estrutural e do SAGE em seis subgrupos extremos do UPFD-GossipCop *test*. Subgrupos derivados *post-hoc* via percentil empírico (não *z*-score, justificado pela rejeição do *fit* lognormal em §4.9.1). Δ = diferença vs. acurácia agregada (RF=0.754, SAGE=0.814). *Subgrupos com classe única não admitem F1-macro.

Subgrupo	N	acc RF (Δ)	acc SAGE (Δ)	F1m RF	F1m SAGE
<code>real_viral</code>	60	0.233 (−0.520)	0.433 (−0.381)	—*	—*
<code>fake_contido</code>	31	0.000 (−0.754)	0.000 (−0.814)	—*	—*
<code>cauda_alta_n</code>	192	0.547 (−0.207)	0.823 (+0.009)	0.506	0.816
<code>cauda_baixa_n</code>	265	0.913 (+0.160)	0.913 (+0.099)	0.477	0.477
<code>deep_extreme</code>	256	0.531 (−0.222)	0.762 (−0.052)	0.528	0.741
<code>wide_extreme</code>	192	0.932 (+0.179)	0.974 (+0.160)	0.600	0.493




Figure 4.10: Acurácia do RF e do SAGE em seis subgrupos extremos definidos *post-hoc* via percentil empírico (p5/p95 sobre o *test*). Linhas pontilhadas indicam baselines agregados. O subgrupo `fake_contido` (notas falsas com baixo engajamento) e o `real_viral` (notícias verdadeiras que viralizaram) caem abaixo da chance – confirmam a inversão distributiva descrita em §4.7.




Figure 4.11: Composição real (% *fake* verdadeira) *vs.* proporção predita pelo modelo, por subgrupo. Linhas com cor diferente em uma mesma coluna indicam que o modelo não reproduz a distribuição de classes do subgrupo – característico de `real_viral` (linha “% predito fake” alta enquanto “% fake verdadeira” = 0).

A §4.7 descreveu narrativamente a inversão distributiva do classificador estrutural: no subconjunto de discordância com o textual, o SAGE atingia $F1 = 0,085$ — *abaixo* do nível da chance. A presente subseção confirma esse fenômeno com números nominais sobre subgrupos extremos definidos *post-hoc*. A Tabela 4.9 e as Figuras 4.10–4.11 re-

portam seis subgrupos, todos derivados de cortes em percentis empíricos do próprio *test*: **fake_contido** (*fakes* com grau de raiz $\leq p5$), **real_viral** (*reais* com grau de raiz $\geq p95$), **cauda_alta_n** e **cauda_baixa_n** (extremos de tamanho da cascata), **deep_extreme** (profundidade ≥ 5) e **wide_extreme** (*branching factor* acima do *p95*).

Três achados se destacam. O primeiro: dos 31 grafos de **fake_contido**, o SAGE acerta **zero** (acurácia 0,000, inversão total da regra aprendida). O segundo: dos 60 grafos de **real_viral**, o SAGE acerta apenas 26 (acurácia 0,433), *abaixo da chance* de 0,50 em problema balanceado. Esses dois subgrupos são os contra-exemplos exatos da regra implicitamente aprendida pelo classificador estrutural (“*fake* = cascata grande, *real* = cascata pequena”): *fakes* contidas violam o primeiro laço da regra, *reais* virais violam o segundo, e o modelo erra precisamente nesses violadores. Não se trata de degradação gradual; trata-se de *inversão distributiva*: a relação entre estrutura e classe está aproximadamente espelhada no subconjunto extremo em relação ao que prevalece no treinamento. O terceiro achado oferece o contraponto positivo: em **cauda_alta_n** ($N = 192$ grafos com **num_nodes** acima do *p95*), o SAGE atinge 0,823 contra 0,547 do RF, *gap* de aproximadamente 28 pontos percentuais absolutos. Quando a topologia oferece estrutura suficiente, a arquitetura neural extrai sinal que o tabular não alcança.

Esta subseção fornece a justificativa empírica mais forte para a assimetria 0,8/0,2 da regra dual (§4.7): quando o classificador estrutural discorda do textual, está sinalizando que possivelmente caiu em um dos subgrupos onde sua regra falha; pesar quatro vezes mais o textual nesse regime é instânciação direta do diagnóstico aqui construído. A caracterização explícita dos subgrupos onde o modelo erra sistematicamente também é insômo direto para a discussão de limitações (Capítulo 5, §5.3) e para o desenho da interface da ferramenta web descrita no Apêndice D, em que predições nesses subgrupos podem ser sinalizadas como “requer revisão humana”.

4.9.4 Cascatas profundas: o ganho cresce com a profundidade




Figure 4.12: Distribuição de profundidade máxima da cascata (`depth_max`) no UPFD-GossipCop *test*. 70% dos grafos tem profundidade 2 (estrela rasa); 30% tem profundidade ≥ 3 , com cauda estendendo-se até 9 *hops*. Contraria a premissa comum de que UPFD é “somente estrela plana”.

Table 4.10: Ganho do SAGE estrutural sobre o RF tabular em subsets de profundidade da cascata no UPFD-GossipCop *test*. Intervalo de confiança 95% via *bootstrap* pareado ($n_{boot} = 2000$). Todos os *subsets* apresentam ganho do SAGE significativo (IC não cruza zero). A magnitude do ganho cresce com a profundidade – consistente com a tese de que o SAGE explora propagação multi-hop, não apenas tamanho.

Subset	N	F1m RF	F1m SAGE	Diff	IC 95%
$\text{depth} \geq 1$ (todos)	3826	0.753	0.814	+0.060	[+0.047, +0.074]
$\text{depth} \geq 3$	1143	0.657	0.791	+0.134	[+0.103, +0.165]
$\text{depth} \geq 5$	256	0.528	0.741	+0.213	[+0.139, +0.287]




Figure 4.13: F1-macro do RF tabular e do SAGE estrutural por valor exato de `depth_max`. O *gap* cresce monotonicamente: +0.029 em `depth=2`, +0.130 em `depth=3`, +0.230 em `depth=5`, +0.383 em `depth=7`.




Figure 4.14: Diferença $F1(\text{SAGE}) - F1(\text{RF})$ em *subsets* de profundidade crescente, com IC 95% *bootstrap* ($n_{boot} = 2000$). Barras verdes indicam *subsets* onde o IC inferior é estritamente positivo (SAGE significativamente melhor). O *gap* em $\text{depth} \geq 5$ é 3,5× o agregado – evidência direta de que o SAGE explora propagação *multi-hop*, não só tamanho.

A Figura 4.12 desfaz uma premissa comum sobre o *dataset*: o UPFD-GossipCop oficial *não é* composto apenas por estrelas rasas. Dos 3.826 grafos do *test*, 2.683 (70,1%) têm profundidade máxima 2 (de fato estrelas), mas os 1.143 restantes (29,9%) têm profundi-

dade ≥ 3 , com cauda estendendo-se até 9 *hops*. Esta heterogeneidade estrutural é o que permite a estratificação seguinte.

A Tabela 4.10 e a Figura 4.13 reportam o $F1$ -macro do RF tabular e do SAGE estrutural estratificado por valor de `depth_max`, e o *gap* entre ambos cresce monotonicamente: +0,029 em `depth`= 2, +0,130 em `depth`= 3, +0,230 em `depth`= 5 e +0,383 em `depth`= 7. Em valores acumulados, o *gap* é de +0,060 no agregado (todos os 3.826 grafos, $IC_{95\%}$ [+0,047, +0,074]), sobe para +0,134 em `depth` ≥ 3 ($N = 1.143$, $IC_{95\%}$ [+0,103, +0,165]) e atinge +0,213 em `depth` ≥ 5 ($N = 256$, $IC_{95\%}$ [+0,139, +0,287]). Os intervalos de confiança foram obtidos por *bootstrap* pareado de 2.000 reamostragens [?] e **não cruzam zero em nenhum dos recortes**; o SAGE é significativamente melhor que RF em todos os três. A Figura 4.14 sintetiza visualmente: a razão entre o *gap* em `depth` ≥ 5 e o agregado é de aproximadamente $3,5\times$, evidência direta de que o ganho da arquitetura neural sobre o tabular *não é uniforme*: concentra-se justamente onde existe estrutura multi-hop a ser explorada.

A leitura mecanicista coerente com este achado encontra-se na §4.8: o GNNExplainer mostrou que o SAGE, em grafos *fake* (tipicamente de *branching* alto), concentra quase toda a massa de importância em arestas a 1-*hop* da raiz, portanto exatamente o sinal que o RF tabular acessa via [`num_nodes`, `grau_root`]; em grafos *real* de cascata grande, o SAGE redistribui importância para *hops* mais distantes, acessando informação que o tabular não consegue representar. É essa segunda capacidade, a propagação multi-hop, que se materializa numericamente no *gap* crescente da Figura 4.13.

Registramos, por fim, uma precisão terminológica: a observação de que “UPFD-GossipCop oficial possui 30% de grafos com `depth` ≥ 3 ” contradiz a leitura simplificada de que “UPFD é tudo estrela”. Esta segunda formulação, que encontramos em discussões preliminares deste trabalho, *não se aplica* ao *dataset* oficial de Dou et al. [1]; aplica-se apenas ao FakeNewsNet que construímos a partir do repositório CSV (limitação (a) da §5.3), em que a ausência de parentesco entre *retweets* força o grafo a degenerar em estrela rasa.

Síntese da §4.9

A estratificação agregou três contribuições ao trabalho. Primeira: confirmou numericamente, com N s explícitos e acurácias nominais, a inversão distributiva que a §4.7 havia descrito apenas em forma narrativa: o SAGE não apenas erra em `fake_contido` e `real_viral`: erra de modo sistematicamente *invertido*. Segunda: demonstrou que o $F1 = 0,810$ agregado do SAGE em UPFD-GossipCop não se distribui uniformemente: o *gap* sobre o RF tabular cresce de +0,060 no agregado para +0,213 em cascatas com `depth` ≥ 5 , com IC *bootstrap* que não cruza zero. Terceira: caracterizou explicitamente os subgrupos em que o modelo falha, fornecendo material direto para a discussão de

limitações (§5.3) e para o desenho da interface da aplicação demonstrativa (Apêndice D).

4.10 Painel mestre dos achados




Figure 4.15: Painel mestre: F1-macro por *dataset* $\times$ tipo de modelo. Azul = textual (LogReg-BERT-raiz); verde = topológico puro (GNN sem texto); vermelho = completo (GNN com *feature* textual). O contraste entre GossipCop e PolitiFact é manifesto: topologia pura aproxima-se da textual no primeiro; despenca para próximo de *chance* no segundo.

A Figura 4.15 consolida visualmente o argumento que percorre todo este capítulo. Cada *dataset* é representado por um trio de barras coloridas: **azul** para o modelo textual (LogReg-BERT-raiz), **verde** para o modelo topológico puro (GNN treinada sem texto algum) e **vermelho** para o modelo completo (GNN com *feature* textual). A leitura horizontal, entre *datasets* dentro de uma mesma cor, expõe a desigualdade que fundamenta a tese central: em UPFD-GossipCop, o modelo topológico puro aproxima-se do textual e se reconcilia com ele no modelo completo; em UPFD-PolitiFact, o topológico puro despenca para nível próximo da chance enquanto o textual mantém desempenho elevado, e o modelo completo não recupera nada além do que o texto já oferecia. A leitura vertical, entre cores dentro de um mesmo *dataset*, expõe o achado complementar: a *magnitude do ganho* aportado pela topologia ao texto depende criticamente do domínio, e essa dependência está operacionalizada pelo Cohen's *d* entre as classes (§4.6). É a esses dois eixos (horizontal e vertical) que os Capítulos seguintes voltarão para discutir limitações e direções futuras.

Chapter 5

Discussão e Conclusão

Este capítulo é o lugar onde se assume responsabilidade pelo que os experimentos efetivamente mostraram. Cada afirmação quantitativa aqui apresentada é ancorada na tabela, figura ou seção que a sustenta; afirmações sem essa âncora foram deliberadamente excluídas.

5.1 Síntese dos achados por pergunta de pesquisa

RQ1 — a topologia carrega sinal acima do que o texto da raiz já fornece? A resposta depende do *dataset* e do regime de *features*. No FakeNewsNet, o texto da raiz isoladamente já satura o sinal: o *baseline* LogReg-BERT atinge $F1\text{-macro} = \mathbf{0,859 \pm 0,043}$ sobre 10 *folds* (Tabela 4.2), e nenhuma das três arquiteturas GNN adicionada ao mesmo protocolo (GCN, GAT e SAGE com *features* estruturais sobre o FNN *posfull*) difere significativamente desse valor pelo *ttest_rel* pareado (todos ranqueados como não-significantes em §3.7). No UPFD-GossipCop, ao contrário, a topologia agrega ganho mensurável: o SAGE com *features* estruturais puras atinge $\mathbf{F1} = \mathbf{0,810 \pm 0,002}$ (Tabela 4.5), e a análise estratificada da §4.9 mostrou que esse ganho *cresce monôtonicamente com a profundidade da cascata*: de $+0,060$ no agregado para $+0,213$ em $\text{depth} \geq 5$, com intervalo de confiança *bootstrap* de 2.000 reamostragens que não cruza zero em nenhum dos recortes (Tabela 4.10). Em UPFD-PolitiFact, finalmente, não se detecta ganho topológico significativo: a mesma arquitetura SAGE sem texto colapsa para $\mathbf{F1} = \mathbf{0,331 \pm 0,009}$ (Tabela 4.5), valor abaixo do nível de chance (0,50 em problema balanceado), e as outras duas arquiteturas testadas no mesmo regime ficam pouco acima (0,362 para GCN; 0,380 para GAT), todas em colapso equivalente.

RQ2 — sob quais condições estruturais? A resposta foi operacionalizada via tamanho de efeito de Cohen (d) entre as classes em métricas de cascata (§4.6 e Tabela 4.7). O UPFD-GossipCop apresenta $\mathbf{d} = +1,53$ no *branching factor* (efeito *grande* pela escala de Cohen) e $d = +0,91$ em *num_nodes* (também grande); o UPFD-PolitiFact não al-

cança sequer um efeito médio em nenhuma métrica avaliada, com $|d|$ máximo de **0,25** em `num_nodes`; e o FakeNewsNet apresenta $|d| \approx 0,22$ em `num_nodes` e `branching_avg`, valores matematicamente idênticos por consequência direta da topologia em estrela (em estrela, $branching\ avg = num_nodes - 1$). Este contraste sustenta a **tese central**, que formulamos de modo deliberadamente falsificável:

Modelos topológicos exigem diferença estrutural entre classes da ordem de magnitude de um efeito médio de Cohen ($|d| \geq 0,5$) em pelo menos uma métrica de cascata para serem efetivos; abaixo desse limiar, colapsam, independentemente da arquitetura GNN escolhida.

A tese é refutável: a apresentação de um *dataset* com $0,2 < |d| < 0,5$ no qual uma arquitetura GNN atinja desempenho significativamente acima do *baseline* textual e do RF tabular constituiria contra-evidência direta.

RQ3 — é viável detectar fake news apenas pela topologia, em cenários sem texto explorável? A resposta também é bilateral e composta de duas partes. Quanto à parte (a), viável sem texto algum?, a Tabela 4.5 mostra que sim, mas *condicional* à condição da RQ2: SAGE com duas dimensões estruturais por nó (`is_root`, `grau_norm`) atinge $F1 = 0,810$ em GossipCop, sem nenhum acesso ao conteúdo textual da notícia. Quanto à parte (b), indiferente ao idioma do post?, a §4.5 aplicou o RF estrutural sobre subconjuntos monolíngues do Bluesky e encontrou $d = -0,057$ entre português e inglês (efeito desprezível) e $d = -0,468$ entre alemão e inglês (efeito médio) (Tabela 4.6). Como o classificador estrutural *não processa texto*, seu mecanismo é arquiteturalmente independente do idioma; a divergência DE *vs.* EN não pôde ser isolada entre fator linguístico, fator de comunidade, *shift* de domínio e desbalanço amostral.

5.2 Achado negativo é achado

O resultado de UPFD-PolitiFact merece tratamento explícito porque é metodologicamente tão importante quanto o resultado positivo de UPFD-GossipCop. Não se trata de falha de implementação: a mesma arquitetura, com o mesmo *pipeline*, atinge $F1 = 0,810$ quando treinada em um *dataset* estruturalmente assortativo (Tabela 4.5). Tampouco se trata de inadequação da família GNN em geral: as três arquiteturas testadas (GCN, GAT, SAGE) colapsam de forma equivalente em PolitiFact, respectivamente para 0,362, 0,380 e 0,331. O Cohen’s d desprezível naquele domínio (Tabela 4.7) mostra, no plano descritivo, que *fake* e *real* são *estruturalmente indistinguíveis* nas métricas de cascata avaliadas, e é justamente isso que a tese da §4.6 prevê: causa estrutural identificada, não falha de modelo.

Reportar este achado com a mesma extensão dos achados positivos não é formalismo: é exigência da tese central. Uma teoria que afirma “topologia funciona sob a condição X ” é fortalecida, não enfraquecida, pela demonstração de que ela *não funciona* quando X falha. A literatura de detecção de fake news com GNNs tende a reportar predominantemente resultados positivos; ao trazer explicitamente o caso negativo, este trabalho oferece o diagnóstico de aplicabilidade, e não apenas mais uma demonstração, que propõe como contribuição primária.

Uma evidência complementar reforça a leitura. A §4.9.3 mostrou que, mesmo no UPFD-GossipCop (onde o modelo *funciona*), há subgrupos extremos em que a regra estrutural aprendida pelo SAGE se inverte sistematicamente: dos 31 grafos do subgrupo **fake_contido** (*fakes* com grau de raiz no percentil 5 inferior), o SAGE acerta **zero**; dos 60 grafos do subgrupo **real_viral** (*reais* com grau de raiz no percentil 95 superior), acerta apenas 43%, desempenho abaixo da chance (Tabela 4.9). Esses subgrupos demarcam o *limite operacional* do mecanismo topológico: ele funciona quando a regra “*fake* = cascata maior” vale, e inverte exatamente onde essa regra falha.

5.3 Limitações

Reconhecemos sete limitações do trabalho, listadas em ordem de importância decrescente.

- (a) **Topologia em estrela no FakeNewsNet construído por nós.** O grafo gerado por `00_construir_grafos_fakenewsnet.py` (§3.3) é sempre uma estrela rasa, pois o CSV bruto do repositório KaiDMML não fornece parentesco entre *retweets* nem *timestamps*. Adicionalmente, o filtro de `MAX_NOS=100` adotado trunca metade dos grafos do *dataset* (verificação matemática em §3.3 mostrou que a distribuição bruta tem média 552 e máximo 29.060 *tweets* por notícia), tornando os 377 grafos truncados indistinguíveis quanto ao tamanho absoluto da cascata. Esta limitação vale exclusivamente para o FakeNewsNet que construímos: no UPFD-GossipCop oficial, 30% dos grafos possuem profundidade ≥ 3 , com cauda até profundidade 9 (§4.9.4).
- (b) **Regra dual derivada *post-hoc* de um único experimento.** A combinação textual + topológico exposta na §4.7 usa pesos 0,8/0,2 derivados após a observação da inversão distributiva no UPFD-GossipCop. Sua generalização a outros domínios é uma conjectura a ser testada, não um resultado validado.
- (c) **Bluesky sem rótulos de veracidade.** O *dataset* de Failla e Rossetti [2] não traça rótulos *fake/real*, o que restringe seu uso à parte (b) da RQ3 (§4.5) e à aplicação demonstrativa documentada no Apêndice D, impedindo validação supervisionada nesta fonte. Os rótulos heurísticos por palavras-chave que acompanham nossa publicação do *dataset* processado não foram empregados como supervisão.

- (d) **Reprodutibilidade não *bit-exact*.** Embora todos os *seeds* sejam fixados (42 como semente universal), o não-determinismo de operadores `scatter/gather` do PyTorch Geometric e a sensibilidade aritmética entre versões de biblioteca podem produzir variações na terceira casa decimal das métricas reportadas. As conclusões qualitativas são robustas a essa variação: os achados centrais foram validados em 10 *seeds* independentes (§4.4) e em *bootstrap* pareado de 2.000 reamostragens (§4.9.4).
- (e) **Ausência de comparativo numérico direto com BiGCN e GCNFN.** Não foi viável re-implementar essas arquiteturas dentro do escopo do trabalho; a comparação com Dou et al. [1] é indicativa (Tabela 4.4) por três diferenças declaradas: *feature content* (310d) em vez de *bert* (768d), hiperparâmetros próprios, e métrica F1-macro em vez de acurácia.
- (f) **Bluesky é *snapshot* temporal.** O dado coletado por [2] cobre 11 *feeds* temáticos da plataforma em janela de aproximadamente um ano; generalização para janelas temporais futuras não é garantida.
- (g) **Ambiente exclusivamente CPU.** Todos os experimentos foram executados em CPU (Intel *Raptor Lake*, 16 *cores* lógicos, 16 GB de RAM, PyTorch 2.10+cpu). Hiperparâmetros adotados podem ser subótimos em ambientes com GPU; o *pipeline*, no entanto, é portátil.

5.4 Trabalhos futuros

Quatro direções naturais se desdobram dos achados deste trabalho.

(1) **Pseudo-rótulos no Bluesky para retreino especializado.** A inferência *cross-domain* demonstrada no Apêndice D poderia ser convertida em ciclo de auto-treinamento: usar o LogReg-BERT treinado em FakeNewsNet como oráculo para gerar pseudo-rótulos em um subconjunto de alta confiança do Bluesky, e então retreinar classificadores estruturais especializados para a plataforma. Os 168.463 posts disponíveis (§D.1) tornariam o experimento tratável.

(2) **Calibração de probabilidades.** O *score* produzido pelo RF estrutural sobre o Bluesky é empregado como *proxy* ordinal (§D.2); transformá-lo em probabilidade calibrada exigiria técnicas como *Platt scaling* ou regressão isotônica, o que demanda subconjunto rotulado no domínio-alvo.

(3) **Expansão para *datasets* de noticiário contemporâneo.** A existência de pelo menos um domínio com $|d| < 0,5$ (UPFD-PolitiFact) sugere que a tese central possa ser

refinada com mais *datasets* de diferentes plataformas (Mastodon, Threads, X pós-2023) e diferentes janelas temporais, testando se o limiar de 0,5 é exato ou apenas ordem de magnitude.

(4) Replicação direta de BiGCN e GCNFN. Para preencher a limitação (e) acima, vale re-implementar essas arquiteturas e submetê-las ao mesmo protocolo de avaliação adotado aqui (mesmo k -fold, mesmo $ttest_rel$ pareado), permitindo confronto *bit-exact* com a literatura.

5.5 Considerações finais

Este trabalho não propôs uma nova arquitetura de Rede Neural de Grafos. Propôs, em seu lugar, um *diagnóstico*: sob quais condições a topologia da propagação detecta fake news, e quando não detecta. Três *datasets*, três arquiteturas e mais de uma dezena de métricas (Tabela 4.1) convergem para uma tese única e refutável: a aplicabilidade depende de assortatividade estrutural mensurável ($|d| \geq 0,5$). A defesa de um resultado negativo (UPFD-PolitiFact) lado a lado de um resultado positivo (UPFD-GossipCop), ancorada em estatística de tamanho de efeito e validada por análise estratificada do erro com *bootstrap* pareado, é a contribuição metodológica que esperamos transcender o escopo do *dataset* específico. O código, os pesos persistidos no Hugging Face Hub e a ferramenta web (Apêndice D) permitem que esta posição seja contestada empiricamente em outros domínios, exatamente como a tese, por ser falsificável, exige.

Bibliography

- [1] Yingtong Dou, Kai Shu, Congying Xia, Philip S. Yu, and Lichao Sun. User preference-aware fake news detection. In *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*, pages 2051–2055, 2021.
- [2] Andrea Failla and Giulio Rossetti. “I’m in the Bluesky Tonight”: Insights from a Year’s Worth of Social Data. *PLOS ONE*, 19(11):e0310330, 2024. Dataset utilizado no Cap 5; disponível no Zenodo, DOI 10.5281/zenodo.14258401.
- [3] Kai Shu, Deepak Mahudeswaran, Suhang Wang, Dongwon Lee, and Huan Liu. FakeNewsNet: A data repository with news content, social context, and spatiotemporal information for studying fake news on social media. *Big Data*, 8(3):171–188, 2020.
- [4] César Augusto Sibila, André Messina Livingston, and Enzo Kikuji Takida. Bluesky Fake News Dataset: A curated snapshot of bluesky posts and repost cascades (2024–2025). Hugging Face Datasets, 2026. Curado pelos autores a partir de um dump público da firehose do Bluesky; rótulos heurísticos derivados de etiquetas de moderação da API e léxico ad-hoc de termos de desinformação.

Apêndices

Appendix A

Hiperparâmetros completos

Appendix B

Índice geral de figuras e tabelas

Appendix C

Estrutura do repositório de código

Appendix D

Aplicação demonstrativa: Bluesky e ferramenta web

Este apêndice documenta a aplicação dos modelos persistidos sobre o *dataset* acadêmico do Bluesky e a ferramenta web que integra os classificadores textual e topológico. É matéria *demonstrativa*, não validatória: o Bluesky não possui rótulos *fake/real*, e portanto nenhum *claim* supervisionado é feito a partir deste material. A validação quantitativa do trabalho está inteiramente no Capítulo 4; a parte referente à independência linguística (RQ3-b) está na §4.5.

D.1 O *dataset* Bluesky

Utilizamos o *snapshot* acadêmico publicado por Failla e Rossetti [2], que cobre 168.463 posts distribuídos em 11 *feeds* temáticos (*Blacksky*, *News*, *Science*, *Political Science*, entre outros), coletados via AT Protocol [?]. O dado é *snapshot* e não amostra probabilística — a limitação temporal está registrada como item (f) da §5.3. O empacotamento publicado pelos autores deste trabalho no Hugging Face Hub [4] preserva a estrutura original dos *feeds* e adiciona rótulos heurísticos por palavra-chave que *não foram empregados* como supervisão em momento algum do *pipeline*.

D.2 Inferência *cross-domain* dos modelos persistidos

Aplicamos o classificador textual (LogReg-BERT-*content* treinado em FakeNewsNet Poli-tiFact) e o classificador topológico (RF estrutural treinado em UPFD-GossipCop) sobre os 168.463 posts. A Tabela ?? reporta a média do *score* “*fake-like*” do RF estrutural por *feed*, permitindo *ranking* relativo entre comunidades.

Table D.1: Aplicacao do RF estrutural (treinado em GossipCop) sobre 168k posts do Bluesky – ranking de feeds por score ‘fake-like’.

Feed Bluesky	N	Score medio	% pred=fake
Political Science	357	0.6663	69.2%
Blacksky	86490	0.4391	32.0%
What’s History	161	0.3665	28.0%
#Disability	566	0.3475	17.1%
#UkrainianView	2098	0.3377	26.1%
Science	33831	0.3374	23.0%
BookSky	638	0.3210	12.5%
GreenSky	662	0.3120	14.2%
AcademicSky	913	0.3095	10.0%
Game Dev	635	0.2809	4.4%
News	42112	0.2704	6.7%




Figure D.1: Distribuição do *score* “fake-like” produzido pelo RF estrutural sobre os 168.463 posts do Bluesky, estratificada por *feed*.

Limitação explícita de interpretação. O *score* reportado *não é probabilidade calibrada*. É a saída `predict_proba` do RF treinado em UPFD-GossipCop, aplicada a um domínio diferente (Bluesky), sem *ground-truth* que permita calibração por *Platt scaling* ou regressão isotônica. A interpretação correta é como *proxy ordinal* — útil para o *ranking* relativo entre *feeds* reportado na Tabela ??, não para decisão absoluta. Trabalho futuro (§5.4, item 2) discute essa calibração.

D.3 Concordância textual $\times$ topológico

Sobre uma amostra estratificada de 3.728 posts com cascata mínima para visualização da árvore de propagação, comparamos as predições do classificador textual com as do topológico (novamente: sem *ground-truth*, apenas concordância entre classificadores). A taxa de concordância agregada é moderada, seguindo o mesmo padrão observado em UPFD-GossipCop (§4.7): *posts* com cascata grande tendem à concordância ($\geq 74\%$ para $n_{\text{nodes}} \geq 20$), *posts* de tamanho médio caem na zona cinzenta (42% a 44% para $2 \leq n_{\text{nodes}} \leq 20$). O *feed Political Science* atinge 88,7% de concordância agregada — o mais alto da amostra — o que sugere que comunidades politicamente engajadas geram sinais textuais e estruturais mais alinhados.

D.4 Ferramenta web

A aplicação web (FastAPI *backend* + Next.js *frontend*) integra os três modelos persistidos — LogReg-BERT-*content*, RF estrutural e SAGE estrutural — expostos através do *endpoint* `/api/result`. A combinação das predições textual e topológica segue a regra dual derivada *post-hoc* dos resultados do Capítulo 4 (Equação 4.1 e Figura 4.5):

Listing D.1: Trecho da regra dual no *backend* FastAPI.

```
def _combinar_scores(score_textual, score_topo):
    pred_t = score_textual >= 0.5
    pred_k = score_topo >= 0.5
    if pred_t == pred_k:
        return 0.5 * score_textual + 0.5 * score_topo, True
    return 0.8 * score_textual + 0.2 * score_topo, False
```

Os pesos do modelo são carregados a partir do repositório publicado no Hugging Face Hub [4] sob licença CC-BY-4.0; o código da *API*, os *scripts* de inferência e o *frontend* estão no repositório Git do trabalho (Apêndice C). A ferramenta foi construída como prova de conceito de *deploy*, não como produto auditado para uso em moderação real — decisões sobre conteúdo a partir desses *scores* devem respeitar as limitações documentadas no Capítulo 5, em especial a ausência de calibração de probabilidades e a dependência de assortatividade estrutural do domínio-alvo.